

Stochastische Prozesse

Vorlesung von Prof. Jiří Černý in 2024

Mitschrift von David Flückiger

Stand: 17. Mai 2024

Inhaltsverzeichnis

1. Einführung	3
1.1. Organisation	3
1.2. Einleitung und Beispiele	3
2. Markov-Ketten: Basics und erste Resultate	7
2.1. Basics und Definition	7
2.2. Existenz und Simulation von Markov-Ketten	12
2.3. Invariante Verteilungen von Markov-Ketten	15
2.4. Kommunikationsklassen	18
3. Intermezzo: Bedingte Erwartung	20
4. Markov-Ketten: Langzeitverhalten	22
4.1. Starke Markov-Eigenschaft	22
4.2. Beispiel: Reflektionsprinzip für einfache Irrfahrten	25
4.3. Langzeitverhalten von Markov-Ketten	26
4.4. Existenz und Eindeutigkeit invarianter Verteilungen und Masse	32
5. Konvergenz von Markov-Ketten	38
5.1. Periodizität	38
5.2. Kupplung von Markov-Ketten	40
5.3. Markov-Chain-Monte-Carlos*	43
6. Standard-Poisson-Prozess	45
6.1. Einführung und Repetition	45
6.2. Definition des Poisson-Prozesses	47
6.3. Charakterisierung von Poisson-Prozessen	49
6.4. Stationäre Poisson-Prozesse	53
6.5. Verzweigungsprozesse	54
7. Markov-Ketten in stetiger Zeit	59
7.1. Definition und Basics	59
7.2. Konstruktion einer Markov-Kette in stetiger Zeit aus den Raten	62
7.3. Klassifizierung stetiger Markov-Ketten	69
7.4. Invariante Verteilungen zeitstetiger Markov-Ketten	72
8. Reversible Markov-Ketten, harmonische Funktionen und elektrische Netzwerke	73
A. Diverses	75
A.1. Erzeugendenfunktionen	75

1. Einführung

1.1. Organisation

- Die Übungsstunde findet in der ersten Woche nicht statt.
- Um die Punkte für jeweils Vorlesung und Übung zu bekommen, müssen beide Kurse abgeschlossen werden, d.h. die jeweilige Prüfung muss bestanden werden. Beispiel: Ist die Übung nicht bestanden erhält man auch die Vorlesungspunkte nicht.
- Die Übungen müssen jede Woche abgegeben werden. Es sind 50% der Punkte zu erreichen, um an der Schlussklausur teilnehmen zu können.
- Über die Vorlesung gibt es dann ein mündliches Examen, welches die Note *zusammen* mit der Abschlussklausur der Übungen gibt.
- Das mündliche Examen ist voraussichtlich am 18. Juni und die schriftliche Klausur in der letzten Übungsstunde.
- Schriftliche Klausur ist am letzten Mittwoch im Semester.
- Gesamtnote

$$\frac{\max\{\text{Note Klausur}, 3.5\}}{3} + \frac{2}{3}\text{Note Vorlesung}$$

1.2. Einleitung und Beispiele

Wir besprechen in dieser Vorlesung:

- Markov-Ketten (diskret und stetige Zeit),
- Poisson Prozesse,
- Renewal-Prozesse und
- Branching-Prozesse.

Motivation. Oftmals sind wir nicht an einzelnen Ereignissen, sondern an Verläufen von Ereignissen interessiert. Beispielsweise interessieren wir uns für den Verlauf des Wetters und weniger für das Wetter an einem bestimmten Zeitpunkt.

Einige Repetitionen:

Wahrscheinlichkeitsraum. Wir nennen das Tripel $(\Omega, \mathcal{A}, \mathbb{P})$ Wahrscheinlichkeitsraum. Ω ist eine beliebige Menge, $\mathcal{A}$ eine σ -Algebra über Ω und $\mathbb{P}$ ein Wahrscheinlichkeitsmass.

Zustandsraum. Der Zustandsraum ist der Raum, wo der stochastische Prozess Werte annimmt. Wir nehmen dafür eine Menge E , welche auch mit einer σ -Algebra $\mathcal{E}$ versehen ist, das heisst, $(E, \mathcal{E})$ ist ein messbarer Raum (z.B. $(E, \mathcal{E}) = (\mathbb{R}, \mathcal{B}(\mathbb{R}))$ oder $(\mathbb{N}, \mathcal{P}(\mathbb{N}))$).

Folgende Definition dürfte auch schon bekannt sein:

Definition 1.1. Eine E -wertige **Zufallsvariable**(ZV) ist eine messbare Abbildung $X : \Omega \rightarrow E$, d.h. für jedes $A \in \mathcal{E}$ gilt

$$X^{-1}[A] := \{\omega \in \Omega \mid X(\omega) \in A\} \in \mathcal{A}.$$

Notation 1.2. Wir werden die Notation

$$\mathbb{P}(X \in A) := \mathbb{P}(\{\omega \in \Omega \mid X(\omega) \in A\}) \quad \text{und} \quad \mathbb{P}_X(A) := \mathbb{P}(X \in A)$$

verwenden.

Beispiel 1.3.

- Wählen wir $E = \{\pm 1\}$, $\mathcal{E} = \mathcal{P}(E)$ und definieren $X : \Omega \rightarrow E$ sodass

$$\mathbb{P}(X = 1) = \mathbb{P}(X = -1) = \frac{1}{2},$$

modelliert dies einen Münzenwurf

- Ein weiteres Beispiel wäre $E = \mathbb{R}$, $\mathcal{E} = \mathcal{B}(\mathbb{R})$ und $X \sim \mathcal{N}(0, 1)$, das heisst, X ist *standardnormalverteilt*, also

$$\mathbb{P}(X \in A) = \frac{1}{\sqrt{2\pi}} \int_A e^{-x^2/2} dx.$$

△


Definition 1.4. Ein **stochastischer Prozess in diskreter Zeit** ist eine Folge $X = (X_n)_{n \in \mathbb{N}_0}$ von E -wertigen Zufallsvariablen, die alle auf dem gleichen Wahrscheinlichkeitsraum definiert sind.

Ein stochastischer Prozess in diskreter Zeit ist nichts anderes als eine zufällige Folge von Objekten in E . Für $\omega \in \Omega$ gegeben ist $X_0(\omega), X_1(\omega), X_2(\omega), \dots$ eine gewöhnliche E -wertige Folge.

Beispiel 1.5 (Einfache Irrfahrt auf $\mathbb{Z}$). Sei $(\xi_i)_{i \in \mathbb{N}}$ eine Folge von Zufallsvariablen die unabhängige Münzenwürfe modellieren mit z.B.

$$\mathbb{P}(\xi_i = 1) = \mathbb{P}(\xi_i = -1) = \frac{1}{2} \quad \text{für alle } i \in \mathbb{N}. \quad (1.1)$$

Wir betrachten nun die Folge $X_n := \xi_1 + \dots + \xi_n$ und nennen diese Irrfahrt oder Random walk, siehe Figure 1.1 △

Abbildung 1.1.: Random Walk auf $\mathbb{Z}$

Definition 1.6. Ein **stochastischer Prozess in stetiger Zeit** ist eine Familie $X = (X_t)_{t \in \mathbb{R}_+}$ ($\mathbb{R}_+ = \mathbb{R}_{\geq 0}$) von E -wertigen Zufallsvariablen, die alle auf dem gleichen Wahrscheinlichkeitsraum definiert sind.

Bemerkung 1.7. Wir können stochastische Prozesse mit einer allgemeinen Indexmenge I definieren d.h. wir betrachten dann $X = (X_t)_{t \in I}$. $\triangle$

Ein stochastischer Prozess in diskreter Zeit ist nichts anderes als eine zufällige E -wertige Funktion. Für $\omega \in \Omega$ gegeben ist $t \in \mathbb{R}_{\geq 0} \mapsto X_t(\omega) \in E$ eine gewöhnliche E -wertige Funktion. Diese Funktion muss nicht unbedingt stetig sein. Wir werden in dieser Vorlesung mit einer abzählbaren Menge E arbeiten und Fälle betrachten, wo $t \in \mathbb{R}_{\geq 0} \mapsto X_t(\omega) \in E$ eine stückweise konstante Funktion ist.

Wir geben nun noch zwei wichtige Beispiele von stochastischen Prozessen:

Beispiel 1.8 (Einfache Irrfahrt auf $\mathbb{Z}^d$). Sei $E = \mathbb{Z}^d$, $I = \mathbb{N}_0$. Wir sagen, dass $\mathbf{x}, \mathbf{y} \in \mathbb{Z}^d$ Nachbarn sind falls $|\mathbf{x} - \mathbf{y}| = 1$. Wir betrachten nun ein Teilchen, dass in $\mathbf{0} \in \mathbb{Z}^d$ startet und in jedem Schritt „gleichmässig“ von einer Position zu einem Nachbarn springt. Für $d = 1$ ist dies genau die in Example 1.5 beschriebene Irrfahrt.

Formal: Für $(\xi_i)_{i \in \mathbb{N}}$ unabhängig mit

$$\mathbb{P}(\xi_i = \pm \mathbf{e}_j) = \frac{1}{2d} \quad \text{für } j = 1, \dots, d \text{ und } i \in \mathbb{N},$$

wo $(\mathbf{e}_1, \dots, \mathbf{e}_d)$ die Standardbasis des $\mathbb{R}^d$ ist, definieren wir $\mathbf{X}_n := \xi_1 + \dots + \xi_n$. Aus dem Gesetz der grossen Zahlen wissen wir, dass

$$\frac{\mathbf{X}_n}{n} \xrightarrow[n \rightarrow +\infty]{\text{f.s.}} \mathbb{E}[\xi_i] = \mathbf{0} \quad \text{d.h.} \quad \mathbb{P}\left(\lim_{n \rightarrow +\infty} \left| \frac{\mathbf{X}_n}{n} - \mathbb{E}[\xi_i] \right| = 0\right) = 1$$

und mit dem *zentralen Grenzwertsatz* folgt

$$\frac{\mathbf{X}_n}{\sqrt{n}} \xrightarrow[n \rightarrow +\infty]{d} \mathcal{N}(0, 1),$$




Abbildung 1.2.: Visualisierung eines Poisson Prozesses

das heisst,

$$\lim_{n \rightarrow +\infty} \mathbb{P} \left(\frac{\mathbf{X}_n}{\sqrt{n}} \in A \right) = \frac{1}{\sqrt{(2\pi)^d}} \int_A e^{-|\mathbf{x}|^2/2} d\mathbf{x}$$

für alle $A \in \mathcal{B}(\mathbb{R}^d)$.

Frage 1.9. Wie oft nimmt $\mathbf{X}_n$ den Wert $\mathbf{0}$ an?

Falls $d = 1, 2$ nimmt $\mathbf{X}_n$ den Wert $\mathbf{0}$ unendlich oft an. Für $d \geq 3$ lässt sich zeigen $\mathbf{X}_n = \mathbf{0}$ kommt fast sicher endlich viele Male vor. $\triangle$

Beispiel 1.10 (Poisson-Prozess). Wir betrachten den Prozess $(N_t)_{t \in \mathbb{R}_+}$, wo N_t die Anzahl Autos, die vor der Zeit t durchgefahren sind modelliert. Weiterhin sei T_n die Durchfahrzeit des n -ten Autos für alle $n \in \mathbb{N}$. Nun gilt

$$N_t = \#\{i \in \mathbb{N} : T_i \leq t\} = \sum_{i=1}^{+\infty} \mathbb{1}_{T_i \leq t}.$$

Wir nennen den Prozess $(T_i)_{i \in \mathbb{N}_0}$ *Zählprozess*. Sind weiter

$$T_1, T_2 - T_1, \dots, T_k - T_{k-1} \sim \text{Exp}(\lambda)$$

unabhängige Zufallsvariablen, dann nennen wir den Prozess $(N_t)_{t \in \mathbb{R}_+}$ *Poisson-Prozess*. Der Name kommt vom Fakt, dass $N_t \sim \text{Pois}(\lambda t)$. $\triangle$

2. Markov-Ketten: Basics und erste Resultate

2.1. Basics und Definition

Sei im Folgenden $(\Omega, \mathcal{F}, \mathbb{P})$ ein Wahrscheinlichkeitsraum und E eine endliche oder abzählbare Menge. Eine Markov Kette in diskreter Zeit ist ein gedächtnisloser stochastischer Prozess $X = (X_n)_{n \in \mathbb{N}_0}$ d.h. für alle $n \in \mathbb{N}_0$ ist die Zukunft $(X_{k+n})_{k \in \mathbb{N}_0}$ nur abhängig von dem aktuellen Wert von X_n und nicht von der Vergangenheit d.h. von $(X_0, \dots, X_{n-1})$. Ziel dieses Kapitels wird es sein, Markov-Ketten zu konstruieren, deren Zusammenhang zur linearen Algebra erläutern und das Langzeitverhalten dieser Objekte zu analysieren. Weiter werden wir die Markov-Eigenschaft besprechen.

Definition 2.1 (Markov Kette). Eine Folge von Zufallsvariablen $X = (X_n)_{n \in \mathbb{N}_0}$ mit Werten in E , heisst **homogene zeitdiskrete Markov-Kette**(MC) falls die folgenden Eigenschaften erfüllt sind:

1. Markov Eigenschaft (ein Schritt): Es gilt

$$\mathbb{P}(X_{n+1} = x_{n+1} \mid X_0 = x_0, \dots, X_n = x_n) = \mathbb{P}(X_{n+1} = x_{n+1} \mid X_n = x_n)$$

für jedes $n \geq 0$ und $x_0, \dots, x_{n+1} \in E$ mit

$$\mathbb{P}(X_0 = x_0, \dots, X_n = x_n) > 0. \quad (2.1)$$

2. Homogenität: Für alle $m, n \in \mathbb{N}_0$ $x, y \in E$ gilt

$$\mathbb{P}(X_{n+1} = y \mid X_n = x) = \mathbb{P}(X_{m+1} = y \mid X_m = x).$$

Bemerkung 2.2. In Definition 2.1 fordern wir, dass die Bedingte Wahrscheinlichkeit existiert, was dank (2.1) der Fall ist. Konvention ist, dass man wenn man $\mathbb{P}(A \mid B)$ schreibt, nimmt man implizit $\mathbb{P}(B) > 0$ an. $\triangle$

Bemerkung 2.3. Es gibt eine äquivalente Definition zu Definition 2.1: Für alle Funktionen $f : E \rightarrow \mathbb{R}$ die beschränkt sind, gilt

$$\mathbb{E}[f \circ X_{n+1} \mid X_0 = x_0, \dots, X_n = x_n] = \mathbb{E}[f \circ X_{n+1} \mid X_n = x_n]. \quad (2.2)$$

In der Tat

$$\begin{aligned}
\mathbb{E}[f \circ X_{n+1} \mid X_0 = x_0, \dots, X_n = x_n] &= \int_{\Omega} f \circ X_{n+1}(\omega) d\mathbb{P}(\omega \mid X_0 = x_0, \dots, X_n = x_n) \\
&= \sum_{x \in E} f(x) \mathbb{P}(X_{n+1} = x \mid X_0 = x_0, \dots, X_n = x_n) \\
&= \sum_{x \in E} f(x) \mathbb{P}(X_{n+1} = x \mid X_n = x_n) \\
&= \mathbb{E}[f \circ X_{n+1} \mid X_n = x_n],
\end{aligned}$$

was (2.2) zeigt. $\triangle$

Beispiel 2.4. Sei $X = (X_n)_{n \in \mathbb{N}_0}$ eine Folge von unabhängigen identisch verteilten (i.i.d) E -wertigen Zufallsvariablen. Dann gilt

$$\begin{aligned}
\mathbb{P}(X_{n+1} = x_{n+1} \mid X_0 = x_0, \dots, X_n = x_n) &= \frac{\mathbb{P}(X_0 = x_0, \dots, X_n = x_n, X_{n+1} = x_{n+1})}{\mathbb{P}(X_0 = x_0, \dots, X_n = x_n)} \\
&\stackrel{\text{Unabh.}}{=} \frac{\prod_{i=0}^{n+1} \mathbb{P}(X_i = x_i)}{\prod_{i=0}^n \mathbb{P}(X_i = x_i)} \\
&= \mathbb{P}(X_{n+1} = x_{n+1}).
\end{aligned}$$

Daraus lässt sich schnell zeigen, dass X eine Markov-Kette ist (der Beweis der zweiten Eigenschaft wird dem Leser überlassen). $\triangle$

Beispiel 2.5 (Einfach Irrfahrt auf $\mathbb{Z}^d$). Seien $(\mathbf{Z}_n)_{n \in \mathbb{N}}$ i.i.d uniform auf den Einheitsvektoren $(\pm \mathbf{e}_1, \dots, \pm \mathbf{e}_d)$ verteilt. Definiere $\mathbf{X}_n := \mathbf{Z}_1 + \dots + \mathbf{Z}_n$ und $\mathbf{X}_0 := 0$. Dann ist $(\mathbf{X}_n)_{n \in \mathbb{N}}$ eine Markov-Kette, denn für $\mathbf{x}_0, \dots, \mathbf{x}_{n+1} \in \mathbb{Z}^d$ beliebig (mit der Konvention aus Remark 2.3 folgt

$$\begin{aligned}
\mathbb{P}(\mathbf{X}_{n+1} = \mathbf{x}_{n+1} \mid \mathbf{X}_0 = \mathbf{x}_0, \dots, \mathbf{X}_n = \mathbf{x}_n) &= \mathbb{P}\left(\mathbf{Z}_{n+1} = \mathbf{x}_{n+1} - \mathbf{x}_n \mid \bigcap_{i=1}^n \{\mathbf{Z}_i = \mathbf{x}_i - \mathbf{x}_{i-1}\}\right) \\
&\stackrel{\text{Unabh.}}{=} \mathbb{P}(\mathbf{Z}_{n+1} = \mathbf{x}_{n+1} - \mathbf{x}_n)
\end{aligned}$$

Genauso

$$\begin{aligned}
\mathbb{P}(\mathbf{X}_{n+1} = \mathbf{x}_{n+1} \mid \mathbf{X}_n = \mathbf{x}_n) &= \frac{\mathbb{P}(\mathbf{Z}_{n+1} = \mathbf{x}_{n+1} - \mathbf{x}_n, \mathbf{X}_n = \mathbf{x}_n)}{\mathbb{P}(\mathbf{X}_n = \mathbf{x}_n)} \\
&\stackrel{\text{Unabh.}}{=} \mathbb{P}(\mathbf{Z}_{n+1} = \mathbf{x}_{n+1} - \mathbf{x}_n),
\end{aligned}$$

das heisst, $(\mathbf{X}_n)_{n \in \mathbb{N}_0}$ hat die Markov-Eigenschaft. Weiter gilt

$$\mathbb{P}(\mathbf{X}_{n+1} = \mathbf{y} \mid \mathbf{X}_n = \mathbf{x}) = \mathbb{P}(\mathbf{Z}_{n+1} = \mathbf{y} - \mathbf{x}) = \begin{cases} \frac{1}{2d} & |x - y| = 1 \\ 0 & \text{sonst} \end{cases},$$

damit ist die rechte Seite unabhängig von n , was die Homogenität zeigt. $\triangle$

Definition 2.6 (Übergangswahrscheinlichkeiten). Eine Übergangswahrscheinlichkeit ist eine Familie $(p_{x,y})_{x,y \in E}$ sodass




Abbildung 2.1.: Gewichteter, gerichteter Graph. Die Zahlen an den Kanten sind die Wahrscheinlichkeiten, gegeben man ist bei Punkt x , nach y zu gehen.

- Für alle $x, y \in E$ ist $p_{x,y} \geq 0$,
- für alle $x \in E$,

$$\sum_{y \in E} p_{x,y} = 1.$$

Bemerkung 2.7 (Darstellung von Übergangswahrscheinlichkeiten). Ist E endlich mit $|E| = N$, können wir $(p_{x,y})_{x,y}$ als Matrix

$$\mathbf{P} = \begin{bmatrix} p_{1,1} & \cdots & p_{1,N} \\ \vdots & & \vdots \\ p_{N,1} & \cdots & p_{N,N} \end{bmatrix}$$

mit positiven Einträgen auffassen. Alle Zeilen von p summieren sich zu 1. Generell können wir $(p_{x,y})_{x,y}$ als positiven linearen Operator

$$p : B(E, \mathbb{R}) \rightarrow B(E, \mathbb{R}), \quad (pf)(x) = \sum_{y \in E} p_{x,y} f(y)$$

mit $B(E, \mathbb{R}) = \{f : E \rightarrow \mathbb{R} \mid f \text{ beschränkt}\}$ betrachten. Dieser hat den Eigenvektor $f \equiv 1$.

Weiter lässt sich $(p_{x,y})_{x,y \in E}$ als gewichteter gerichteter Graph darstellen: E ist die Menge der Knoten und (x, y) wäre eine Kante mit Wahrscheinlichkeit/Gewicht $p_{x,y} \geq 0$, siehe ??.

Bemerkung 2.8. Erinnerung aus „Einführung in die Statistik“: Ist E abzählbar entspricht ein Wahrscheinlichkeitsmass μ auf E einer Folge $(\mu_x)_{x \in E}$ mit

- $\mu_x \geq 0$ für alle $x \in E$,
- $\sum_{x \in E} \mu_x = 1$ und
- $\mu(A) = \sum_{x \in A} \mu_x$.

Wir werden die Menge an Wahrscheinlichkeitsmassen auf E mit $\mathcal{M}(E)$ bezeichnen. $\triangle$

Definition 2.9. Sei p eine Übergangswahrscheinlichkeit und μ ein Wahrscheinlichkeitsmass auf E . Eine Folge $(X_n)_{n \in \mathbb{N}_0}$ von Zufallsvariablen mit Werten in E ist eine **Markov-Kette mit Startverteilung $\mu = (\mu_x)_{x \in E}$ und Übergangswahrscheinlichkeiten $p = (p_{x,y})_{x,y \in E}$** (MC(μ, p)) falls für alle $x_0, \dots, x_n \in E$,

$$\mathbb{P}(X_0 = x_0, \dots, X_n = x_n) = \mu_{x_0} p_{x_0, x_1} \cdots p_{x_{n-1}, x_n},$$

wobei wir $p_{x,y}$ als Wahrscheinlichkeit von x nach y zu springen interpretieren werden.

Satz 2.10. Sei $(X_n)_{n \in \mathbb{N}_0}$ eine Folge von E -wertigen Zufallsvariablen. Dann sind die folgenden Aussagen äquivalent:

1. $(X_n)_{n \in \mathbb{N}_0}$ ist eine Markov-Kette.
2. Es gibt ein Wahrscheinlichkeitsmass μ und eine Übergangswahrscheinlichkeit p , so dass $(X_n)_{n \in \mathbb{N}}$ ist eine MC(μ, p).

Beweis. (1) $\Rightarrow$ (2): Setze $\mu_x := \mathbb{P}(X_0 = x)$, das heisst, μ ist die Verteilung von X_0 . Weiter definieren wir

$$p_{x,y} := \begin{cases} \mathbb{P}(X_{n+1} = y \mid X_n = x) & \text{falls } n \text{ existiert mit } \mathbb{P}(X_n = x) > 0 \\ \mathbb{1}_{\{x=y\}} & \text{sonst} \end{cases}.$$

Dies ist wohldefiniert, da $(X_n)_{n \in \mathbb{N}_0}$ als Markov-Kette homogen ist. Dann folgt für $x_0, \dots, x_n \in E$ beliebig aus der Definition der bedingten Wahrscheinlichkeit

$$\begin{aligned} \mathbb{P}(X_0 = x_0, \dots, X_n = x_n) \\ = \mathbb{P}(X_n = x_n \mid X_{n-1} = x_{n-1}, \dots, X_0 = x_0) \mathbb{P}(X_{n-1} = x_{n-1}, \dots, X_0 = x_0). \end{aligned}$$

Daraus folgt induktiv

$$\begin{aligned} \mathbb{P}(X_0 = x_0, \dots, X_n = x_n) &= \mathbb{P}(X_0 = x_0) \prod_{i=1}^n \mathbb{P}(X_i = x_i \mid X_0 = x_0, \dots, X_{i-1} = x_{i-1}) \\ &= \mathbb{P}(X_0 = x_0) \prod_{i=1}^n \mathbb{P}(X_i = x_i \mid X_{i-1} = x_{i-1}) \\ &= \mu_{x_0} p_{x_0, x_1} \cdots p_{x_{n-1}, x_n}. \end{aligned}$$

Es bleibt zu zeigen, dass $p = (p_{x,y})_{x,y \in E}$ eine Übergangswahrscheinlichkeit ist. Sei $x \in E$ sodass $\mathbb{P}(X_n = x) > 0$, dann ist

$$\sum_{y \in E} p_{x,y} = \sum_{y \in E} \mathbb{P}(X_{n+1} = y \mid X_n = x) = 1,$$

da wir Wahrscheinlichkeiten von disjunkten Ereignissen addieren. Ist $\mathbb{P}(X_n = x) = 0$ für alle $n \in \mathbb{N}$ gilt

$$\sum_{y \in E} p_{x,y} = \sum_{y \in E} \mathbb{1}_{\{x=y\}} = 1.$$

(2) $\Rightarrow$ (1): Seien $x_0, \dots, x_{n+1} \in E$ mit $\mu_{x_0} p_{x_0, x_1} \dots p_{x_n, x_{n+1}} > 0$. Dann ist

$$\mathbb{P}(X_{n+1} = x_{n+1} \mid X_0 = x_0, \dots, X_n = x_n) = \frac{\mu_{x_0} p_{x_0, x_1} \dots p_{x_n, x_{n+1}}}{\mu_{x_0} p_{x_0, x_1} \dots p_{x_{n-1}, x_n}} = p_{x_n, x_{n+1}} \quad (2.3)$$

und für $x, y \in E$ mit $\mathbb{P}(X_n = x) > 0$ für ein $n \in \mathbb{N}_0$ folgt

$$\begin{aligned} \mathbb{P}(X_{n+1} = y \mid X_n = x) &= \sum_{\substack{u_i \in E \\ i=1, \dots, n-1}} \mathbb{P}(X_{n+1} = y, X_0 = u_0, \dots, X_{n-1} = u_{n-1} \mid X_n = x) \\ &= \sum_{\substack{u_i \in E \\ i=1, \dots, n-1}} \mathbb{P}(X_{n+1} = y \mid X_0 = u_0, \dots, X_{n-1} = u_{n-1}, X_n = x) \mathbb{P}(X_0 = u_0, \dots, X_{n-1} = u_{n-1}) \\ &\stackrel{(2.3)}{=} p_{x,y} \cdot \sum_{\substack{u_i \in E \\ i=1, \dots, n-1}} \mathbb{P}(X_0 = u_0, \dots, X_{n-1} = u_{n-1}) = p_{x,y}. \end{aligned}$$

Dies zeigt die Eigenschaften der Markov-Kette nach Definition 2.1. $\square$

Bemerkung 2.11. Theorem 2.10 erlaubt es uns, Markov Ketten nur durch die Anfangsverteilung und die Übergangsmatrix/die Familie von Übergangswahrscheinlichkeiten zu definieren. Ist $E = \{1, \dots, N\}$ endlich, können wir die Anfangsverteilung

$$\boldsymbol{\mu} = (\mathbb{P}(X_0 = i))_{i \in E}$$

als Vektor betrachten. Weiter können wir

$$\begin{aligned} \mathbb{P}(X_n = j) &= \sum_{i_0, \dots, i_{n-1}=0}^N \mathbb{P}(X_0 = i_0, \dots, X_{n-1} = i_{n-1}, X_n = j) \\ &= \sum_{i_0, \dots, i_{n-1}=0}^N p_{i_0, i_1} \dots p_{i_{n-2}, i_{n-1}} p_{i_{n-1}, j} = (\boldsymbol{\mu}^\top \mathbf{P}^n)_j, \end{aligned}$$

wo $\mathbf{P}$ die Übergangsmatrix ist, schreiben. $\triangle$

Sei nun $f : E := \{1, \dots, N\} \rightarrow \mathbb{R}$ eine Funktion. Wir können f als Vektor $\mathbf{f} = (f(i))_{i=1}^N$ betrachten. Der *Erwartungswert* von $f \circ X_n$ ist dann gegeben durch

$$\mathbb{E}[f \circ X_n] = \sum_{j \in E} f(j) \mathbb{P}(X_n = j) = \boldsymbol{\mu}^\top \mathbf{P}^n \mathbf{f}.$$

Beispiel 2.12 (Gambler's Ruin). In jeder Runde eines Spieles gewinnt man mit Wahrscheinlichkeit 0,4 einen Dollar und verliert mit Wahrscheinlichkeit 0,6 einen Dollar. Definiere X_0 als die Anzahl Dollar am Anfang und X_i als die Anzahl Dollar nach der i -ten Runde. Das Spiel hört auf, falls entweder $X_k = 0$ (Ruin) oder $X_k = n$.

Dann ist $(X_k)_{k \in \mathbb{N}_0}$ eine Markov-Kette mit Zustandsraum $E = \{0, \dots, N\}$ mit $\mu = \delta_i$

für ein $i \in E$ fixiert. Dann ist die Übergangsmatrix

$$\mathbf{P} = \begin{bmatrix} 1 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0.6 & 0 & 0.4 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0.6 & 0 & 0.4 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0.6 & 0 & 0.4 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0.6 & 0 & 0.4 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0.6 & 0 & 0.4 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0.6 & 0 & 0.4 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & 0.6 & 0 & 0.4 \\ 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 1 \end{bmatrix}.$$

Daraus berechnet man z.B. für $\mathbf{f} = (0, \dots, 8)$ und $\boldsymbol{\mu} = \boldsymbol{\delta}_4 \in \mathbb{R}^9$

$$\mathbb{E}[f \circ X_{10}] = \boldsymbol{\delta}_4^\top \mathbf{P}^{10} \mathbf{f} \approx 2.35449$$

und

$$\mathbb{P}(X_{10} = 0) = (\boldsymbol{\mu}^\top \mathbf{P}^{10})_0 \approx 0.444522.$$

△

2.2. Existenz und Simulation von Markov-Ketten

Sei E endlich, $\mu \in \mathcal{M}(E)$ eine Startverteilung und p eine Übergangswahrscheinlichkeit auf E . Existiert nun eine Markov-Kette mit Startverteilung μ und Übergangswahrscheinlichkeit p ?

Im Folgenden nehmen wir an, dass ein Wahrscheinlichkeitsraum $(\Omega, \mathcal{F}, \mathbb{P})$ mit einer Folge $U_0, U_1, \dots$ von unabhängigen $[0, 1]$ -verteilten Zufallsvariablen existiert (dies ist überhaupt nicht trivial).

Satz 2.13. Für jede höchstens abzählbare Menge E , $\mu \in \mathcal{M}(E)$, p eine Übergangswahrscheinlichkeit auf E gibt es $(\Omega, \mathcal{F}, \mathbb{P})$ und Zufallsvariablen $X_0, X_1, \dots$ sodass $(X_i)_{i \in \mathbb{N}_0}$ eine Markov-Kette $(\text{MC}(\mu, p))$ ist.

Beweis. Sei ohne Beschränkung der Allgemeinheit $E \subseteq \mathbb{N}$.

Schritt 1: Konstruktion von X_0 : Seien $U_0, U_1, \dots$ uniform auf $[0, 1]$ verteilt. Setze

$$S_0 = 0, \quad S_n := \sum_{i=1}^n \mu(i)$$

und definiere

$$X_0 := i \quad \text{falls } U_0(\omega) \in [S_{i-1}, S_i).$$

Dann ist

$$\mathbb{P}(X_0 = i) = \mathbb{P}(U_0 \in [S_{i-1}, S_i)) = \mu(i).$$

Schritt 2: Konstruktion von X_i , $i \geq 1$: Setze analog zu Schritt 1

$$S_{i,0} := 0, \quad S_{i,j} := \sum_{k=0}^j p_{i,k}$$

und

$$\Phi : E \times [0, 1] \rightarrow E, \quad \Phi(i, u) = j \quad \text{falls } u \in [S_{i,j-1}, S_{i,j}).$$

Rekursiv können wir nun

$$X_n := \Phi(X_{n-1}, U_n)$$

definieren. Damit haben wir

$$\begin{aligned} \mathbb{P}(X_0 = i_0, \dots, X_n = i_n) &= \mathbb{P}(X_0 = i_0, \Phi(i_0, U_1) = i_1, \dots, \Phi(i_{n-1}, U_n) = i_n) \\ &\stackrel{\text{Unabh.}}{=} \underbrace{\mathbb{P}(X_0 = i_0)}_{=\mu(i_0)} \prod_{j=1}^n \underbrace{\mathbb{P}(\Phi(i_{j-1}, U_j) = i_j)}_{=p_{i_{j-1}, i_j}}, \end{aligned}$$

was den Satz zeigt. $\square$

Notation 2.14. Sei $\mu \in \mathcal{M}(E)$ eine Verteilung auf dem Zustandsraum. Wir werden $\mathbb{P}_\mu$ als Verteilung von $\text{MC}(\mu, p)$ bezeichnen d.h.

$$\mathbb{P}_\mu(X_0 = x_0, \dots, X_n = x_n) = \mu(x_0)p_{x_0, x_1} \cdots p_{x_{n-1}, x_n}.$$

Wenn $\mu = \delta_x$, werden wir $\mathbb{P}_x := \mathbb{P}_{\delta_x}$ schreiben. Nach Theorem 2.10 ist $(X_n)_{n \in \mathbb{N}_0}$ eine Markov-Kette unter $\mathbb{P}_\mu$.

Satz 2.15 (Schwache Markov-Eigenschaft). Sei $X = (X_n)_{n \in \mathbb{N}_0}$ eine $\text{MC}(\mu, p)$. Dann gegeben $X_n = x$, ist $(X_{m+n})_{m \in \mathbb{N}_0}$ eine $\text{MC}(\delta_x, p)$ und unabhängig von $X_0, \dots, X_{n-1}$.

Bemerkung 2.16. Seien A, B, C Ereignisse mit $\mathbb{P}(C) > 0$. Dann ist A unabhängig von B gegeben C , genau dann wenn A, B unabhängig sind unter $\mathbb{P}(\cdot | C)$ d.h.

$$\mathbb{P}(A \cap B | C) = \mathbb{P}(A | C)\mathbb{P}(B | C).$$

Sind X, Y Zufallsvariablen, dann ist X unabhängig von Y gegeben C genau dann wenn

$$\mathbb{P}(X = x, Y = y | C) = \mathbb{P}(X = x | C)\mathbb{P}(Y = y | C)$$

für alle $x, y \in E$ (diese Definition gilt nur auf höchstens abzählbaren Zustandsräumen!).
 $\triangle$

Beweis von Theorem 2.15. Wir zeigen: Für jedes Ereignis A determiniert von $X_0, \dots, X_{n-1}$ gilt

$$\mathbb{P}\left(\bigcap_{i=0}^m \{X_{n+i} = x_{n+i}\} \cap A \mid X_n = x\right) = \mathbb{P}(A \mid X_n = x) \cdot \delta_{x_0}(x)p_{x_0, x_1} \cdots p_{x_{m-1}, x_m}. \quad (2.4)$$

Schritt 1: Sei vorerst $A := \bigcap_{i=0}^{n-1} \{X_i = x_i\}$. Dann ist aber

$$\begin{aligned} \mathbb{P}\left(\bigcap_{i=0}^m \{X_{n+i} = x_{n+i}\} \cap A \mid X_n = x\right) &= \frac{\mathbb{P}\left(\bigcap_{i=1}^{n+m} \{X_i = x_i\}\right) \cdot \delta_{x_n}(x)}{\mathbb{P}(X_n = x)} \\ &= \delta_{x_n}(x)\mu(x_0) \frac{p_{x_0, x_1} \cdots p_{x_{n+m-1}, x_{n+m}}}{\mathbb{P}(X_n = x)} \\ &= \frac{\mathbb{P}(A \cap \{X_n = x\})}{\mathbb{P}(X_n = x)} \delta_{x_n}(x) \prod_{i=n}^{n+m-1} p_{i, i+1} \end{aligned}$$

für beliebige $x_n, \dots, x_{n+m} \in E$.

Schritt 2: Wir bemerken, dass jedes Ereignis A , welches nur von $X_0, \dots, X_{n-1}$ abhängt, sich als folgende disjunkte Vereinigung schreiben lässt:

$$A = \bigcup_{k=1}^{+\infty} A_k, \quad A_k \text{ wie in Schritt 1.}$$

Daraus folgt

$$\begin{aligned} \mathbb{P} \left(\bigcap_{i=n}^{n+m} \{X_i = x_i\} \cap A \mid X_n = x \right) &= \mathbb{P} \left(\bigcup_{k=1}^{+\infty} \left(A_k \cap \bigcap_{i=n}^{n+m} \{X_i = x_i\} \right) \mid X_n = x \right) \\ &\stackrel{A_k \text{ disjunkt}}{=} \sum_{k \geq 1} \mathbb{P} \left(A_k \cap \bigcap_{i=n}^{n+m} \{X_i = x_i\} \mid X_n = x \right) \end{aligned}$$

womit wir mit Schritt 1 die Behauptung (2.4) folgern können. $\square$

Folgerung 2.17. Seien $\mu \in \mathcal{M}(E)$, $x \in E$, $n \in \mathbb{N}_0$, p eine Übergangswahrscheinlichkeit und $f : E^{\mathbb{N}} \rightarrow \mathbb{R}$ eine beschränkte Funktion. $E^{\mathbb{N}}$ ist die Menge aller Folgen in E . Dann gilt für die homogene Markov-Kette $X = (X_n)_{n \in \mathbb{N}_0}$ (X ist eine MC(μ, p))

$$\mathbb{E}_\mu[f((X_{n+m})_{m=0}^{+\infty}) \mid X_n = x] = \mathbb{E}_x[f(X)]. \quad (2.5)$$

Notation 2.18. Wir werden für $k \in \mathbb{N}$

$$p_{x,y}^{(k)} = \mathbb{P}_x(X_k = y), \quad p_{x,y}^{(1)} = \mathbb{P}_x(X_1 = y) = p_{x,y}$$

schreiben.

Satz 2.19. Für alle $m, n \in \mathbb{N}_0$ und $x, y \in E$, mit E höchstens abzählbar gilt die *Chapmann-Kolmogorov-Gleichung*:

$$p_{x,y}^{(n+m)} = \sum_{z \in E} p_{x,z}^{(n)} p_{z,y}^{(m)}.$$

Beweis. Die Behauptung folgt aus

$$\begin{aligned} p_{x,y}^{(n+m)} &= \mathbb{P}_x(X_{m+n} = y) = \sum_{z \in E} \mathbb{P}(X_{m+n} = y, X_m = z) \\ &= \sum_z \underbrace{\mathbb{P}(X_{m+n} = y \mid X_m = z)}_{=\mathbb{P}_z(X_n = y) \text{ (schwache Markov Eigenschaft)}} \mathbb{P}(X_m = z) \\ &= \sum_z p_{x,z}^{(n)} p_{z,y}^{(m)}. \end{aligned} \quad \square$$

Bemerkung 2.20. Für E endlich entspricht dies der Matrixmultiplikation $\mathbf{P}^m \mathbf{P}^n = \mathbf{P}^{(m+n)}$ für $\mathbf{P} \in \mathbb{R}^{N \times N}$ ($|E| = N$). Dies ist insbesondere wichtig für die Übergangsmatrizen.

$\triangle$

2.3. Invariante Verteilungen von Markov-Ketten

Frage 2.21. Sei μ_n die Verteilung von X_n d.h. dem n -ten Schritt der homogenen Markov-Kette $(X_i)_{i \in \mathbb{N}_0}$, also $\mu_n^\top = \mu^\top \mathbf{P}$ im vektoriellen Fall. Gibt es μ sodass

$$\mu = \mu_1 = \mu_2 = \cdots = \mu_n = \cdots?$$

Dies wird insbesondere für das Langzeitverhalten interessant. Die Frage ist also: Existiert der Grenzwert

$$\lim_{n \rightarrow +\infty} \mathbb{P}_\mu(X_n = x)$$

und was kommt heraus?

Definition 2.22. Sei $(X_n)_{n \in \mathbb{N}_0}$ eine homogene Markov-Kette mit Übergangswahrscheinlichkeit $p = (p_{x,y})_{x,y \in E}$. Eine Verteilung $\pi \in \mathcal{M}(E)$ heisst **invariant** oder **stationär** falls

$$\pi(y) = \sum_{x \in E} \pi(x) p_{x,y}.$$

Lemma 2.23. Sei π invariant für p . Dann gilt

$$\mathbb{P}_\pi(X_n = y) = \pi(y)$$

für alle $m, y \in E$.

Beweis. Wir zeigen die Behauptung durch Induktion. Für $m = 0$ ist die Behauptung offensichtlich. Für den Induktionsschritt $n - 1 \mapsto n$ nehmen wir an, dass die Behauptung für $n - 1$ gilt. Dann folgt

$$\begin{aligned} \mathbb{P}_\pi(X_n = y) &= \sum_{x \in E} \mathbb{P}_\pi(X_n = y, X_{n-1} = x) \\ &= \sum_{x \in E} \mathbb{P}_\pi(X_n = y \mid X_{n-1} = x) \mathbb{P}_\pi(X_{n-1} = x) \\ &\stackrel{\text{Ind}}{=} \sum_{x \in E} \pi(y) p_{x,y} \stackrel{\text{Definition 2.22}}{=} \pi(y). \end{aligned} \quad \square$$

Bemerkung 2.24. Ist E endlich d.h. $E = \{1, \dots, N\}$, dann entspricht dies wieder der Vektor-Matrix Multiplikation

$$\pi^\top = \pi^\top \mathbf{P}, \quad (2.6)$$

das heisst, $\pi^\top$ ist ein Linkseigenvektor von $\mathbf{P}$ zum Eigenwert 1. Die 1 ist *immer* ein Eigenwert von $\mathbf{P}$, denn

$$\mathbf{P} \cdot \begin{bmatrix} 1 \\ \vdots \\ 1 \end{bmatrix} = \begin{bmatrix} 1 \\ \vdots \\ 1 \end{bmatrix},$$

das heisst, $(1, \dots, 1)$ ist immer ein rechter Eigenvektor. Daraus folgt, dass es auch einen linken Eigenvektor für $\mathbf{P}$ gibt. Allerdings ist solch ein Eigenvektor nicht immer eine Verteilung. $\triangle$

Beispiel 2.25. Betrachte eine Markov-Kette mit Zustandsraum $E = \{1, 2\}$. Seien $p_{1,2} = \alpha, p_{2,1} = \beta$, dann ist die gesamte Markov-Kette durch diese Wahrscheinlichkeiten gegeben. Dies entspricht der Übergangsmatrix

$$\mathbf{P} = \begin{bmatrix} 1 - \alpha & \alpha \\ \beta & 1 - \beta \end{bmatrix}.$$

Eine Invariante Verteilung wäre dann

$$\boldsymbol{\pi} = \frac{1}{\alpha + \beta} \cdot \begin{bmatrix} \beta \\ \alpha \end{bmatrix}.$$

Sind $1 > \alpha, \beta > 0$, ist $\boldsymbol{\pi}$ die *einzig*e invariante Verteilung. Sind $\alpha, \beta = 0$, ist jede Startverteilung invariant. $\triangle$

Beispiel 2.26. Betrachte $(\xi_i)_{i \in \mathbb{N}}$ wie in Example 1.5. Dann ist die Übergangswahrscheinlichkeit der Markov Kette $X = (X_i)_{i \in \mathbb{N}}$ mit $X_n = \xi_1 + \dots + \xi_n$ gegeben durch

$$p_{x,y} = \begin{cases} \frac{1}{2} & x = y \pm 1 \\ 0 & \text{sonst} \end{cases}.$$

Dann ist π invariant falls

$$\pi(x) = \frac{1}{2}\pi(x+1) + \frac{1}{2}\pi(x-1)$$

für alle $x \in E$. Dies impliziert

$$\pi(x) = ax + b \quad a, b \in \mathbb{R}.$$

π ist also keine Verteilung wenn $a \neq 0$. Ist aber $a = 0$ ist $\pi \equiv b$, was ein Widerspruch zu

$$+\infty = \sum_{x \in \mathbb{Z}} b = \sum_{x \in \mathbb{Z}} \pi(x) = 1$$

ist. Damit kann π nicht invariant sein. $\triangle$

Definition 2.27. Eine Verteilung $\pi \in \mathcal{M}(E)$ heisst **reversibel** für die Übergangswahrscheinlichkeit $p = (p_{x,y})_{x,y \in E}$, falls

$$\pi(x)p_{x,y} = \pi(y)p_{y,x} \quad \text{für alle } x, y \in E \quad (2.7)$$

Wir nennen (2.7) **detailliertes Gleichgewicht**.

Bemerkung 2.28. (2.7) ist äquivalent zu

$$\mathbb{P}_\pi(X_0 = x, X_1 = y) = \mathbb{P}_\pi(X_0 = y, X_1 = x).$$

Ist π reversibel, gilt für alle $x_0, \dots, x_n \in E$,

$$\mathbb{P}_\pi(X_0 = x_0, \dots, X_n = x_n) = \mathbb{P}_\pi(X_n = x_0, \dots, X_0 = x_n).$$

das heisst, für einen Pfad mit einer gewissen Wahrscheinlichkeit nehmen, haben wir die gleiche Wahrscheinlichkeit, den Pfad rückwärts zu gehen. Dies lässt sich durch Induktion zeigen. $\triangle$

Bemerkung 2.29. Besitzt p eine reversible Verteilung, dann heisst p , beziehungsweise die Markov-Kette $(X_n)_{n \in \mathbb{N}_0}$ mit Verteilung p , *reversibel*. Reversible Verteilung existieren nicht immer. $\triangle$

Satz 2.30. Sei π reversibel für $p = (p_{x,y})_{x,y \in E}$. Dann ist π invariant für p .

Beweis. Dies folgt aus

$$\sum_{x \in E} \pi(x) p_{x,y} \stackrel{(2.7)}{=} \sum_{x \in E} \pi(y) p_{x,y} = \pi(y) \underbrace{\sum_{x \in E} p_{x,y}}_{=1} = \pi(y). \quad \square$$

Beispiel 2.31 (Symmetrische Irrfahrt auf $\mathbb{Z}/n\mathbb{Z}$). Betrachte folgende Irrfahrt. Dann ist die Übergangsmatrix

$$p_{x,y} = \begin{cases} \frac{1}{2} & \text{wenn } x = y \pm 1 \\ 0 & \text{sonst} \end{cases}.$$

für alle $x, y \in \mathbb{Z}/n\mathbb{Z}$. Nun gilt $p_{x,x+1} = p_{x+1,x}$ (wir schreiben $x+1$ für $[x+1]$), das heisst, $\pi(x)$ ist konstant über E . Dann folgt

$$\pi(x) = \frac{1}{N},$$

woraus folgt, dass π stationär ist. $\triangle$

Beispiel 2.32 (Ehrenfest-Modell). Wir unterteilen eine Box mit N Teilchen in zwei Hälften welche wir mit A, B bezeichnen (siehe Figure 2.2). In jedem Schritt wähle ein Teilchen durch ein Laplace Modell, welches die Hälfte wechselt. Definiere nun

$X_n = \text{Anzahl der Teilchen in } A \text{ nach dem } n\text{-ten Schritt.}$

Dann sind die Übergangswahrscheinlichkeiten durch

$$p_{x,y} = \begin{cases} 0 & y \notin \{x \pm 1\} \\ \frac{x}{N} & y = x - 1 \\ 1 - \frac{x}{N} & y = x + 1 \end{cases}$$

gegeben. Dann gilt

$$\pi(x+1) = \pi(x) \frac{N-x}{x+1},$$

womit induktiv folgt, dass

$$\pi(x) = \pi(0) \prod_{i=0}^{x-1} \frac{N-i}{x+1} = \pi(0) \cdot \binom{N}{x}$$

und daraus

$$1 = \sum_{x \in E} \pi(x) = \pi(0) \sum_{x=0}^N \binom{N}{x} = \pi(0) 2^N,$$

was impliziert, dass $\pi \sim \text{Bin}(N, \frac{1}{2})$ reversible und damit invariant ist. Also ist der stationäre Zustand, dass in beiden Räumen etwa gleichviele Moleküle sind. Dies gilt insbesondere für grosse N . $\triangle$




Abbildung 2.2.: Ehrenfest Modell der Diffusion aus Example 2.32. Mit Wahrscheinlichkeit $p_{x,y}$ verändert sich die Anzahl an Molekülen in Box A von x zu y .

Satz 2.33 (Invarianz und Konvergenz). Nehme an, dass für $(X_n)_{n \in \mathbb{N}_0}$ eine $\text{MC}(\mu, p)$ mit $p = (p_{x,y})_{x,y \in E}$,

$$\lim_{n \rightarrow +\infty} \mathbb{P}_\mu(X_n = x) =: \pi(x)$$

existiert und dass $\sum_{x \in E} \pi(x) = 1$ (dies ist eine starke Annahme!). Dann ist π invariant.

Beweis. Für alle $y \in E$,

$$\begin{aligned} \pi(y) &= \lim_{n \rightarrow +\infty} \mathbb{P}_\mu(X_n = y) = \lim_{n \rightarrow +\infty} \sum_{x \in E} \mathbb{P}_\mu(X_{n-1} = x, X_n = y) \\ &= \lim_{n \rightarrow +\infty} \sum_{x \in E} \mathbb{P}_\mu(X_{n-1} = x) p_{x,y} = \sum_{x \in E} p_{x,y} \underbrace{\lim_{n \rightarrow +\infty} \mathbb{P}_\mu(X_{n-1} = x)}_{=\pi(x)} \\ &= \sum_{x \in E} p_{x,y} \pi(x). \end{aligned}$$

Somit ist π invariant. □

2.4. Kommunikationsklassen

Definition 2.34. Seien $x, y \in E$. Wir schreiben $x \rightarrow y$ falls $p_{x,y}^{(n)} > 0$ für ein $n \in \mathbb{N}_0$ d.h. y ist **erreichbar** von x . Weiter schreiben wir $x \leftrightarrow y$ falls $x \rightarrow y$ und $y \rightarrow x$ gilt und sagen, dass x, y **kommunizieren**.

Bemerkung 2.35. Wir bemerken, dass $x \rightarrow y$ äquivalent ist zu

$$\mathbb{P}_x(\exists n \in \mathbb{N}_0 : X_n = y) = \mathbb{P}\left(\bigcup_{n \in \mathbb{N}_0} \{X_n = y\}\right) > 0.$$

Weiter können wir aus

$$0 < p_{x,y}^{(n)} = \sum_{\substack{z_i \in E \\ i=1, \dots, n-1}} p_{x,z_1} p_{z_1,z_2} \cdots p_{z_{n-2},z_{n-1}} p_{z_{n-1},y}$$

die Existenz von $z_1, \dots, z_{n-1} \in E$ schliessen, sodass

$$p_{x,z_1}, p_{z_1,z_2}, \dots, p_{z_{n-2},z_{n-1}}, p_{z_{n-1},y} > 0,$$

dies ist ebenfalls eine Äquivalenz.

Betrachten wir die Markov-Kette als stochastischen gerichteten Graphen, entspricht $x \rightarrow y$ der Existenz eines orientierten Pfades von x nach y beschreibt, siehe ??.

△

Satz 2.36. Die Relation „ $\leftrightarrow$ “ wie in Definition 2.34 ist eine Äquivalenzrelation auf E .

Beweis. Reflexivität: Es gilt $x \leftrightarrow x$ für alle $x \in E$, weil $p_{x,x}^{(0)} = 1$.

Symmetrie: Dies folgt direkt aus der Definition.

Transitivität: Seien $x, y, z \in E$ sodass $(x \leftrightarrow y)$ und $(y \leftrightarrow z)$. Wir schliessen nun aus einem ähnlichen Argument wie in Remark 2.35, dass $x \leftrightarrow z$. □

Definition 2.37. Die Äquivalenzklassen der Relation „ $\leftrightarrow$ “ heissen **Kommunikationsklassen**. Besteht E aus nur einer Kommunikationsklasse besteht, nennen wir p , beziehungsweise die Markovkette X , **irreduzibel**.

Beispiel 2.38 (Gambler's ruin). Betrachten wir Example 2.12, haben wir dort die Äquivalenzklassen

$$C_1 = \{0\}, \quad C_2 = \{N\}, \quad C_3 = \{1, \dots, N-1\}.$$

△

Definition 2.39. Eine Kommunikationsklasse C heisst **abgeschlossen**, falls für alle $x, y \in E$ die Implikation

$$x \in C \text{ und } x \rightarrow y \quad \Rightarrow \quad y \in C$$

gilt.

Bemerkung 2.40 (Interpretation). Es gilt

$$\mathbb{P}_x(\forall n \in \mathbb{N}_0, X_n \in C) = 1 \quad \text{für alle } x \in C$$

genau dann wenn C abgeschlossen ist. Der Beweis davon wird dem Leser als Übung überlassen. *Tipp:* Zeige beide Richtungen durch Kontraposition und schreibe eine Reihe an Äquivalenzen.

△

Beispiel 2.41. Im Example 2.38 sind C_1 und C_3 abgeschlossen.

△

3. Intermezzo: Bedingte Erwartung

Die Ereignisse $\{X_0 = x_0, \dots, X_n = x_n\}$ für $x_i \in E$ für $i = 0, \dots, n$ sind disjunkt und vereinigen zu

$$\bigcup_{\substack{x_i \in E \\ i=0, \dots, n}} \{X_i = x_i\} = \Omega.$$

Definition 3.1. Eine Sammlung an Teilmengen $\mathcal{B} = \{B_i \mid i \in I\}$, wo I eine höchstens abzählbare Indemenge ist, sodass $B_i \in \mathcal{F}$ paarweise disjunkt sind und $\bigcup_{B \in \mathcal{B}} B = \Omega$ heisst (messbare) **Partition**. Wir werden die **kanonische Partition** der Markov-Kette X als

$$\mathcal{B}_n = \{\{\omega \in \Omega : X_i(\omega) = x_i, \forall i = 0, \dots, n\} \mid x_0, \dots, x_n \in E\}$$

bezeichnen.

Definition 3.2. Sei $\mathcal{B}$ eine Partition und $A \in \mathcal{F}$. Wir definieren die Zufallsvariable

$$\mathbb{P}(A \mid \mathcal{B})(\omega) := \begin{cases} \mathbb{P}(A \mid B) & \text{falls } \omega \in B \in \mathcal{B}, \mathbb{P}(B) > 0 \\ 0 & \text{sonst} \end{cases}.$$

Bemerkung 3.3. • Die Funktion $\omega \mapsto \mathbb{P}(A \mid \mathcal{B})(\omega)$ ist konstant auf jeder Menge $B \in \mathcal{B}$. Weiter gilt, ist $\omega \in A \subseteq B_n \in \mathcal{B}$, dann ist $\mathbb{P}(A \mid B)(\omega) = 1$.

- Es gilt für eine diskrete Zufallsvariable X ,

$$\mathbb{E}[\mathbb{P}(X \mid \mathcal{B})] = \sum_{B \in \mathcal{B}} \mathbb{P}(A \mid B) \mathbb{P}(B) = \sum_{\substack{B \in \mathcal{B} \\ \mathbb{P}(B) > 0}} \mathbb{P}(A \mid B) \mathbb{P}(B) \stackrel{\text{totale W-keit}}{=} \mathbb{P}(A)$$

△

Definition 3.4. Sei $X : \Omega \rightarrow \mathbb{R}$ eine diskrete Zufallsvariable. Wenn $B \in \mathcal{F}$ sodass $\mathbb{P}(B) > 0$ setzen wir

$$\underbrace{\mathbb{E}[X \mid B]}_{\text{Erwartungswert von } X \text{ unter } \mathbb{P}(\cdot \mid B)} = \frac{\mathbb{E}[X \mathbf{1}_B]}{\mathbb{P}(B)}. \quad (3.1)$$

Ist $\mathcal{B}$ eine Partition, definieren wir die Zufallsvariable

$$\mathbb{E}[X \mid \mathcal{B}](\omega) = \begin{cases} \mathbb{E}[X \mid B] & \text{falls } \omega \in B \in \mathcal{B}, \mathbb{P}(B) > 0 \\ 0 & \text{sonst} \end{cases},$$

welche wir **bedingte Erwartung von X bezüglich B** nennen.

Bemerkung 3.5. • $\mathbb{E}[X \mid \mathcal{B}]$ ist konstant auf allen $B \in \mathcal{B}$.

- Es gilt

$$\begin{aligned}\mathbb{E}[X] &= \mathbb{E}\left[X \sum_{B \in \mathcal{B}} \mathbf{1}_B\right] = \sum_{B \in \mathcal{B}} \mathbb{E}[X \mathbf{1}_B] \\ &\stackrel{(3.1)}{=} \sum_{B \in \mathcal{B}} \mathbb{E}[X \mid B] \mathbb{P}(B) = \mathbb{E}[\mathbb{E}[X \mid \mathcal{B}]].\end{aligned}$$

analog zu oben.

△

Definition 3.6. Sei $Y : \Omega \rightarrow E$ eine Zufallsvariable. Y induziert eine Partition

$$\mathcal{B}_Y = \{\{\omega \in \Omega : Y(\omega) = y\} \mid y \in E\} = \{Y^{-1}[\{y\}] : y \in E\}$$

Wir schreiben dann

$$\mathbb{E}[X \mid Y] := \mathbb{E}[X \mid \mathcal{B}_Y], \quad \mathbb{P}(A \mid Y) := \mathbb{P}(A \mid \mathcal{B}_Y).$$

Anwendungen der obigen Definitionen. Die Einschnitt-Markov-Eigenschaft lässt sich nun mit der obigen Notation äquivalent schreiben als: für alle $n \in \mathbb{N}_0, x \in E$ gilt

$$\mathbb{P}(X_{n+1} = x \mid \mathcal{B}_n) = \mathbb{P}(X_{n+1} = x \mid X_n), \quad (3.2)$$

wobei dies *keine* Gleichheit zwischen zwei Zahlen, sondern zwischen zwei Zufallsvariablen ist.

Übung 3.7. Zeigen Sie, dass (3.2) äquivalent zur Markov-Eigenschaft ist.

Die schwache Markov-Eigenschaft (2.5) schreibt sich dann als

$$\mathbb{E}_\mu[f(X_n, X_{n+1}, \dots) \mid \mathcal{B}_n](\omega) = \mathbb{E}_{X_n(\omega)}[f(X_0, X_1, \dots)].$$

Wir können $\mathcal{B}_n$ als Information bis zum Zeitpunkt n auffassen.

Bemerkung 3.8. Die Partition $\mathcal{B}$ aus Definition 3.4 entspricht einer σ -Algebra, welche wir mit $\mathcal{F}_\mathcal{B}$ bezeichnen werden:

$$\mathcal{F}_\mathcal{B} := \left\{ \bigcup_{i \in I} B_i \mid I \subseteq \mathbb{N} \right\}.$$

In Definition 3.4 schreibt man normalerweise auch $\mathbb{E}[A \mid \mathcal{F}_\mathcal{B}]$ (was die übliche bedingte Notation bezeichnet). △

Die σ -Algebra zur *kanonischen Partition* werden wir mit $\mathcal{F}_n := \mathcal{F}_{\mathcal{B}_n} \subseteq \mathcal{F}$ bezeichnen. Wir fragen nun, ob für ein eingetretenes ω , ob $\omega \in A$ gilt oder $\omega \notin A$ für $A \in \mathcal{F}_n$. Das Eintreten von A hängt dann nur von den Werten der Zufallsvariablen $X_0, \dots, X_n$ ab. Die σ -Algebra $\mathcal{F}_n$ entspricht der Information, die bis zum Zeitpunkt n verfügbar ist.

4. Markov-Ketten: Langzeitverhalten

4.1. Starke Markov-Eigenschaft

Beispiel 4.1. Betrachten wir eine einfache Irrfahrt auf $\mathbb{Z}$ und betrachten die Zeit des ersten Eintretens der Zahl 3. Starten wir unsere Irrfahrt ab diesem zufälligen Punkt, ist der Prozess immer noch eine Markov-Kette?

$$H_3(\omega) = \inf\{n \in \mathbb{N}_0 \mid X_n(\omega) = 3\} = \text{Erste Zeit wenn 3 erreicht wird}$$

$$L_3(\omega) = \sup\{n \in \mathbb{N}_0 \mid X_n(\omega) = 3\} = \text{Letzte Zeit wenn 3 erreicht wird,}$$

wobei wir $\inf \emptyset = +\infty$ definieren.

Betrachten wir H_3 als zufälligen Punkt, wird die Antwort intuitiv ja sein, bei L_3 intuitiv nein, da in L_3 schon viel informationen über die Zukunft verpackt ist (es darf nie wieder eine 3 kommen, L_3 ist keine Stoppzeit). $\triangle$

Definition 4.2. Eine $\mathbb{N}_0 \cup \{+\infty\}$ -wertige Zufallsvariable T heisst **Stoppzeit**, falls für alle $n \in \mathbb{N}_0$ das Eintreten von $\{T = n\}$ nur mithilfe der Zufallsvariablen $X_0, \dots, X_n$ entscheidbar ist d.h. $\{T = n\} \in \mathcal{F}_n$.

Beispiel 4.3. Sei $A \subseteq E$ und

$$H_A := \begin{cases} \inf\{n \in \mathbb{N}_0 : X_n(\omega) \in A\} & \{n \in \mathbb{N}_0 : X_n(\omega) \in A\} \neq \emptyset \\ +\infty & \text{sonst} \end{cases}.$$

Wir behaupten nun, dass H_A eine Stoppzeit ist. Wir schreiben dazu

$$\{H_A = n\} = \bigcup_{\substack{x_n \in A \\ x_0, \dots, x_{n-1} \in A^c}} \underbrace{\{X_0 = x_0, \dots, X_n = x_n\}}_{\in \mathcal{B}_n} \in \mathcal{F}_n$$

und erhalten damit das Resultat, denn eine Vereinigung von Mengen in $\mathcal{B}_n$ ist in $\mathcal{F}_n$. $\triangle$

Satz 4.4 (Starke Markov-Eigenschaft). Sei T eine Stoppzeit. Dann, gegeben $T < +\infty$, $X_T = x \in E$, ist $(X_{T+n})_{n \in \mathbb{N}_0}$ eine Markovkette mit Startverteilung δ_x und Übergangswahrscheinlichkeiten $p = (p_{x,y})_{x,y \in E}$ und unabhängig von $X_0, \dots, X_T$.

Beweis. Sei B ein Ereignis, welches nur von $X_0, \dots, X_T$ determiniert ist. Bemerke zuerst,

dass $B \cap \{T = k\} \in \mathcal{F}_k$. Damit folgt

$$\begin{aligned}
 & \mathbb{P}_\mu(B \cap \{X_T = x_0, \dots, X_{T+m} = x_m\} \mid T < +\infty, X_T = x) \\
 &= \frac{\mathbb{P}_\mu(B \cap \{X_T = x_0, \dots, X_{T+m} = x_m\} \cap \{T < +\infty\} \cap \{X_T = x\})}{\mathbb{P}_\mu(T < +\infty, X_T = x)} \\
 &= \sum_{k=0}^{+\infty} \frac{\mathbb{P}_\mu(B \cap \{X_k = x_0, \dots, X_{k+m} = x_m\} \cap \{T = k\} \cap \{X_k = x\})}{\mathbb{P}_\mu(T < +\infty, X_T = x)} \\
 &\stackrel{\text{Theorem 2.15}}{=} \sum_{k=0}^{+\infty} \frac{\mathbb{P}_\mu(B \cap \{T = k\}) \mathbb{P}_x(\bigcap_{i=0}^m \{X_{i+k} = x_i\})}{\mathbb{P}_\mu(T < +\infty, X_T = x)} \\
 &= \mathbb{P}_\mu(B \mid T < +\infty, X_T = x) \cdot \mathbb{P}_x(X_0 = x_0, \dots, X_n = x_n),
 \end{aligned}$$

was den Satz zeigt. $\square$

Definition 4.5. Sei N eine $\mathbb{N}_0 \cup \{+\infty\}$ -wertige Zufallsvariable. Wir definieren die **erzeugende Funktion** von N durch

$$\varphi_N(s) := \sum_{i=0}^{+\infty} s^i \mathbb{P}(N = i) \quad \text{für } |s| < 1.$$

Bemerkung 4.6. Es gilt

$$\varphi_N(s) = \sum_{i=0}^{+\infty} s^i \mathbb{P}(N = i) = \mathbb{E}[s^N] \quad \text{für } |s| < 1.$$

Weiter wird die Zufallsvariable N eindeutig durch die erzeugende Funktion definiert (für $s \in [0, 1)$). $\triangle$

Lemma 4.7. Seien M, N zwei unabhängige $\mathbb{N}_0 \cup \{+\infty\}$ Zufallsvariable. Dann ist $\varphi_{M+N} = \varphi_M \varphi_N$.

Beweis. Dies folgt aus der einfachen Berechnung:

$$\varphi_{N+M}(s) = \mathbb{E}[s^N s^M] \stackrel{\text{unabh.}}{=} \mathbb{E}[s^N] \mathbb{E}[s^M] = \varphi_N(s) \varphi_M(s). \quad \square$$

Beispiel 4.8 (Assymetrische Irrfahrt auf $\mathbb{Z}$). Seien $(\xi_i)_{i \in \mathbb{N}_0}$ Zufallsvariablen mit

$$\mathbb{P}(\xi_i = 1) = p, \quad \mathbb{P}(\xi_i = -1) = q := 1 - p$$

Definiere $X_n := \xi_0 + \dots + \xi_n$. Wir fragen nun nach der Verteilung von H_0 , wenn $X_0 = 1$, wo $H_0 = \inf\{n \in \mathbb{N}_0 \mid X_n(\omega) = 0\}$. Dazu betrachten wir die erzeugende Funktion φ_{H_0} . Unter $\mathbb{P}_2$ (Wahrscheinlichkeit, dass wir von 2 starten) schreiben wir $H_0 = H_1 + \tilde{H}_0$, wo $\tilde{H}_0$ eine neue Zufallsvariable ist. Bedingt $H_1 < +\infty$, ist $\tilde{H}_0$ verteilt wie H_0 unter $\mathbb{P}_1$ und $\tilde{H}_0$ ist unabhängig von H_1 . Nun ist

$$\begin{aligned}
 \mathbb{E}_2[s^{H_0}] &= \mathbb{E}_2[s^{H_1 + \tilde{H}_0} \mathbf{1}_{H_1 < +\infty}] = \mathbb{E}_1[s^{H_1 + \tilde{H}_0} \mid H_1 < +\infty] \mathbb{P}_1(H_1 < +\infty) \\
 &= \mathbb{E}_2[s^{H_1} \mid H_1 < +\infty] \cdot \mathbb{E}_1[s^{H_0}] \cdot \mathbb{P}_1(H_1 < +\infty) = \varphi(s) \underbrace{\mathbb{E}_2[s^{H_1}]}_{=\mathbb{E}_1[s^{H_0}] = \varphi(s)} = \varphi(s)^2.
 \end{aligned}$$

Weiter gilt, da $H_0 \stackrel{d}{=} H_0 - 1$ unter $\mathbb{P}_2$ folgt

$$\begin{aligned}\varphi(s) &= \mathbb{E}_1[s^{H_0}] = \underbrace{\mathbb{E}_1[s^{H_0} \mathbb{1}_{X_1=0}]}_{=\mathbb{E}_1[s^{H_0} | X_1=0] \mathbb{P}_1(X_1=0)=sq} + \mathbb{E}_1[s^{H_0} \mathbb{1}_{X_1=2}] \\ &= sq + \mathbb{E}_1[s^{H_0} | X_1 = 2] \underbrace{\mathbb{P}_1(X_1 = 2)}_{=p} = sq + sp \mathbb{E}_2[s^{H_0}].\end{aligned}$$

Damit folgt

$$\varphi(s) = sq + sp \cdot \varphi(s)^2.$$

Dann ist

$$\varphi(s) = \frac{(1 - \sqrt{1 - 4pqs^2})}{2ps}$$

da $\varphi \leq 1$ ist. △

Lemma 4.9. Sei N eine $\mathbb{N}_0 \cup \{+\infty\}$ -wertige Zufallsvariable. Dann ist

$$\lim_{s \uparrow 1} \varphi_N(s) = \mathbb{P}(N < +\infty) \quad \text{und} \quad \lim_{s \uparrow 1} \varphi'_N(s) = \mathbb{E}[N]$$

solange der Erwartungswert existiert.

Beweis. Der einfache Beweis verbleibt dem Leser als Übung. □

Beispiel 4.10 (Fortsetzung von Example 4.8). Was ist $\mathbb{P}_1(H_0 < +\infty)$? Aus Lemma 4.9 folgt

$$\mathbb{P}_1(H_0 < +\infty) = \frac{1}{2p}(1 - |1 - 2p|) = \begin{cases} \frac{q}{p}, & p > \frac{1}{2} \\ 1 - \frac{q}{p}, & p \leq \frac{1}{2} \end{cases}.$$

Weiter stellt sich die Frage nach $\mathbb{P}_1(H_0 = k)$ für $k \in \mathbb{N}$. Dazu bemerken wir, dass φ seine eigene Taylorentwicklung ist und schreiben für $|s| < 1$

$$\begin{aligned}\varphi(s) &= \frac{1}{2ps} \left(1 - \sum_{k=0}^{+\infty} \binom{1/2}{k} (-4pqs^2)^k \right) \\ &= qs + pq^2s^3 + 2p^2q^3s^5 + \dots\end{aligned}$$

wobei für $a \in \mathbb{R}_{\geq k}$, $k \in \mathbb{N}$,

$$\binom{a}{k} := \frac{a(a-1) \dots (a-k+1)}{k!}.$$

Damit folgt, da nur ungerade Exponenten von s in der Reihe vorkommen, dass

$$\mathbb{P}_1(H_0 = 2k) = 0 \quad \text{für alle } k \in \mathbb{N}_0,$$

was sich auch ohne diese Berechnung überprüfen lässt. Weiter sind

$$\mathbb{P}_1(H_0 = 1) = q, \quad \mathbb{P}_1(H_0 = 3) = pq^2, \quad \mathbb{P}_1(H_0 = 5) = 2p^2q^3, \dots$$

Wir hätten die ganzen Wahrscheinlichkeiten auch ohne die Erzeugendenfunktion ausrechnen können, aber das Beispiel zeigt, wie man es damit geht. △

Definition 4.11 (Gestoppte σ -Algebra). Sei T eine Stoppzeit. Definiere die σ -Algebra

$$\mathcal{F}_T := \{A \in \mathcal{F} \mid \forall n \in \mathbb{N}_0, A \cap \{T = n\} \in \mathcal{F}_n\}$$

wo $\mathcal{F}_n = \sigma(X_0, \dots, X_n)$ wie oben. Wir nennen $\mathcal{F}_T$ **gestoppte σ -Algebra**. Diese σ -Algebra beschreibt die Information über X bis zur Zeit T .

Bemerkung 4.12. Diese σ -Algebra $\mathcal{F}_T$ entspricht *keiner* Partition. Es entspricht „fast“ der Partition

$$\mathcal{B}_T = \{\{T = k, X_0 = x_0, \dots, X_k = x_k\} \mid k \in \mathbb{N}_0, x_i \in E\}.$$

△

Wir können nun die starke Markov Eigenschaft mit dieser Notation rigoros schreiben:

Satz 4.13. Sei $\mu \in \mathcal{M}(E)$ eine beliebige Startverteilung, T eine Stoppzeit, $f : E^{\mathbb{N}_0} \rightarrow \mathbb{R}$ eine beschränkte Funktion. Sei $A \in \mathcal{F}_T$, dann

$$\mathbb{E}_\mu[\mathbb{1}_A f((X_{T+k})_{k \in \mathbb{N}_0}) \mid \mathcal{F}_T](\omega) = \mathbb{E}_{X_T(\omega)}[f((X_k)_{k \in \mathbb{N}_0})] \cdot \mathbb{E}_\mu[\mathbb{1}_A \mid \mathcal{F}_T](\omega),$$

falls $T(\omega) < +\infty$.

Beweis. Der Beweis verläuft analog zu dem der ursprünglichen Version. □

4.2. Beispiel: Reflektionsprinzip für einfache Irrfahrten

Beispiel 4.14 (Reflektionsprinzip für einfache Irrfahrten). Betrachte eine symmetrische Irrfahrt auf $\mathbb{Z}$ mit $p_{x,y} = \frac{1}{2} \mathbb{1}_{|x-y|=1}$, $\mu = \delta_0$. Setze

$$M_n := \max\{X_0, \dots, X_n\} \geq 0$$

Frage: Was ist die Verteilung von M_n ?

△

Satz 4.15. Betrachten wir die symmetrische Irrfahrt aus Example 4.14. Für alle $a \in \mathbb{N}$, $b \in \mathbb{Z}_{\leq a}$ ist

$$\mathbb{P}_0(M_n \geq a, X_n = b) = \mathbb{P}_0(X_n = 2a - b).$$

Bemerkung 4.16. Die Wahrscheinlichkeit auf der rechten Seite ist wesentlich einfacher zu bestimmen als die auf der linken. △

Beweis von Theorem 4.15. Sei $H_a := \inf\{n \geq 0 : X_n = a\} \geq 1$. Dann gilt

$$\{M_n \geq a\} = \{H_a \leq a\} \quad \text{womit} \quad \mathbb{P}_0(M_n \geq a, X_n = b) = \mathbb{P}_0(H_a \leq a, X_n = b).$$

Weiter ist

$$\begin{aligned} \mathbb{P}_0(H_a \leq a, X_n = b) &= \sum_{k=0}^n \mathbb{P}_0(H_a = k, X_n = b) \\ &\stackrel{\text{Theorem 2.15}}{=} \sum_{k=0}^n \mathbb{P}_0(H_a = k) \underbrace{\mathbb{P}_a(X_{n-k} = b)}_{=\mathbb{P}_a(X_{n-k}=2a-b)} \\ &= \mathbb{P}_0(H_n \leq 0, X_n = 2a - b). \end{aligned}$$

Es gilt $\mathbb{P}_a(X_{n-k} = b) = \mathbb{P}_a(X_{n-k} = 2a-b)$, weil die Irrfahrt symmetrisch ist (aus ähnlichen Grund heisst es auch Reflektionsprinzip). Weiter folgt aus $H_a \leq n$, dass $b \leq a$, was $2a-b \geq a$ impliziert, womit

$$\mathbb{P}_0(H_a \leq a, X_n = b) = \mathbb{P}_0(H_n \leq 0, X_n = 2a-b) = \mathbb{P}(X_n = 2a-b)$$

folgt. □

Übung 4.17. Zeigen Sie:

$$\mathbb{P}_0(H_a < +\infty) = 1 \quad \text{für alle } a \in \mathbb{Z}$$

und

$$\mathbb{E}_0[H_a] = +\infty.$$

4.3. Langzeitverhalten von Markov-Ketten

Wir bezeichnen den höchstens abzählbaren Zustandsraum der Markov-Kette weiterhin mit E . Wir arbeiten weiterhin auf dem Wahrscheinlichkeitsraum $(\Omega, \mathcal{F}, \mathbb{P}_x)$ für $x \in E$. Ist weiter $(X_n)_{n \in \mathbb{N}_0}$ eine Markov-Kette unter $\mathbb{P}_x$, ist

$$\mathbb{P}_\mu = \sum_{x \in E} \mu(x) \mathbb{P}_x.$$

Frage 4.18. • Wie ist die Grenzverteilung für X_n , wenn $n \rightarrow +\infty$?

- Für $x \in E$, wievielmals kommt X nach x ?

Wir setzen

$$H_x := \inf\{n \in \mathbb{N}_0 \mid X_n = x\}$$

die *Zeit des ersten Auftretens* von x und

$$\tilde{H}_x := \inf\{n \in \mathbb{N} \mid X_n = x\}$$

die *Rückkehrzeit*.

Definition 4.19. Sei $x \in E$. x heisst **rekurrent** falls $\mathbb{P}_x[\tilde{H}_x < +\infty] = 1$ und **transient** falls $\mathbb{P}_x[\tilde{H}_x < +\infty] < 1$.

Bemerkung 4.20. Ist x rekurrent, kommt X fast immer zurück nach x , ist es transient, besteht die Möglichkeit, dass X von x wegläuft. △

Notation 4.21. Wir werden

$$N_x := \sum_{n \in \mathbb{N}_0} \mathbb{1}_{X_n = x} \in \mathbb{N}_0 \cup \{+\infty\}$$

für die Anzahl Besuche von X schreiben.

Satz 4.22 (Dichotomie-Satz). Sei $x \in E$. Dann ist x rekurrent genau dann wenn $\mathbb{P}_x(N_x = +\infty) = 1$. Weiter ist x transient genau dann wenn $\mathbb{E}_x[N_x] < +\infty$.

Bemerkung 4.23. $\mathbb{E}_x[N_x] < +\infty$ ist äquivalent zu

$$\sum_{n=0}^{+\infty} p_{x,x}^{(n)} < +\infty,$$

denn

$$\mathbb{E}_x[N_x] = \mathbb{E}_x \left[\sum_{n=0}^{+\infty} \mathbb{1}_{X_n=x} \right] = \sum_{n=0}^{+\infty} \mathbb{E}_x[\mathbb{1}_{X_n=x}] = \sum_{n=0}^{+\infty} p_{x,x}^{(n)}$$

und $\mathbb{P}_x(N_x = +\infty) = 1$ ist äquivalent zu

$$\sum_{n=0}^{+\infty} p_{x,x}^{(n)} = +\infty$$

was aus einer ähnlichen Argumentation wie oben folgt. △

Der Beweis von Definition 4.19 benötigt das folgende Lemma:

Lemma 4.24. Für alle $i \in \mathbb{N}$ und $x \in E$ ist

$$\mathbb{P}_x(N_x \geq i) = \rho_x^{i-1}, \quad \rho_x := \mathbb{P}_x(\tilde{H}_x < +\infty).$$

Beweis von Lemma 4.24. Wir setzen

$$T_0 := 0, \quad T_k = \inf \left\{ n \in \mathbb{N}_0 \mid \sum_{i=0}^n \mathbb{1}_{X_i=x} = k+1 \right\} \quad \forall k \geq 1,$$

wobei wir bemerken, dass $T_1 = \tilde{H}_x$. Wir behaupten nun, dass T_k eine Stoppzeit ist. Dies ist aber offensichtlich, denn

$$\{T_k = m\} = \{X_m = x\} \cap \left\{ \sum_{i=0}^{m-1} \mathbb{1}_{X_i=x} = k \right\} \in \sigma(X_0, \dots, X_m) = \mathcal{F}_m.$$

Weiter ist für $i \geq 2$

$$\begin{aligned} \mathbb{P}_x(N_x \geq i) &= \mathbb{P}_x(T_{i-1} < +\infty) = \mathbb{P}_x(T_{i-1} < +\infty, T_{i-2} < +\infty) \\ &= \mathbb{P}_x(T_{i-1} < +\infty, T_{i-2} < +\infty, X_{T_{i-2}} = x) \\ &= \mathbb{P}_x(T_{i-1} < +\infty \mid T_{i-2} < +\infty, X_{T_{i-2}} = x) \mathbb{P}_x(T_{i-2} < +\infty, X_{T_{i-2}} = x). \end{aligned}$$

Benutzen wir nun die starke Markov-Eigenschaft folgt

$$\mathbb{P}_x(N_x \geq i) = \underbrace{\mathbb{P}_x(T_1 < +\infty)}_{=\rho_x} \mathbb{P}_x(N_x \geq i-1).$$

Durch Induktion zeigt man $\mathbb{P}_x(N_x \geq i-1) = \rho_x^{i-1}$. □

Beweis von Theorem 4.22. Sei $x \in E$ rekurrent. Dann ist in Lemma 4.24 $\rho_x = 1$ und damit $\mathbb{P}_x(N_x \geq i) = 1$ für jedes $i \in \mathbb{N}$. Weiter ist dann

$$\mathbb{P}_x(N_x = +\infty) = \mathbb{P}_x \left[\bigcap_{i \in \mathbb{N}} \{N_x \geq i\} \right] = \lim_{i \rightarrow +\infty} \underbrace{\mathbb{P}_x[N_x \geq i]}_{=1} = 1.$$

Für die umgekehrte Implikation folgt man einfach obiger Argumentation rückwärts.

Sei nun x transient, dann ist in Lemma 4.24 $\rho_x < 1$ und damit

$$\mathbb{P}_x[N_x = i] = \mathbb{P}_x[N_x \geq i] - \mathbb{P}_x[N_x \geq i+1] = \rho^{i-1} - \rho^i = \rho^{i-1}(1 - \rho).$$

Somit ist $N_x \sim \text{Geom}(1 - \rho_x)$, woraus folgt, dass

$$\mathbb{E}_x[N_x] = \frac{1}{1 - \rho_x} < +\infty.$$

Die umgekehrte Implikation folgt wieder, indem man obige Argumentation in umgekehrter Reihenfolge liest. $\square$

Der Beweis der folgenden Behauptung ist eine Anwendung des Dichotomiesatzes.

Behauptung 4.25. Ist E endlich existiert mindestens ein $x \in E$ sodass x rekurrent ist.

Beweis. Es gilt

$$\begin{aligned} \sum_{x \in E} N_x &= \sum_{x \in E} \sum_{n \geq 0} \mathbb{1}_{X_n = x} = \sum_{n \geq 0} \sum_{x \in E} \mathbb{1}_{X_n = x} \\ &= \sum_{n \geq 0} 1 = +\infty, \end{aligned}$$

aber die Summe $\sum_{x \in E} N_x$ ist über endlich viele Elemente, da E endlich ist. Sei nun $y \in E$. Dann ist

$$+\infty = \mathbb{E}_y \left[\sum_{x \in E} N_x \right] \stackrel{\text{M.C.}}{=} \sum_{x \in E} \mathbb{E}_y[N_x],$$

somit existiert ein $x \in E$, sodass $\mathbb{E}_y[N_x] = +\infty$. Ist $x = y$ folgt aus Theorem 4.22, dass x rekurrent ist. Ist $x \neq y$, dann ist $N_x = N_x \mathbb{1}_{H_x < +\infty}$ und deshalb

$$+\infty = \mathbb{E}_y[N_x] = \mathbb{E}_y[\mathbb{1}_{H_x < +\infty} N_x] \stackrel{\text{starke Markov}}{=} \mathbb{E}_x[N_x] \underbrace{\mathbb{P}_y(H_x < +\infty)}_{\in [0,1]};$$

dies impliziert $\mathbb{E}_x[N_x] = +\infty$ und damit ist x nach Theorem 4.22 rekurrent. $\square$

Klassifikation der Zustände. Wir wollen im Folgenden diskutieren, wie obige Konzepte mit den Kommunikationsklassen verträglich sind.

Satz 4.26. Seien $x, y \in E$ mit $x \rightarrow y$. Ist x rekurrent ist auch y rekurrent und

$$\mathbb{P}_x(H_y < +\infty) = \mathbb{P}_y(H_x < +\infty) = 1.$$

Beweis. Schritt 1: Wir zeigen, zuerst, dass $\mathbb{P}_y[H_x < +\infty] = 1$. Weil $x \rightarrow y$ existieren $z_1, \dots, z_{n-1}$ paarweise verschieden, sodass

$$p_{x,z_1}p_{z_2,z_3}, \dots, p_{z_{n-1},y} > 0. \quad (4.1)$$

Nun ist

$$\begin{aligned} 0 = \mathbb{P}_x(\tilde{H}_x = +\infty) &\geq \mathbb{P}_x \left(\bigcap_{i=0}^{n-1} \{X_i = z_i\} \cap \{X_n = y\} \cap \bigcap_{i \geq n} \{X_i \neq x\} \right) \\ &\stackrel{\text{Theorem 2.15}}{=} \underbrace{\mathbb{P}_x \left(\bigcap_{i=0}^{n-1} \{X_i = z_i\} \cap \{X_n = y\} \right)}_{>0 \text{ nach (4.1)}} \mathbb{P}_y(H_x = +\infty), \end{aligned}$$

daher ist $\mathbb{P}_y(H_x = +\infty) = 0$ was die ursprüngliche Behauptung zeigt.

Schritt 2: Wir zeigen: y ist rekurrent. Es gilt nun $x \leftrightarrow y$ d.h.

$$p_{x,y}^{(m)}, p_{y,x}^{(n)} > 0 \quad \text{für gewisse } n, m \in \mathbb{N}_0.$$

Weiter ist

$$\begin{aligned} \mathbb{E}_y[N_y] &= \sum_{k \geq 0} p_{y,y}^{(k)} \geq \sum_{k \geq 0} p_{y,y}^{(n+m+k)} \\ &\geq \underbrace{p_{x,y}^{(n)} p_{x,x}^{(m)}}_{>0} \underbrace{\sum_{k \geq 0} p_{x,x}^{(k)}}_{=+\infty \text{ da } x \text{ rekurrent}} \quad (\text{Chapman-Kolmogorov}) \\ &= +\infty, \end{aligned}$$

was zeigt, dass y rekurrent ist nach Theorem 4.22.

Schritt 3: Wir zeigen $\mathbb{P}_x(H_y < \infty) = 1$. Dies folgt aber aus Schritt 1, indem wir x und y vertauschen. $\square$

Folgerung 4.27. Sei C eine Kommunikationsklasse von $p = (p_{x,y})_{x,y \in E}$. Falls wir ein rekurrentes/transientes $x \in C$ finden, dann sind alle Zustände in C rekurrent/transient.

Beweis. Das Resultat ist eine direkte Konsequenz des vorherigen Satzes. $\square$

Folgerung 4.28. Jede rekurrente Kommunikationsklasse C ist wesentlich.

Beweis. Ist $x \in C$ und $x \rightarrow y$, dann folgt die Implikation

$$y \rightarrow x \quad \Rightarrow \quad y \in C. \quad \square$$

Bemerkung 4.29. Es gilt immer, dass

$$E = T \dot{\cup} R_1 \dot{\cup} R_2 \dot{\cup} \dots,$$

wobei R_i rekurrente Kommunikationsklassen sind und T die Menge aller transienten Zuständen. Startet die Markov-Kette X in R_i bleibt sie für immer in R_i und $p|_{R_i}$ ist immer eine Übergangswahrscheinlichkeit.

T kann wesentlich sein, muss aber nicht. $\triangle$

Definition 4.30. Sei X bez. p irreduzibel d.h. alle Zustände von E kommunizieren. Dann X bez. p **rekurrent** falls alle x in E rekurrent sind und **transient** falls jedes $x \in E$ transient ist.

Bemerkung 4.31 (Rekurrenz/Transienz der Irrfahrt auf $\mathbb{Z}^d$). Wir betrachten eine Irrfahrt auf $\mathbb{Z}^d$ mit Übergangswahrscheinlichkeit

$$p_{x,y} := \begin{cases} \frac{1}{2d} & |x - y| = 1 \\ 0 & \text{sonst} \end{cases} . \quad (4.2)$$

Dann kommunizieren alle Zustände von $\mathbb{Z}^d$. △

Satz 4.32 (Polya, 1921). Die Irrfahrt auf $\mathbb{Z}^d$ mit Übergangswahrscheinlichkeiten (4.2) ist

- rekurrent falls $d \in \{1, 2\}$ und
- transient falls $d \geq 3$.

Beweis. Wir werden hier den Beweis nicht in voller Länge diskutieren, sondern nur die Idee darlegen. Um den Satz zu zeigen, muss man $p_{0,0}^{(n)}$ berechnen, was schwierig ist für $d \geq 2$.

Ist $d = 1$, gilt

$$p_{0,0}^{(2n)} = \frac{c}{\sqrt{n}}(1 + o(1))$$

und damit

$$\sum_{n \geq 0} p_{0,0}^{(n)} = +\infty,$$

was impliziert, dass 0 rekurrent ist und damit X rekurrent ist, da alle Zustände miteinander kommunizieren.

Für $d \geq 2$ schreiben wir $X_i = (X_i^{(1)}, \dots, X_i^{(d)})$. Dann ist $X^{(i)} = (X_k^{(i)})_{k \in \mathbb{N}_0}$ eine Irrfahrt auf $\mathbb{Z}$ wobei wir nun die Möglichkeit haben, stehen zu bleiben. Wären $(X^{(i)})_{i=1}^d$ unabhängig (was NICHT der Fall ist!), wäre

$$p_{0,0}^{(2n)} = \underbrace{\mathbb{P}_0(X_{2n}^{(1)} = 0) \dots \mathbb{P}_0(X_{2n}^{(d)} = 0)}_{\sim \frac{1}{\sqrt{n}}} \sim n^{-d/2},$$

was das Resultat mit

$$\sum_{n \geq 0} n^{-d/2} \quad \begin{cases} = +\infty & d = 1, 2 \\ < +\infty & d \geq 3 \end{cases}$$

zeigen würde. Dies geht aber nicht. Im Allgemeinen kann man zeigen, dass

$$p_{0,0}^{(2n)} = \frac{C_d}{n^{d/2}}(1 + o(1)),$$

was aber ein schwieriges Unterfangen ist. □

Beispiel 4.33. Siehe Skript:) Vorlesung 9 △

Frage 4.34. Ist x rekurrent, gilt $\mathbb{P}_x(N_x = +\infty) = 1$. Was wissen wir über die Dichte der Rekurrenz?

Wir setzen

$$N_x^{(n)} := \sum_{i=1}^n \mathbb{1}_{X_i=x} = \# \text{ Besuche von } x \text{ vor der Zeit } n$$

und stellen uns die Frage, wie verhält sich $\frac{1}{n}N_x^{(n)}$ für $n \rightarrow +\infty$ (Wir nennen $\frac{1}{n}N_x^{(n)}$ die Dichte der Besuche)?

Definition 4.35. Sei $x \in E$, $\mu_x := \mathbb{E}_x[\tilde{H}_x]$. Wir sagen, dass x ist **positiv rekurrent** falls $\mu_x < +\infty$ und x ist **null rekurrent** falls $\mu_x = +\infty$ und x rekurrent ist.

Satz 4.36. Seien $x, y \in E$ mit $x \leftrightarrow y$. Dann gilt

$$\frac{N_y^{(n)}}{n} \xrightarrow[n \rightarrow +\infty]{\mathbb{P}_x} \frac{1}{\mu_y},$$

wobei falls $\mu_y = +\infty$ definieren wir $\mu_y^{-1} := 0$.

Lemma 4.37.

1. $(W_i)_{i \geq 1}$ sind unabhängig unter $\mathbb{P}_x$
2. $(W_i)_{i \geq 2}$ sind identisch verteilt unter $\mathbb{P}_x$ und $\mathbb{P}_x(W_i = t) = \mathbb{P}_y(\tilde{H}_y = t)$

Bemerkung 4.38. In Lemma 4.37 bei Punkt 2 startet die Folge erst bei 2, weil W_1 keine wirkliche Exkursion ist, da wir von x nach y gehen. $\triangle$

Beweis von Lemma 4.37. Siehe Skript. Folgt aus der starken Markov-Eigenschaft. $\square$

Beweis von Theorem 4.36. Seien $x, y \in E$ rekurrent (sind x, y transient, kehrt die Irrfahrt endlich viel mal zu y zurück, d.h. rechte und linke Seite von Theorem 4.36 gleich null). Wir setzen

$$\begin{aligned} H_y^{(0)} &:= 0 \\ H_y^{(1)} &:= H_y \\ H_y^{(i+1)} &:= \inf\{i > H_y^{(i)} : X_i = y\} \\ W_i &:= H_y^{(i)} - H_y^{(i-1)}. \end{aligned}$$

W_i ist die Dauer der i -ten Exkursion und

$$H_y^{N_y^{(n)}} \leq n \leq H_y^{N_y^{(n)}+1}.$$

Wir schreiben nun

$$\begin{aligned} \frac{1}{k}H_y^k &= \underbrace{\frac{1}{k}W_1}_{\rightarrow 0} + \underbrace{\frac{k-1}{k}}_{\rightarrow 1} \underbrace{\left(\frac{1}{k-1} \sum_{i=2}^k W_i \right)}_{\rightarrow \mathbb{E}[W_2]} \\ &\xrightarrow{k \rightarrow +\infty} \mathbb{E}_x[W_2]. \quad (\text{Starkes Gesetz der grossen Zahlen}) \end{aligned}$$

Wir können das Starke Gesetz der grossen Zahlen dank Lemma 4.37 anwenden. Somit folgt

$$\frac{1}{k} H_y^{(k)} \xrightarrow{k \rightarrow +\infty} \mu_y. \quad (4.3)$$

Weiter ist

$$\frac{N_y^{(n)}}{H_y^{(N_y^{(n)}+1)}} \leq \frac{N_y^{(n)}}{n} \leq \frac{N_y^{(n)}}{H_y^{(N_y^{(n)})}}$$

aber beide Seiten konvergieren gegen $\frac{1}{\mu_x}$ für $n \rightarrow +\infty$ dank (4.3); hierraus folgt der Satz. $\square$

Bemerkung 4.39. $H_y^{(n)}$ und $N_y^{(n)}$ sind „beinahe“ inverse Funktionen beziehungsweise sie verhalten sich asymptotisch wie inverse Funktionen. $\triangle$

Beispiel 4.40. Wir betrachten eine Irrfahrt auf $E = \{1, 2\}$ mit Übergangswahrscheinlichkeitsmatrix

$$\mathbf{P} = \begin{bmatrix} 1 - \alpha & \alpha \\ \beta & 1 - \beta \end{bmatrix}.$$

Wir behaupten nun, dass 1 positiv rekurrent ist. Für $k \geq 1$ ist

$$\mathbb{P}_1(\tilde{H}_1 \geq k) = \mathbb{P}(X_1 = 2, \dots, X_{k-1} = 2) = \alpha(1 - \beta)^{k-2},$$

was impliziert, dass

$$\mathbb{E}_1[\tilde{H}_1] = \sum_{k \geq 1} \mathbb{P}_1(\tilde{H}_1 \geq k) = \sum_{k \geq 1} \alpha(1 - \beta)^{k-2} < +\infty.$$

$\triangle$

Beispiel 4.41 (Irrfahrt auf $\mathbb{Z}$). Man kann zeigen, dass

$$\mathbb{P}_0(\tilde{H}_0 < 2n) = \mathbb{P}_0(X_{2n} = 0) = \mathcal{O}\left(\frac{1}{\sqrt{n}}\right) \quad \text{für } n \rightarrow +\infty.$$

Damit ist $\mathbb{E}_0[\tilde{H}_0] = +\infty$. $\triangle$

4.4. Existenz und Eindeutigkeit invarianter Verteilungen und Masse

Wir sagen, dass $\pi \in \mathcal{M}(E)$ eine invariante Verteilung bezüglich der Startverteilung $p = (p_{x,y})_{x,y \in E}$ ist, falls

$$\pi(x) = \sum_{y \in E} \pi(y) p_{y,x}^{(k)}, \quad k \geq 1 \quad (4.4)$$

(Wir hatten $k \geq 2$ in den Übungen gezeigt).

Frage 4.42. Wann existieren invariante Verteilungen und wann sind sie eindeutig?

Bemerkung 4.43. Wie wir bereits gesehen haben, liest sich (4.4) im vektoriellen Fall als $\boldsymbol{\pi}^\top = \boldsymbol{\pi}^\top \mathbf{P}$. Aus der linearen Algebra, erhalten wir die Existenz eines linken Eigenvektors $\mathbf{v}$ von $\mathbf{P}$ zum Eigenwert 1, d.h. $\mathbf{v}^\top = \mathbf{v}^\top \mathbf{P}$, da $\mathbf{P}\mathbf{1} = \mathbf{1}$. Der linke Eigenvektor muss aber nicht zwingend eine Verteilung sind. Die Existenz der invarianten Verteilung ist also nicht trivial. $\triangle$

Definition 4.44. Sei $\nu \neq 0$ ein Mass. Wir sagen, dass ν ein **invariantes Mass** für p ist, falls $\nu(x) \geq 0$ für alle $x \in E$ und

$$\nu(x) = \sum_{y \in E} \nu(y) p_{y,x} \quad \text{für alle } x \in E.$$

Bemerkung 4.45. • Jede invariante Verteilung ist ein invariantes Mass.

• Ist $C > 0$ und ν ein invariantes Mass, dann ist auch $C\nu$ ein invariantes Mass.

• Ist ν ein invariantes Mass und

$$Z := \sum_{x \in E} \nu(x) < +\infty$$

dann ist $\frac{1}{Z}\nu(\cdot)$ ein invariantes Mass.

△

Existenz invarianter Masse. Wir führen die folgende Notation ein: Seien $x, y \in E$. Wir definieren

$$n_x(y) := \mathbb{E}_x \left[\sum_{i=1}^{\tilde{H}_x} \mathbb{1}_{X_i=y} \right],$$

die Anzahl der erwarteten Besuche von y während einer Exkursion von x nach y . Diese Quantität wird im folgenden Satz entscheidend sein:

Satz 4.46. Sei x rekurrent. Dann

1. $n_x(x) = 1$,
2. $n_x(\cdot)$ ist ein Invariantes Mass und
3. falls $x \leftrightarrow y$ ist $n_x(y) \in (0, +\infty)$ und falls x und y nicht kommunizieren gilt $n_x(y) = 0$.

Beweis. 1. Falls x rekurrent ist, ist $\mathbb{P}_x(\tilde{H}_x < +\infty) = 1$ und $X_{\tilde{H}_x} = x$ und somit

$$\mathbb{P}_x \left(\sum_{i=1}^{\tilde{H}_x} \mathbb{1}_{X_i=x} = 1 \right) = 1 \quad \Rightarrow \quad n_x(x) = 1.$$

2. Wir schreiben

$$\begin{aligned}
n_x(y) &= \mathbb{E}_x \left[\sum_{i=1}^{+\infty} \mathbb{1}_{X_i=y, i \leq \tilde{H}_x} \right] \\
&= \sum_{i=1}^{+\infty} \mathbb{P}_x(X_i = y, i \leq \tilde{H}_x) \quad (\text{Monotone Konvergenz}) \\
&= \sum_{i=1}^{+\infty} \sum_{z \in E} \mathbb{P}_x(X_i = y, X_{i-1} = z, i \leq \tilde{H}_x) \\
&\stackrel{(!)}{=} \sum_{i=1}^{+\infty} \sum_{z \in E} \mathbb{P}_x(X_{i-1} = z, i \leq \tilde{H}_x) p_{z,y} \quad (\text{schw. Markov}) \\
&= \sum_{z \in E} p_{z,y} \sum_{i=0}^{+\infty} \mathbb{P}_x(X_i = z, i \leq \tilde{H}_x - 1) \\
&= \sum_{z \in E} p_{z,y} \mathbb{E}_x \left[\sum_{k=0}^{\tilde{H}_x-1} \mathbb{1}_{X_k=z} \right] \quad (\text{obige Schritte rückwärts})
\end{aligned}$$

wobei wir bei (!) benutzt haben, dass $\{i \leq \tilde{H}_x\} = \{i-1 \geq \tilde{H}_x\}^c \in \mathcal{F}_{i-1}$. Nun ist x rekurrent, d.h. $\mathbb{P}_x(\tilde{H}_x < +\infty) = 1$ und damit $\mathbb{P}_x(\mathbb{1}_{X_0=y} = \mathbb{1}_{X_{\tilde{H}_k}=y}) = 1$. Dies impliziert

$$\sum_{z \in E} p_{z,y} \mathbb{E}_x \left[\sum_{k=0}^{\tilde{H}_x-1} \mathbb{1}_{X_k=z} \right] = \sum_{z \in E} p_{z,y} \mathbb{E}_x \left[\sum_{k=1}^{\tilde{H}_x} \mathbb{1}_{X_k=z} \right] = \sum_{z \in E} p_{z,y} n(z),$$

d.h. $n_x(\cdot)$ ist invariant, wie behauptet.

3. Gilt $x \leftrightarrow y$ existieren $m, n \in \mathbb{N}_0$ sodass $p_{x,y}^{(n)}, p_{x,y}^{(m)} > 0$. Da $n_x(\cdot)$ invariant ist, folgt

$$p_{x,y}^{(n)} \sum_{z \in E} p_{x,y}^{(n)} n_x(y) \geq p_{x,y}^{(n)} \underbrace{n_x(x)}_{=1} > 0$$

Fortsetzung nächste Woche :)??

□

Lemma 4.47. Sei ν ein beliebiges invariantes Mass mit $\nu(x) = 1$, wobei x rekurrent ist. Dann ist

$$\nu(y) \geq n_x(y) \quad \text{für alle } y \in E.$$

Beweis. Da ν invariant ist, gilt für ein beliebiges $z \in E$, dass

$$\begin{aligned}
\nu(z) &= \sum_{y_1 \in E} \nu(y_1) p_{y_1,z} = \sum_{\substack{y_1 \in E \\ y_1 \neq x}} \nu(y_1) p_{y_1,z} + p_{x,z} \\
&= \sum_{\substack{y_1 \in E \\ y_1 \neq x}} \sum_{y_2 \in E} \nu(y_2) p_{y_1,y_2} p_{y_1,z} + p_{x,z} \\
&= \sum_{\substack{y_1 \in E \\ y_1 \neq x}} \sum_{\substack{y_2 \in E \\ y_2 \neq x}} \nu(y_2) p_{y_1,y_2} p_{y_1,z} + \sum_{\substack{y_1 \in E \\ y_1 \neq x}} p_{x,y_1} p_{y,z} + p_{x,z}.
\end{aligned}$$

Wiederholen wir dies induktiv, folgt

$$\begin{aligned}\nu(z) &= \sum_{y_1, \dots, y_k \in E \setminus \{x\}} \nu(y_k) p_{y_k, y_{k-1}} \cdots p_{y_2, y_1} p_{y_1, z} \\ &+ \sum_{y_1, \dots, y_{k-1} \in E \setminus \{x\}} \nu(y_k) p_{y_k-1, y_{k-2}} \cdots p_{y_2, y_1} p_{y_1, z} \\ &\dots \\ &+ \sum_{y_1 \in E \setminus \{x\}} p_{y, z} p_{x, y_1} + p_{x, z}\end{aligned}$$

Vergessen wir die erste Summe und fassen die übrigen wieder zusammen, ergibt sich

$$\nu(z) \geq \sum_{i=1}^k \mathbb{P}_x(X_i = z, \tilde{H}_x \geq i).$$

Bilden wir nun den Grenzwert $k \rightarrow +\infty$, erhalten wir

$$\nu(z) \geq \sum_{i=1}^{+\infty} \mathbb{P}_x(X_i = z, \tilde{H}_x \geq i) = \mathbb{E}_x \left[\sum_{i=1}^{+\infty} \mathbb{1}_{X_i=z, \tilde{H}_x \geq i} \right] = n_x(z). \quad \square$$

Folgerung 4.48.

1. Sei ν ein invariantes Mass mit $\nu(x) = 1$ und sei x rekurrent. Dann gilt für alle $y \in E$ mit $x \leftrightarrow y$ die Gleichheit

$$\nu(y) = n_x(y)$$

2. Ist p irreduzibel gilt $\nu = n_x$, das heisst, n_x ist das einzige Mass mit $\nu(x) = 1$.

Beweis. 1. Da x rekurrent ist, ist n_x invariant und aus Lemma 4.47 wissen wir, dass $\nu \geq n_x$. Setzen wir $\lambda := \nu - n_x \geq 0$, ist $\lambda(x) = 1$ und λ ist invariant. Sei nun $y \in E$, sodass $x \leftrightarrow y$. Dann finden wir $n \in \mathbb{N}$, sodass $p_{y,x}^{(n)} > 0$. Dann ist

$$0 = \lambda(x) \stackrel{\lambda \text{ invariant}}{=} \sum_{z \in E} \lambda(z) p_{z,x}^{(n)} \geq \lambda(y) p_{y,x}^{(n)}$$

und daraus folgt, dass $\lambda(y) = 0$ ist. Dies zeigt den ersten Punkt.

2. Diese Aussage ist eine direkte Konsequenz der vorherigen. $\square$

Invariante Verteilungen. Sei ν ein invariantes Mass mit $Z := \sum_{x \in E} \nu(x) < +\infty$. Wir können dann $\pi := \frac{\nu}{Z}$ definieren und erhalten eine invariante Verteilung. Ist nun x ein rekurrenter Punkt, haben wir gezeigt, dass n_x ein invariantes Mass ist. Wenn die Summe $\sum_{y \in E} n_x(y)$ endlich können wir die obige Überlegung direkt anwenden.

Es ergibt sich schnell, dass

$$\sum_{y \in E} n_x(y) = \mathbb{E}_x \left[\sum_{i=1}^{\tilde{H}_x} \sum_{y \in E} \mathbb{1}_{X_i=y} \right] = \mathbb{E}_x \left[\sum_{i=1}^{\tilde{H}_x} 1 \right] = \mathbb{E}_x[\tilde{H}_x] \in [0, +\infty].$$

Wir benannten den Zustand $\mathbb{E}_x[\tilde{H}_x] < +\infty$ als *positiv rekurrent* und den Fall der Unendlichkeit als *null rekurrent*.

Satz 4.49. Sei C eine Kommunikationsklasse der Übergangswahrscheinlichkeit $p = (p_{x,y})_{x,y \in E}$. Dann sind folgende Aussagen äquivalent:

1. Es existiert $x \in C$, sodass x positiv rekurrent.
2. Jedes $x \in C$ ist positiv rekurrent.
3. Es gibt eine invariante Verteilung π für p mit $\pi(C) = 1$.

Sind diese Voraussetzungen erfüllt, ist π die eindeutige invariante Verteilung mit $\pi(C) = 1$ und es gilt

$$\pi(y) = \frac{n_x(y)}{\mathbb{E}_x[\tilde{H}_x]} \quad \text{für alle } x, y \in E. \quad (4.5)$$

Bemerkung 4.50. Aus dem Satz folgt die Gleichheit

$$\frac{n_x(y)}{\mathbb{E}_x[\tilde{H}_x]} = \frac{n_z(y)}{\mathbb{E}_z[\tilde{H}_z]} \quad \text{für alle } x, y, z \in C,$$

wobei C die Kommunikationsklasse aus Theorem 4.49 ist. $\triangle$

Beweis von Theorem 4.49. „(2) $\Rightarrow$ (1)“: Diese Implikation ist offensichtlich.

„(1) $\Rightarrow$ (3)“: Nach Beobachtung ist (4.5) invariant. Ist $x \not\rightarrow y$ ist $n_x(y) = 0$ und damit $\pi(E \setminus C) = 0$ woraus $\pi(C) = 1$ folgt.

„(3) $\Rightarrow$ (2)“: Sei $x \in C$ beliebig und π eine invariante Verteilung mit $\pi(C) = 1$. Daraus folgt die Existenz von $y \in C$ mit $\pi(y) > 0$ und damit existiert $n \in \mathbb{N}_0$ mit $p_{x,y}^{(n)} > 0$. Die Invarianz von π impliziert

$$\pi(x) = \sum_{z \in E} p_{z,x}^{(n)} p(z) \geq p_{y,x}^{(n)} \pi(y) > 0,$$

wodurch $\pi(x) > 0$. Wir zeigen nun, dass x positiv rekurrent ist. Definieren wir

$$\lambda(z) := \frac{\pi(z)}{\pi(x)} \quad \text{für alle } z \in E.$$

Dann gilt $\lambda(x) = 1$ und λ ist invariant, da π invariant ist. Benutzen wir Lemma 4.47, erhalten wir $\lambda \geq n_x$. Weiter ist

$$\mathbb{E}_x[\tilde{H}_x] = \sum_{y \in E} n_x(y) \leq \sum_{y \in E} \lambda(y) = \sum_{y \in E} \frac{\pi(y)}{\pi(x)} = \frac{1}{\pi(x)} < +\infty, \quad (4.6)$$

weshalb x rekurrent ist. Da x arbiträr gewählt wurde, folgt das Resultat.

Es bleibt nun zu zeigen, dass π in seiner Rolle eindeutig ist. Dies folgt aber aus Corollary 4.48. Damit ist der Beweis vollendet. $\square$

Bemerkung 4.51. Wir können anstatt (4.6), zeigen, dass

$$\mathbb{E}_x[\tilde{H}_x] = \frac{1}{\pi(x)}$$

gilt. $\triangle$

Bemerkung 4.52. Ist E endlich, existiert eine positiv rekurrente Kommunikationsklasse C . Daraus lässt sich dann direkt die Existenz einer invarianten Verteilung mit $\pi(C) = 1$ schließen. $\triangle$

Beispiel 4.53. Wir betrachten die einfache symmetrische Irrfahrt auf $\mathbb{Z}$ $(X_k)_{k \in \mathbb{N}_0}$. Diese Kette ist irreduzibel und rekurrent. $\nu(x) = 1$ für alle $x \in \mathbb{Z}$ ist ein invariantes Mass, was man durch die folgende Berechnung sieht:

$$\nu(x) = \sum_{y \in E} \underbrace{\nu(y)}_{=1} p_{y,x} = \sum_{y \in E} p_{y,x} = 1.$$

Da $\sum_{x \in E} \nu(x) = +\infty$ folgt, dass $(X_k)_{k \in \mathbb{N}_0}$ keine invariante Verteilung besitzt. Damit ist $(X_k)_{k \in \mathbb{N}_0}$ nach Theorem 4.49 null rekurrent. Dieses Argument lässt sich auch auf den Fall in $\mathbb{Z}^d$ anwenden. In $\mathbb{Z}^d$ mit $d \geq 3$ ist $\nu(x) = 1$ für alle $x \in \mathbb{Z}^d$ ein invariantes Mass aber keine invariante Verteilung. $\triangle$

Beispiel 4.54. Betrachte die asymmetrische Irrfahrt auf $\mathbb{Z}$, dass heisst wir betrachten $(X_k)_{k \in \mathbb{N}_0}$ mit Übergangswahrscheinlichkeit

$$p_{x,y} = \begin{cases} p, & y = x + 1 \\ q, & y = x - 1 \\ 0, & \text{sonst} \end{cases},$$

wo $p + q = 1$ und $p, q \geq 0$ mit $p, q \neq \frac{1}{2}$. Suchen wir ein invariantes Mass ν , müssen wir

$$\nu(x) = \sum_{y \in \mathbb{Z}} \nu(y) p_{y,x} = \nu(x-1)p + \nu(x+1)q$$

Dann sind für $A, B > 0$,

$$\nu \equiv A \quad \text{und} \quad \nu(x) = B \left(\frac{p}{q} \right)^x$$

invariante Masse. Da jede Linearkombination eines invarianten Masses wieder ein invariantes Mass ist, ist

$$\nu(x) = A + B \left(\frac{p}{q} \right)^x, \quad A, B \geq 0, A + B > 0 \quad (4.7)$$

ein invariantes Mass. Es ist aber nie möglich, dieses zu normieren, da die Summe über alle Zustände stets divergiert. Hier sind nicht alle invarianten Masse Vielfache von einander, was aus (4.7) folgt. Damit kann $(X_k)_{k \in \mathbb{N}_0}$ nach (4.48) nicht rekurrent und $(X_k)_{k \in \mathbb{N}_0}$ transient. $\triangle$

Übung 4.55. Zeigen Sie: Es gibt transiente Ketten die kein invariantes Mass haben.

Typ der Markov-Kette	positiv rekurrent	null rekurrent	transient
Anz. invarianter Masse	1 (bis auf Vielfache)	1 (bis auf Vielfache)	$\{0, 1, +\infty\}$
Anz. invarianter Verteil.	1	0	0

Tabelle 4.1.:

5. Konvergenz von Markov-Ketten

5.1. Periodizität

Wir hatten gezeigt, dass

$$y \mapsto \lim_{n \rightarrow +\infty} P_\mu(X_n = y)$$

ein invariantes Mass ist, falls der Grenzwert existiert. Weiter hatten wir in Theorem 4.36 gezeigt, dass

$$\frac{1}{n} \sum_{i=1}^n \mathbb{1}_{X_i=y} \xrightarrow[n \rightarrow +\infty]{\text{unter } \mathbb{P}_\mu} \frac{1}{\mu_y}, \quad \mu_y = \mathbb{E}_y[\tilde{H}_y] \quad (5.1)$$

und damit

$$\frac{1}{n} \sum_{i=1}^n \mathbb{P}_x(X_i = y) \xrightarrow[n \rightarrow +\infty]{} \frac{1}{\mu_y}.$$

Ist weiter x positiv rekurrent, ist

$$\pi(y) := \frac{n_x(y)}{\mu_x} \stackrel{x=y}{=} \frac{n_y(y)}{\mu_y} = \frac{1}{\mu_y}$$

und damit erhalten wir Cesaro-Konvergenz von $(p_{x,y}^{(i)})_{i \geq 1}$ im Falle eines rekurrenten x :

$$\frac{1}{n} \sum_{i=1}^n p_{x,y}^{(i)} \xrightarrow[n \rightarrow +\infty]{} \pi(y).$$

Frage 5.1. Gilt

$$p_{x,y}^{(i)} \xrightarrow[i \rightarrow +\infty]{} \pi(y)$$

für manche x ? Und für welche Ketten können wir dies schliessen?

Definition 5.2. Sei $x \in E$. Wir definieren

$$T(x) := \{n \in \mathbb{N} : p_{x,x}^{(n)} > 0\} \quad \text{und} \quad d_x := \text{ggT}(T(x))$$

und nennen d_x die **Periode von x** .

Lemma 5.3. Seien $x, y \in E$ mit $x \leftrightarrow y$. Dann ist $d_x = d_y$.

Bemerkung 5.4. Man spricht deshalb über die Periode einer Kommunikationsklasse, dank Lemma 5.3. △

Beweis von Lemma 5.3. Sei $x \neq y$. Wir zeigen, dass d_x die Zahl d_y teilt. Da x und y kommunizieren, existieren $k, l \in \mathbb{N}$ sodass $p_{x,y}^{(k)}, p_{y,x}^{(l)} > 0$. Aus Chapman Kolmogorov folgt

$$p_{y,y}^{(k+l)} \geq p_{x,y}^{(k)} p_{y,x}^{(l)} > 0$$

und damit $k + l \in T(y)$, weshalb $d_y \mid k + l$. Nehmen wir nun $n \in \mathbb{N}$ mit $p_{x,x}^{(n)} > 0$ folgt wieder mit Chapman-Kolmogorov

$$p_{y,y}^{(k+l+n)} \geq P_{y,x}^{(l)} p_{x,x}^{(n)} p_{x,y}^{(k)} > 0,$$

woraus $k + l + n \in T(y)$ folgt und damit $d_y \mid k + l + n$ für alle $n \in T(x)$ d.h. d_y teilt jedes $n \in T(x)$. Somit $d_y \mid d_x$. Durch Vertauschen der beiden Variablen können wir schliessen, dass $d_x \mid d_y$ und damit $d_x = d_y$. $\square$

Definition 5.5. Der Punkt $x \in E$ heisst **aperiodisch** falls $d_x = 1$. Wir nennen die Klasse/Kette **aperiodisch**, falls jeder Punkt in der Klasse/Kette aperiodisch ist.

Lemma 5.6. Seien $x, y \in E$ zwei Zustände die kommunizieren und aperiodisch sind, das heisst $d_x = d_y = 1$. Dann gibt es ein $n_0 = n_0(x, y)$, sodass $p_{x,y}^{(n)} > 0$ für alle $n \geq n_0$.

Beweis. Ohne Beschränkung der Allgemeinheit sei $x = y$. Aus $p_{x,x}^{(n)}, p_{x,x}^{(m)} > 0$ folgt

$$p_{x,x}^{(n+m)} \geq p_{x,x}^{(n)} p_{x,x}^{(m)} > 0,$$

das heisst, $T(x)$ ist bezüglich der Addition abgeschlossen. Aus dem Lemma von Bézout schliessen wir nun (da $\text{ggT}(T(x)) = 1$), dass wir $c_1, \dots, c_N \in \mathbb{Z}$ und $n_1, \dots, n_N \in T(x)$ mit

$$\sum_{i=1}^N c_i n_i = 1$$

finden. Setzen wir $\ell := \sum_{i=1}^N |c_i| n_i \in T(x)$, ist

$$m := \ell + 1 = \sum_{i=1}^N (|c_i| + c_i) n_i \in T(x).$$

Sei $k \geq \ell^2$, $k \in \mathbb{N}$. Wir teilen k durch ℓ mit Rest, das heisst wir finden $q \in \mathbb{N}$ und $s \in \{0, \dots, \ell - 1\}$ sodass

$$k = q\ell + s = q\ell + s(m - \ell) = (q - s)\ell + sm \in T(x).$$

Wir können daher $n_0 := \ell^2$ wählen. $\square$

Ein Korollar von (5.1) ist:

Folgerung 5.7 (Ergodizitätssatz). Sei X irreduzibel, positiv rekurrent und $f : E \rightarrow \mathbb{R}$ beschränkt. Dann konvergiert der zeitliche Durchschnitt von f gegen den räumlichen Durchschnitt von f , d.h.

$$\frac{1}{n} \sum_{i=1}^n f(X_i) \xrightarrow{n \rightarrow +\infty} \sum_{x \in E} \pi(x) f(x).$$

Beweis. Wir wenden (5.1) an:

$$\frac{1}{n} \sum_{i=1}^n f(X_i) = \sum_{y \in E} f(y) \underbrace{\left(\frac{1}{n} \sum_{i=1}^n \mathbb{1}_{X_i=y} \right)}_{\rightarrow \pi(y)} \xrightarrow{n \rightarrow +\infty} \sum_{x \in E} \pi(x) f(x),$$

wobei wir Beppo-Levi benutzt haben, um Grenzwert und Summe zu vertauschen. $\square$

Satz 5.8. Sei $p = (p_{x,y})_{x,y \in E}$ irreduzibel, aperiodisch und positiv rekurrent. Dann gilt für alle Verteilungen μ auf E , dass

$$\pi(y) = \lim_{n \rightarrow +\infty} \mathbb{P}_\mu(X_n = y),$$

mit π der eindeutigen invarianten Verteilung; und insbesondere, falls $\mu = \delta_x$,

$$\pi(y) = \lim_{n \rightarrow +\infty} p_{x,y}^{(n)}$$

eine invariante Verteilung ist.

5.2. Kupplung von Markov-Ketten

Um Theorem 5.8 zu zeigen brauchen wir weitere Werkzeuge. Die Idee ist nun die folgende: Wir werden im Folgenden zwei Markov-Ketten $(X_n)_{n \in \mathbb{N}_0}, (Y_n)_{n \in \mathbb{N}_0}$ mit Übergangswahrscheinlichkeit $p = (p_{x,y})_{x,y \in E}$ betrachten, wobei $(X_n)_{n \in \mathbb{N}_0}$ Startverteilung μ und $(Y_n)_{n \in \mathbb{N}_0}$ invarianter Startverteilung π . Dann interessieren wir uns für die Stoppzeit

$$T := \inf\{k : X_k = Y_k\}.$$

Da $X_{T+k} = Y_{T+k}$ unter dem entsprechenden Wahrscheinlichkeitsmass für alle $k \in \mathbb{N}_0$ finden wir, dass $(X_k)_{k \in \mathbb{N}_0}$ invariant wird.

Definition 5.9 (Produktübergangswahrscheinlichkeit). Wir definieren die **Produktübergangswahrscheinlichkeit** $\bar{p} = (\bar{p}_{w,w'})_{w,w' \in E^2}$ auf $E^2 = E \times E$ durch

$$\bar{p}_{w,w'} = p_{x,x'}p_{y,y'} \quad \text{mit } w = (x,y), w' = (x',y').$$

Bemerkung 5.10. Es lässt sich leicht zeigen, dass $\bar{p}$ wirklich eine Übergangswahrscheinlichkeit ist. Dieser Beweis verbleibt dem Leser zur Übung. $\triangle$

Wir erhalten dadurch einen Wahrscheinlichkeitsraum $(\Omega, \mathcal{F}, (\mathbb{P}_w)_{w \in E^2})$. Wir nehmen dann eine Markov-Kette auf $(W_n)_{n \in \mathbb{N}_0} = ((X_n, Y_n))_{n \in \mathbb{N}_0}$ sodass $(W_n)_{n \in \mathbb{N}_0}$ eine Markov-Kette mit Startverteilung δ_w und Übergangswahrscheinlichkeit $\bar{p}$ unter $\mathbb{P}_w$ ist. Für zwei Wahrscheinlichkeitsmasse $\mu, \nu \in \mathcal{M}(E)$ setzen wir

$$\mathcal{M}(E^2) \ni (\mu \otimes \nu)(x, y) := \mu(x)\nu(y)$$

und

$$\mathbb{P}_{\mu \otimes \nu} := \sum_{x,y \in E} (\mu \otimes \nu)(x, y) \mathbb{P}_{(x,y)}.$$

Behauptung 5.11. Unter $\mathbb{P}_{\mu \otimes \nu}$ gilt folgendes:

1. $(X_n)_{n \in \mathbb{N}_0}$ ist eine MC(μ, p)
2. $(Y_n)_{n \in \mathbb{N}_0}$ ist eine MC(ν, p)
3. X und Y sind unabhängig.

Beweis. Es gilt

$$\begin{aligned}
 \mathbb{P}_{\mu \otimes \nu} \left(\bigcap_{i=0}^n (\{X_i = x_i\} \cap \{Y_i = y_i\}) \right) &= \mathbb{P}_{\mu \otimes \nu} \left(\bigcap_{i=0}^n \{W_i = (x_i, y_i)\} \right) \\
 &= (\mu \otimes \nu)(x_0, y_0) \prod_{i=1}^n \bar{p}_{(x_{i-1}, y_{i-1}), (x_i, y_i)} \\
 &= \left(\mu(x_0) \prod_{i=1}^n p_{x_{i-1}, x_i} \right) \left(\nu(y_0) \prod_{i=1}^n p_{y_{i-1}, y_i} \right),
 \end{aligned}$$

daraus folgt gleich die Unabhängigkeit von $(X_n)_{n \in \mathbb{N}_0}$ und $(Y_n)_{n \in \mathbb{N}_0}$. Weiterhin können wir zeigen, dass $(X_n)_{n \in \mathbb{N}_0}$ eine MC(μ, p) ist, indem wir in der obigen Rechnung einfach über alle $y \in E$ summieren, d.h.

$$\begin{aligned}
 \mathbb{P}_{\mu \otimes \nu} \left(\bigcap_{i=0}^n \{X_i = x_i\} \right) &= \sum_{\substack{y_i \in E \\ i=0, \dots, n}} \mathbb{P}_{\mu \otimes \nu} \left(\bigcap_{i=0}^n (\{X_i = x_i\} \cap \{Y_i = y_i\}) \right) \\
 &= \left(\mu(x_0) \prod_{i=1}^n p_{x_{i-1}, x_i} \right) \underbrace{\sum_{\substack{y_i \in E \\ i=0, \dots, n}} \left(\nu(y_0) \prod_{i=1}^n p_{y_{i-1}, y_i} \right)}_{=1} \\
 &= \left(\mu(x_0) \prod_{i=1}^n p_{x_{i-1}, x_i} \right).
 \end{aligned}$$

Analog folgt das Resultat für $(Y_n)_{n \in \mathbb{N}_0}$. □

Behauptung 5.12. Ist p irreduzibel, aperiodisch und positiv rekurrent, ist auch $\bar{p}$ irreduzibel, aperiodisch und positiv rekurrent.

Bemerkung 5.13. Es stimmt nicht, dass p irreduzibel impliziert, dass $\bar{p}$ irreduzibel. Betrachte zum Beispiel die Markov-Kette auf $E = \{0, 1\}$ mit Übergangsmatrix

$$\mathbf{P} = \begin{bmatrix} 0 & 1 \\ 1 & 0 \end{bmatrix}.$$

Diese Markov-Kette ist offensichtlich irreduzibel. Für den Produktraum ist die Kette aber nicht mehr irreduzibel, denn sie hat Kommunikationsklassen

$$\{(0, 0), (1, 1)\} \quad \text{und} \quad \{(1, 0), (0, 1)\}.$$

△

Beweis von Proposition 5.12. Wir zeigen nun, dass $\bar{p}$ aperiodisch ist. Aus Lemma 5.6 folgt die Existenz von $n, n' \in \mathbb{N}$ sodass

$$p_{x,y}^{(k)} > 0 \quad \text{für alle } k \geq n \quad \text{und} \quad p_{y,x}^{(k')} > 0 \quad \text{für alle } k' \geq n'.$$

Setzen wir $N := \max(n, n')$ folgt für $k \geq N$, dass

$$\bar{p}_{(x,y),(x',y')}^{(k)} = p_{x,y}^{(k)} p_{y,x}^{(k)} > 0.$$

Da x, x', y, y' arbiträr gewählt wurde, muss also $\bar{p}$ irreduzibel sein. Weiter folgt daraus

$$T(w) \supseteq \{n \in \mathbb{N} : n \geq N_{w,w}\}$$

und damit $\text{ggT}(T(w)) = 1$, weshalb $d_w = 1$. Somit ist $\bar{p}$ aperiodisch. Weiter ist für $w = (x, y)$

$$\begin{aligned} \pi^{\otimes 2}(w) &= \pi(x)\pi(y) \\ &= \sum_{x' \in E} \sum_{y' \in E} \pi(x')\pi(y')p_{y',x}p_{x',x} \\ &= \sum_{(x',y') \in E^2} \pi^{\otimes 2}((x', y')) \underbrace{p_{y',x}p_{x',x}}_{=\bar{p}_{(x',x),(y',y)}}. \end{aligned}$$

Das heisst $\pi^{\otimes 2}$ ist ein invariantes Mass für $\bar{p}$. Aus Theorem 4.49 schliessen wir dank der Irreduzibilität von $\bar{p}$, dass $\bar{p}$ positiv rekurrent ist. $\square$

Behauptung 5.14. Sei $T := \inf\{n \in \mathbb{N}_0 : X_n = Y_n\}$. Wir setzen

$$\tilde{X}_n := \begin{cases} X_n, & n \leq T \\ Y_n, & n > T \end{cases}$$

Dann ist $\tilde{X}$ eine Markov-Kette mit Startverteilung μ und Übergangswahrscheinlichkeiten $p = (p_{x,y})_{x,y \in E}$.

Beweis. T ist eine Stoppzeit, denn $T = H_A$ mit $A = \{(x, x) \mid x \in E\}$ (Hitting-Zeiten sind Stoppzeiten). Seien $x_i \in E$ für $i = 0, \dots, n$. Dann gilt für $n \leq k$

$$\begin{aligned} &\mathbb{P}_{\mu \otimes \nu} \left(\bigcap_{i=0}^n \{\tilde{X}_i = x_i\} \cap \{T = k\} \right) \\ &= \mathbb{P}_{\mu \otimes \nu} \left(T = k \mid \bigcap_{i=0}^n \{X_i = x_i\} \right) \mathbb{P}_{\mu \otimes \nu} \left(\bigcap_{i=0}^n \{X_i = x_i\} \right) \\ &= \mathbb{P}_{\mu \otimes \nu} \left(T = k \mid \bigcap_{i=0}^n \{X_i = x_i\} \right) \mu(x_0) \prod_{i=0}^{n-1} p_{x_i, x_{i+1}} \end{aligned}$$

und für $n > k$ bemerken wir, dass $\bigcap_{i=0}^k \{X_i = x_i\} \cap \{T = k\} \in \mathcal{F}_n$. Damit folgt aus der starken Markov-Eigenschaft (angewandt auf $\tilde{X}$)

$$\begin{aligned} &\mathbb{P}_{\mu \otimes \nu} \left(\bigcap_{i=0}^n \{\tilde{X}_i = x_i\} \cap \{T = k\} \right) \\ &= \mathbb{P}_{\mu \otimes \nu} \left(\bigcap_{i=0}^k \{X_i = x_i\} \cap \{T = k\} \right) \underbrace{\mathbb{P}_{x_k} \left(\bigcap_{i=1}^{n-k} \{Y_i = x_{k+i}\} \right)}_{=\delta_{x_k} \prod_{i=k}^{n-1} p_{x_i, x_{i+1}}} \\ &= \mathbb{P}_{\mu \otimes \nu} \left(T_k = k \mid \bigcap_{i=0}^k \{X_i = x_i\} \right) \mu(x_0) \prod_{i=0}^{n-1} p_{x_i, x_{i+1}}. \end{aligned}$$

Weiter gilt wegen der Unabhängigkeit von X und Y

$$\begin{aligned}\mathbb{P}_{\mu \otimes \nu} \left(T_k = k \mid \bigcap_{i=0}^k \{X_i = x_i\} \right) &= \mathbb{P}_{\mu \otimes \nu} (Y_0 \neq x_0, \dots, Y_{k-1} = x_k, Y_k = x_k) \\ &= \mathbb{P}_{\mu \otimes \nu} \left(T = k \mid \bigcap_{i=0}^n \{X_i = x_i\} \right).\end{aligned}$$

Nun ist aufgrund obiger Berechnungen

$$\begin{aligned}\mathbb{P}_{\mu \otimes \nu} \left(\bigcap_{i=0}^n \{\tilde{X}_i = x_i\} \right) &= \sum_{k \in \mathbb{N}_0 \cup \{+\infty\}} \mathbb{P}_{\mu \otimes \nu} \left(\bigcap_{i=0}^n \{\tilde{X}_i = x_i\} \cap \{T = k\} \right) \\ &= \mu(x_0) \prod_{i=0}^{n-1} p_{x_i, x_{i+1}} \underbrace{\sum_k \mathbb{P}_{\mu \otimes \nu} \left(T = k \mid \bigcap_{i=0}^n \{X_i = x_i\} \right)}_{=1}.\end{aligned}$$

Dies zeigt das Resultat. □

Wir können nun Theorem 5.8 zeigen:

Beweis von Theorem 5.8. Wir starten die Kette $W = (X, Y)$ von $\mu \otimes \pi$. Dann ist $\mathbb{P}_{\mu \otimes \pi}(Y_k = y) = \pi(y)$ für jedes $k \in \mathbb{N}_0$. Da X und $\tilde{X}$ die gleiche Verteilung haben, gilt

$$\begin{aligned}\mathbb{P}_\mu(X_k = y) &= \mathbb{P}_{\mu \otimes \pi}(\tilde{X}_k = y) = \mathbb{P}_{\mu \otimes \pi}(\tilde{X}_k = y, k \leq T) + \mathbb{P}_{\mu \otimes \pi}(\tilde{X}_k = y, k > T) \\ &= \mathbb{P}_\mu(X_k = y, k \leq T) + \mathbb{P}_\mu(Y_k = y, k > T)\end{aligned}$$

und weil π invariant ist,

$$\pi(y) = \mathbb{P}_{\mu \otimes \pi}(Y_k = y) = \mathbb{P}_{\mu \otimes \pi}(Y_k = y, k \leq T) + \mathbb{P}_{\mu \otimes \pi}(Y_k = y, k > T)$$

für beliebiges $k \in \mathbb{N}$. Dann ist

$$\begin{aligned}|\mathbb{P}_\mu(X_k = y) - \pi(y)| &\leq \mathbb{P}_\mu(X_k = y, k \leq T) + \mathbb{P}_\mu(Y_k = y, k \leq T) \\ &\leq 2\mathbb{P}_\mu(T \leq k)\end{aligned}$$

bilden wir den Grenzwert $k \rightarrow +\infty$ folgt

$$\lim_{k \rightarrow +\infty} |\mathbb{P}_\mu(X_k = y) - \pi(y)| \leq \lim_{k \rightarrow +\infty} \mathbb{P}_\mu(T \leq k) = \mathbb{P}_\mu(T = +\infty).$$

Aber da W positiv rekurrent und damit rekurrent ist, ist $\mathbb{P}_\mu(H_{(x,x)}^{(W)} = +\infty) = 0$ und daher $\mathbb{P}_\mu(T = +\infty) = 0$. □

5.3. Markov-Chain-Monte-Carlos*

Sei E ein grosser Zustandsraum, π ein Mass auf E . Das Ziel ist es, Zufallsvariablen von diesem Mass zu generieren, d.h. wir wollen eine Folge $X_1, X_2, X_3, \dots$ konstruieren sodass $X_i \sim \text{iid}(\pi)$ (Sampling of π).

Beispiel 5.15 (Colouring of a Graph). Sei $G = (V, \mathcal{E})$ ein Graph. Sei $Q = \{1, \dots, q\}$ (Wir nennen die Elemente von Q *Farben*). Wir wollen jedem Knoten eine Zahl (Farbe) aus Q zuordnen, sodass benachbarte Knoten nie die gleiche Zahl aus Q zugeteilt bekommen (alle Kanten sind zweifarbig). Wir betrachten nun

$$E := \{f : V \rightarrow Q : f(x) \neq f(y) \forall (x, y) \in \mathcal{E}\}$$

und fragen uns, wie E aussieht insbesondere für $|G|$ gross, bzw. was ist $|E|$? Das Ziel ist es nun X_i gleichverteilt auf E zu konstruieren. Dies wäre eine Anwendung der obigen Idee. $\triangle$

Die Idee ist nun eine Markov-Kette $Y = (Y_k)_{k \in \mathbb{N}_0}$ auf E zu konstruieren, sodass π eine invariante Verteilung dieser Kette ist und die Kette aperiodisch und irreduzibel ist. Haben wir so ein Y gefunden, wissen wir aus Theorem 5.8, dass dann

$$\mathbb{P}(Y_k = y) \approx \pi(y) \quad \text{für } k \text{ gross.} \quad (5.2)$$

Setzen wir nun $X_n = Y_{2k}$ sind X_i etwa gleichverteilt auf π . In der Praxis ist k gross genug zu wählen, sodass (5.2) genau genug ist, aber klein genug, um Rechenschritte zu vermeiden. Es ist deshalb nützlich, die Konvergenzgeschwindigkeit der linken Seite von (5.2) zu kennen.

Beispiel 5.16. Sei $G = (V, \mathcal{E})$ ein endlicher Graph und sei $f : Q \rightarrow V$. G modelliert ein Stück Metall mit Atomen. Die Energie ist dann gegeben durch

$$H(f) = \sum_{(x,y) \in \mathcal{E}} \varphi(f(x), f(y)), \quad \varphi : Q^2 \rightarrow \mathbb{R}.$$

Ist nun π eine Verteilung auf $\text{Abb}(V, Q)$

$$\pi(f) = \frac{1}{Z_T} \exp \left\{ -\frac{H(f)}{T} \right\}, \quad Z_T = \sum_{f \in \text{Abb}(V, Q)} \exp \left\{ -\frac{H(f)}{T} \right\}$$

wobei $T \in \mathbb{R}$ die Temperatur bezeichnet. Z_T ist aber schwierig zu berechnen in der Praxis, aber die Summe $H(f)$ ist einfacher berechenbar, da sie viel kürzer ist. Dies wird *Gibbs-Verteilung* genannt. Betrachte nun eine Übergangswahrscheinlichkeit

$$p_{f,f'} = \begin{cases} 0, & |\{x : f(x) \neq f'(x)\}| \geq 2 \\ \frac{1}{2}, & f = f' \\ \frac{1}{2} \min \left(1, \frac{\pi(f')}{\pi(f)} \right), & |\{x : f(x) \neq f'(x)\}| = 1 \end{cases}.$$

Übung 5.17. Zeigen Sie, dass π reversibel für p ist.

Es gilt dann

$$\frac{\pi(f')}{\pi(f)} = \exp \left\{ -\frac{H(f')}{T} + \frac{H(f)}{T} \right\}$$

was vergleichsweise einfach zu berechnen ist. $\triangle$

6. Standard-Poisson-Prozess

6.1. Einführung und Repetition

Motivation. Wir möchten unter anderem stochastische Prozesse in stetiger Zeit betrachten. Der Poisson-Prozess ist einer der einfachsten Modelle und es ist eine Markov-Kette in stetiger Zeit. Dieser Prozess wird oftmals in der „Queueing“-Theorie betrachtet.

Definition 6.1. Sei $\lambda > 0$. Eine Zufallsvariable T heisst **exponentialverteilt** mit Parameter λ (wir schreiben $T \sim \text{Exp}(\lambda)$) falls T die Dichte

$$f_T(t) = \lambda e^{-\lambda t} \mathbb{1}_{[0, +\infty)}(t)$$

besitzt. Die Verteilungsfunktion von T ist dann gegeben durch

$$\mathbb{P}(T \leq t) = \int_{-\infty}^t f_T(t) dt = \begin{cases} 1 - e^{-\lambda t} & t > 0 \\ 0 & t \leq 0 \end{cases} \quad (6.1)$$

für alle $t \in \mathbb{R}$.

Bemerkung 6.2. Aus (6.1) sehen wir, dass

$$\mathbb{P}(T \geq t) = \mathbb{P}(T > t) = e^{-\lambda t} \quad \text{für alle } t \geq 0$$

und falls obige Formel gilt, ist T auch exponentialverteilt. Wir werden diesen Fakt noch oft in diesem Kurs verwenden. $\triangle$

Lemma 6.3 (Gedächtnislosigkeit). Sei $\lambda > 0$ und $T \sim \text{Exp}(\lambda)$, dann gilt

$$\mathbb{P}(T \geq s + t \mid T \geq t) = \mathbb{P}(T \geq s) \quad \text{für alle } s, t \geq 0.$$

Beweis. Siehe Einführung in die Statistik oder Übung. $\square$

Bemerkung 6.4. Die Exponentialverteilung ist die einzige absolutstetige nicht-negative Verteilung mit der Eigenschaft Gedächtnislosigkeit. $\triangle$

Lemma 6.5 (Minima von Exponentialverteilungen). Sei $n \in \mathbb{N}$ und seien $T_1, \dots, T_n$ unabhängige Zufallsvariablen wo $T_i \sim \text{Exp}(\lambda_i)$ mit $\lambda_i > 0$ für $i = 1, \dots, n$. Dann gilt

1. Das Minimum von $T_1, \dots, T_n$ ist wieder exponentialverteilt mit

$$Z := \min_{i=1, \dots, n} T_i \sim \text{Exp} \left(\sum_{i=1}^n \lambda_i \right).$$

2. Es gilt für alle $i = 1, \dots, n$,

$$\mathbb{P}(T_i = Z) = \frac{\lambda_i}{\lambda_1 + \dots + \lambda_n}.$$

Beweis. Sei $t \geq 0$. Dann gilt

$$\begin{aligned} \mathbb{P}(Z \geq t) &= \mathbb{P}\left(\min_{i=1, \dots, n} T_i \geq t\right) = \mathbb{P}\left(\bigcap_{i=1}^n \{T_i \geq t\}\right) \\ &\stackrel{\text{Unabhängigkeit}}{=} \prod_{i=1}^n \mathbb{P}(T_i \geq t) = \prod_{i=1}^n e^{-\lambda_i t} = \exp\left\{-t \sum_{i=1}^n \lambda_i\right\}. \end{aligned}$$

was (1) zeigt. Zu (2) sei ohne Beschränkung der Allgemeinheit $i = 1$. Dann ist

$$\begin{aligned} \mathbb{P}(T_1 = Z) &= \mathbb{P}\left(\bigcap_{i=2}^n \{T_1 \leq T_i\}\right) = \int_0^{+\infty} \lambda_1 e^{-\lambda_1 t} \mathbb{P}\left(\bigcap_{i=2}^n \{T_i \geq t\}\right) dt \\ &\stackrel{\text{Unabhängigkeit}}{=} \int_0^{+\infty} \lambda_1 e^{-\lambda_1 t} \prod_{i=2}^n e^{-\lambda_i t} dt = \frac{\lambda_1}{\lambda_1 + \dots + \lambda_n}. \quad \square \end{aligned}$$

Lemma 6.6 (Summe der Exponentialverteilungen). Sei $\lambda > 0$ und $T_1, \dots, T_n$ unabhängige Zufallsvariablen mit $T_i \sim \text{Exp}(\lambda)$ für $i = 1, \dots, n$. Dann ist

$$S_n = T_1 + \dots + T_n \sim \Gamma(\lambda, t)$$

das heisst, S_n hat die Dichte

$$f_{S_n}(t) = \lambda e^{-\lambda t} \frac{(\lambda t)^{n-1}}{(n-1)!} \mathbb{1}_{t \geq 0}.$$

Beweis. Der Beweis erfolgt durch Induktion über $n \in \mathbb{N}$. Für $n = 1$ bemerken wir, dass $\text{Exp}(\lambda) = \Gamma(\lambda, 1)$. Um den Induktionsschritt $n \mapsto n+1$ zu vollziehen, nehmen wir an, dass die Behauptung für $n \in \mathbb{N}$ gilt. Dann gilt dank der Unabhängigkeit von $T_1, \dots, T_n$ dass S_{n-1} und T_n unabhängig sind. Somit gilt für $t \geq 0$

$$\begin{aligned} f_{S_n}(t) &= f_{S_{n-1}+T_n}(t) = (f_{S_{n-1}} \star T_n)(t) = \int_0^t f_{S_{n-1}}(s) f_{T_n}(t-s) ds \\ &= \int_0^t \lambda e^{-\lambda s} \frac{(\lambda s)^{n-1}}{(n-1)!} \cdot \lambda e^{-\lambda(t-s)} ds = \frac{\lambda e^{-\lambda t}}{(n-1)!} \int_0^t \lambda (\lambda s)^{n-1} ds \\ &= \lambda e^{-\lambda t} \frac{(\lambda t)^n}{n!} \mathbb{1}_{t \geq 0}. \end{aligned}$$

Für $t \leq 0$ sind beide Dichten ohnehin Null und damit

$$f_{S_n}(t) = f_{S_{n-1}+T_n}(t) = (f_{S_{n-1}} \star T_n)(t) = 0 \quad \text{für } t \leq 0.$$

Damit folgt das Resultat. □

Definition 6.7. Eine $\mathbb{N}_0$ -wertige Zufallsvariable N ist **Poisson-verteilt mit Parameter** $\lambda > 0$ falls

$$\mathbb{P}(N = k) = \frac{\lambda^k}{k!} e^{-\lambda} \quad \text{für alle } k \in \mathbb{N}_0$$

Lemma 6.8. Seien $\lambda_1, \dots, \lambda_n > 0$ und $N_1, \dots, N_n$ unabhängige Zufallsvariablen mit $N_i \sim \text{Pois}(\lambda_i)$ für $i = 1, \dots, n$. Dann ist

$$N_1 + \dots + N_n \sim \text{Pois}(\lambda_1 + \dots + \lambda_n).$$

Beweis. Der einfache Beweis verbleibt dem Leser zur Übung. □

Lemma 6.9. Sei $(T_i)_{i \in \mathbb{N}}$ eine Folge von unabhängigen Zufallsvariablen mit $T_i \sim \text{Pois}(\lambda)$ für alle $i \in \mathbb{N}$ mit $\lambda > 0$. Wir setzen für $t > 0$,

$$N := \max\{k \in \mathbb{N} : T_1 + \dots + T_k \leq t\} = \sum_{i=1}^{+\infty} \mathbb{1}_{S_i \leq t}.$$

Dann ist $N \sim \text{Pois}(\lambda t)$.

Beweis. Wir schreiben $S_i := T_1 + \dots + T_i$ und bemerken, dass aus der Unabhängigkeit der T_i s folgt, dass T_{k+1} und S_k unabhängig sind. Dann

$$\begin{aligned} \mathbb{P}(N = k) &= \mathbb{P}(S_k \leq t, S_{k+1} > t) = \mathbb{P}(S_k \leq t, T_{k+1} > t - S_k) \\ &= \int_0^t f_{S_k}(s) \mathbb{P}(T_{k+1} \geq t - s) \, ds = \int_0^t \lambda e^{-\lambda s} \frac{(\lambda s)^{k-1}}{(k-1)!} e^{-\lambda(t-s)} \, ds \\ &= \frac{(\lambda t)^k}{k!} e^{-\lambda t}. \end{aligned} \quad \square$$

6.2. Definition des Poisson-Prozesses

Wir werden im Folgenden $\lambda > 0$ und $T_1, T_2, \dots$ unabhängige exponentialverteilte Zufallsvariablen arbeiten die $T_i \sim \text{Exp}(\lambda)$ für alle $i \in \mathbb{N}$ erfüllen. Wir setzen

$$S_n = T_1 + \dots + T_n.$$

Definition 6.10. Der stochastische Prozess $(N_t)_{t \in [0, +\infty)}$ definiert durch

$$N_t := \max\{k \in \mathbb{N} : S_k \leq t\} = \sum_{i=1}^{+\infty} \mathbb{1}_{S_i \leq t}$$

heisst Poisson-Prozess mit Intensität λ . Wir schreiben dann für den Prozess $N = (N_t)_{t \in \mathbb{R}_{\geq 0}} \sim \text{PP}(\lambda)$. Wir nennen die S_i s **Sprungzeiten** des Prozesses und die T_i s heissen **Zwischenankunftszeiten** (Inter arrival times).

Bemerkung 6.11. Die Funktion $t \mapsto N_t$ ist immer rechtsstetig und $N_t \sim \text{Pois}(\lambda t)$ für alle $t > 0$, siehe Lemma 6.9. △

Wir werden zeigen, dass der Poisson-Prozess die Markov-Eigenschaft hat.

Notation 6.12. Sei $t > 0$ und definiere

$$N_s^{(t)} := N_{t+s} - N_t$$

und schreiben $N^{(t)} := (N_s^{(t)})_{s \in \mathbb{R}_{\geq 0}}$, was auch wieder ein stochastischer Prozess ist.

Satz 6.13. Sei $t > 0$ dann ist $N^{(t)} \sim \text{PP}(\lambda)$ unabhängig von $(N_a)_{a \in [0, t]}$. Das heisst, es existieren $\tau_1, \tau_2, \dots \sim \text{Exp}(\lambda)$ unabhängig sodass

$$N_s^{(t)} = \sum_{i=1}^{+\infty} \mathbb{1}_{\tau_1 + \dots + \tau_i \leq s}$$

und für alle $n, \ell \geq 1$, $u_i \in [0, t]$ für $i = 1, \dots, n$ und $s_j \geq 0$ für $j = 1, \dots, \ell$ sind

$$(N_{u_i})_{i=1}^n \quad \text{und} \quad (N_{s_j}^{(t)})_{j=1}^\ell$$

unabhängig.

Beweis. Seien

$$\tau_1 = S_{N_t+1} - t, \quad \tau_i = T_{N_t+i} \quad \text{für alle } i \geq 2.$$

Schritt 1: $\tau_i \stackrel{i.i.d.}{\sim} \text{Exp}(\lambda)$, unabhängig von N_t . Sei $s \geq 0$, $n \geq 1$. Dann ist

$$\begin{aligned} \mathbb{P}(N_t = n, \tau_1 \geq s) &= \mathbb{P}(S_n \leq t, S_{n+1} > t, S_{n+1} \geq t + s) \\ &= \mathbb{P}(S_n \leq t, S_n + T_{n+1} \geq t + s) \\ &= \int_0^t f_{S_n}(u) \mathbb{P}(T_{n+1} \geq t + s - u) du \\ &\stackrel{\text{Unabh.}}{=} e^{-\lambda s} \int_0^t f_{S_n}(u) \mathbb{P}(T_{n+1} \geq t - u) du = e^{-\lambda s} \mathbb{P}(N_t = n). \end{aligned}$$

damit ist τ_1 unabhängig von N_t . Weiter schreiben wir für $n, i \geq 0$, $s_1, \dots, s_i > 0$,

$$\mathbb{P}(N_t = n, \tau_1 \geq s_1, \dots, \tau_i \geq s_i) = \mathbb{P}(N_t = n, \tau_1 \geq 1, T_{n+2} \geq s_2, \dots, T_{n+i} \geq s_i).$$

Da $\{N_t = n, \tau_1 \geq 1\}$ nur abhängig von $T_1, \dots, T_{n+1}$ und $\{T_{n+2} \geq s_2, \dots, T_{n+i} \geq s_i\}$ nur von $T_{n+2}, \dots, T_{n+i}$ abhängt, folgt aus der Unabhängigkeit der T_i s, dass

$$\mathbb{P}(N_t = n, \tau_1 \geq s_1, \dots, \tau_i \geq s_i) = \mathbb{P}(N_t = n, \tau_1 \geq 1) \mathbb{P}(T_{n+2} \geq s_2, \dots, T_{n+i} \geq s_i)$$

Aus Berechnungen für τ_1 können wir also schliessen, dass

$$\mathbb{P}(N_t = n, \tau_1 \geq s_1, \dots, \tau_i \geq s_i) = \mathbb{P}(N_t = n) \mathbb{P}(\tau_1 \geq s_1) \underbrace{\prod_{j=2}^i \mathbb{P}(T_{n+j} \geq s_j)}_{= e^{-\lambda s_j}}.$$

Der Rest des Beweises verbleibt dem Leser zur Übung :)

□

Definition 6.14. Sei $(X_t)_{t \in \mathbb{R}_{\geq 0}}$ ein stochastischer Prozess. Der Prozess hat

- **unabhängige Zuwächse**, falls für jedes $k \in \mathbb{N}$ und $0 = t_0 < t_1 < \dots < t_k$,

$$X_{t_1} - X_{t_0}, X_{t_2} - X_{t_1}, \dots, X_{t_k} - X_{t_{k-1}}$$

unabhängig sind.

- **stationäre Zuwächse**, falls für jedes $k \in \mathbb{N}$, $0 = t_0 < t_1 < \dots < t_k$ und $h > 0$,

$$(X_{t_{i+1}} - X_{t_i})_{i=1}^k \stackrel{d}{=} (X_{t_i+h} - X_{t_{i-1}+h})_{i=1}^k.$$

Weiter nennen wir $(X_t)_{t \in \mathbb{R}_{\geq 0}}$ **Zählprozess**, falls dieser Prozess $\mathbb{N}_0$ -wertig ist und $t \mapsto X_t(\omega)$ ist rechtsstetig und nicht fallend für fast alle $\omega \in \Omega$. Wir definieren dann die **Sprungzeiten** als $S_0 := 0$ und ??

$$S_k := \inf\{t > S_{k-1} : X_t > X_{S_{k-1}}\} \quad \text{für alle } k \in \mathbb{N}.$$

6.3. Charakterisierung von Poisson-Prozessen

Satz 6.15. Sei $\lambda > 0$ und sei $N = (N_t)_{t \in \mathbb{R}_{\geq 0}}$ ein Zählprozess mit Sprunghöhen gleich 1, der von null startet, d.h., $N_0 = 0$. Dann sind die folgenden Aussagen äquivalent:

1. N ist ein Poisson-Prozess mit Intensität λ .
2. N hat unabhängige und stationäre Zuwächse und für $t \searrow 0$,

$$\mathbb{P}(N_t = 1) = \lambda t + o(t), \quad \mathbb{P}(N_t \geq 2) = o(t).$$

3. N hat unabhängige und stationäre Zuwächse und $N_t \sim \text{Pois}(\lambda t)$.
4. Für alle $t > 0$ ist $N_t \sim \text{Pois}(\lambda t)$ und für alle $k \in \mathbb{N}$, bedingt auf $N_t = k$ sind die Sprungzeiten $S_1, \dots, S_k$ verteilt wie eine geordnete Folge von k i.i.d. Zufallsvariablen, die Uniform auf $[0, t]$ verteilt sind d.h. der Vektor $(S_1, \dots, S_k)$ hat die Dichte

$$f_{(S_1, \dots, S_k) | N_t = k}(s_1, \dots, s_k) = \frac{k!}{t^k} \mathbb{1}_{0 < s_1 < \dots < s_k < t}$$

auf $\mathbb{R}^k$.

Bemerkung 6.16. Von (3) folgt, dass für alle $k \in \mathbb{N}$, $0 = t_0 < t_1 < \dots < t_k$, $n_i \in \mathbb{N}$ für $i = 1, \dots, k$

$$\begin{aligned} \mathbb{P} \left(\bigcap_{i=1}^k \{N_{t_i} - N_{t_{i-1}} = n_i\} \right) &\stackrel{\text{Unabhängigkeit}}{=} \prod_{i=1}^k \mathbb{P}(N_{t_i} - N_{t_{i-1}} = n_i) \\ &\stackrel{\text{stationär}}{=} \prod_{i=1}^k \frac{\lambda^{n_i} (t_i - t_{i-1})^{n_i}}{n_i!} e^{-\lambda(t_i - t_{i-1})}. \end{aligned}$$

△

Beweis von Theorem 6.15. “(3) $\Rightarrow$ (2)“: Ist $N_t \sim \text{Pois}(\lambda t)$ folgt

$$\mathbb{P}(N_t = 1) = \frac{(\lambda t)^1}{1!} e^{-\lambda t} = \lambda t (1 - \lambda t + o(t)) = \lambda t + o(t), \quad \text{für } t \searrow 0$$

und

$$\begin{aligned} \mathbb{P}(N_t \geq 2) &= 1 - \mathbb{P}(N_t = 0) - \mathbb{P}(N_t = 1) \\ &= 1 - e^{-\lambda t} - (\lambda t + o(t)) = o(t) \quad \text{für } t \searrow 0. \end{aligned}$$

“(2) $\Rightarrow$ (3)“: Wir definieren die Zufallsvariable

$$M_{n,t} := \sum_{i=1}^n \mathbb{1}\left\{ \underbrace{N_{\frac{ti}{n}} - N_{\frac{t(i-1)}{n}}}_{\text{Zuwachs über } i\text{-tem Teilintervall}} \geq 1 \right\}. \quad (6.2)$$

Nun ist jeder Summand in (6.2) bernoulliverteilt mit Parameter $p_n = \mathbb{P}\left(N_{\frac{t}{n}} = 1\right)$. Weiter sind die Summanden unabhängig, daher ist $M_{n,t} \sim \text{Bin}(n, p_n)$ und damit folgt

$$p_n = \lambda \frac{t}{n} + o\left(\frac{t}{n}\right) \quad \text{für } n \rightarrow +\infty.$$

Damit folgt aus Einführung in die Statistik (Approximation der Poissonverteilung durch Binominalverteilung), dass

$$\lim_{n \rightarrow +\infty} \mathbb{P}(M_{n,t} = k) = \frac{(\lambda t)^k}{k!} e^{-\lambda t}.$$

Wegen

$$\begin{aligned} \mathbb{P}(N_t \neq M_{n,t}) &= \mathbb{P}\left(\bigcup_{i=1}^n \left\{ N_{\frac{ti}{n}} - N_{\frac{t(i-1)}{n}} \geq 2 \right\}\right) \\ &\leq \sum_{i=1}^n \mathbb{P}\left(N_{\frac{ti}{n}} - N_{\frac{t(i-1)}{n}} \geq 2\right) \\ &= \sum_{i=1}^n o\left(\frac{t}{n}\right) = n \cdot o\left(\frac{t}{n}\right) \quad \text{für } n \rightarrow +\infty \end{aligned}$$

folgt $\mathbb{P}(N_t \neq M_{n,t}) \rightarrow 0$ für $n \rightarrow +\infty$ und somit

$$\lim_{n \rightarrow +\infty} \mathbb{P}(N_t = k) = \frac{(\lambda t)^k}{k!} e^{-\lambda t}.$$

“(3) $\Rightarrow$ (1)“: Wir setzen $T_i := S_i - S_{i-1}$ für $i \in \mathbb{N}$ und zeigen, dass die T_i unabhängig und $T_i \sim \text{Exp}(\lambda)$. Betrachten wir T_1 , sehen wir, dass

$$\mathbb{P}(T_1 > t) = \mathbb{P}(S_1 > t) = \mathbb{P}(N_t = 0) \stackrel{(3)}{=} \frac{(\lambda t)^0}{0!} e^{-\lambda t}$$

und für $s_1 < t_1 < s_2 < t_2$ ist

$$\begin{aligned} \mathbb{P}(s_1 < S_1 \leq t_1, s_2 < S_2 \leq t_2) &= \mathbb{P}(N_{s_1} = 0, N_{t_1} - N_{s_1} = 1, N_{s_2} - N_{t_1} = 0, N_{t_2} - N_{s_2} \geq 1) \\ &\stackrel{(3)}{=} e^{-\lambda s_1} \cdot \frac{\lambda(t_1 - s_1)}{1!} e^{-\lambda(t_1 - s_1)} \cdot e^{-\lambda(s_2 - t_1)} (1 - e^{-\lambda(t_2 - s_2)}) \\ &= \lambda(t_1 - s_1)(e^{-\lambda s_2} - e^{-\lambda s_1}) \\ &= \int_{s_1}^{t_1} \int_{s_2}^{t_2} \lambda^2 e^{-\lambda y_2} dy_2 dy_1 \end{aligned}$$

und wir haben damit die Dichte des Zufallsvektors (S_1, S_2) gefunden mit

$$f_{(S_1, S_2)}(y_1, y_2) = \lambda^2 e^{-\lambda y_2} \mathbb{1}_{0 \leq y_1 < y_2}(y_1, y_2).$$

Analog zeigt man, dass $(S_1, \dots, S_k)$ die Dichte

$$f_{(S_1, \dots, S_k)} \lambda^k e^{-\lambda y_k} (S_1, \dots, S_k) \mathbb{1}_{0 \leq y_1 < \dots < y_k}$$

hat. Setzen wir

$$\varphi_k : \mathbb{R}^k \rightarrow \mathbb{R}^k, \quad (y_1, y_2 - y_1, \dots, y_k - y_{k-1})$$

sehen wir, dass

$$\varphi_k(S_1, \dots, S_k) = (T_1, \dots, T_k).$$

Weiterhin ist φ_k bijektiv und differenzierbar, daher folgt nach Theorem A.4, dass

$$f_{(T_1, \dots, T_k)}(x_1, \dots, x_k) = \lambda^k e^{-\lambda(x_1 + \dots + x_k)} \mathbb{1}_{x_1 \geq 0, \dots, x_k \geq 0} = \prod_{i=1}^k \lambda e^{-\lambda x_i} \mathbb{1}_{x_i \geq 0},$$

da $\det \mathbf{J}_{\varphi^{-1}} = 1$ an jedem Punkt. Damit sind die $T_i \sim \text{Exp}(\lambda)$.

„(1) $\Rightarrow$ (3)“: Wir zeigen, dass für jedes $k \geq 1$ und $0 = t_0 < t_1 < \dots < t_k$, $n_i \in \mathbb{N}_0$ für $i = 1, \dots, k$,

$$\mathbb{P}(N_{t_1} - N_{t_0}, \dots, N_{t_k} - N_{t_{k-1}}) = \prod_{i=1}^k \frac{(\lambda(t_i - t_{i-1}))^{n_i}}{n_i!} e^{-\lambda(t_i - t_{i-1})}. \quad (6.3)$$

Die Unabhängigkeit der Inkremente folgt dann direkt aus (6.3), die Stationarität auch mit ein wenig mehr Arbeit (siehe Übungen) und $N_t \sim \text{Pois}(\lambda t)$ folgt dann aus $k = 1$. Wir zeigen also (6.3) durch Induktion:

Sei $k = 1$. Dann ist

$$N_{t_1} - N_{t_0} = N_{t_1} - N_0 = N_{t_1} \sim \text{Pois}(\lambda(t_1 - t_0)).$$

Um den Induktionsschritt $k \mapsto k + 1$ zu vollziehen, nehmen wir an, dass die Behauptung für ein $k \in \mathbb{N}$ stimmt und nehmen $0 = t_0 < t_1 < \dots < t_{k+1}$, $n_i \in \mathbb{N}_0$ für $i = 1, \dots, k + 1$ und bemerken, dass

$$\bigcap_{i=1}^k \{N_{t_i} - N_{t_{i-1}} = n_i\} \in \sigma((N_s)_{s \in [0, t_k]}) \quad \text{und} \quad N_{t_{k+1}} - N_{t_k} = N_{t_{k+1} - t_k}^{(t_k)}$$

unabhängig sind und damit folgt aus der Markov-Eigenschaft, dass

$$\begin{aligned} \mathbb{P} \left(\bigcap_{i=1}^{k+1} \{N_{t_i} - N_{t_{i-1}} = n_i\} \right) &= \mathbb{P} \left(\bigcap_{i=1}^k \{N_{t_i} - N_{t_{i-1}} = n_i\} \right) \mathbb{P}(N_{t_{k+1}-t_k} = n_{k+1}) \\ &\stackrel{\text{Ind}}{=} \left(\prod_{i=1}^k \frac{(\lambda(t_i - t_{i-1}))^{n_i}}{n_i!} e^{-\lambda(t_i - t_{i-1})} \right) \mathbb{P}(N_{t_{k+1}-t_k} = n_{k+1}) \\ &= \prod_{i=1}^{k+1} \frac{(\lambda(t_i - t_{i-1}))^{n_i}}{n_i!} e^{-\lambda(t_i - t_{i-1})}. \end{aligned}$$

“(1) $\Rightarrow$ (4)“: Nach Lemma 6.9 folgt aus (1), dass $N_t \sim \text{Pois}(\lambda t)$. Aus dem Beweis der Implikation (3) $\Rightarrow$ (1) folgt, dass $(S_1, \dots, S_{k+1})$ die Dichte

$$f_{(S_1, \dots, S_k)}(y_1, \dots, y_{k+1}) = \lambda^{k+1} e^{-\lambda y_{k+1}} (S_1, \dots, S_k) \mathbb{1}_{0 \leq y_1 < \dots < y_k}$$

hat, daher ist die Dichte von $(S_1, \dots, S_{k+1})$ gegeben $N_t = k$

$$f_{(S_1, \dots, S_{k+1})|N_t=t}(y_1, \dots, y_{k+1}) = \frac{\lambda^{k+1}}{\mathbb{P}(N_t = k)} e^{-\lambda S_{k+1}} \mathbb{1}_{0 < S_1 < \dots < S_k \leq t} \mathbb{1}_{S_t \leq t < S_{k+1}}.$$

Die Dichte von $(S_1, \dots, S_k)$ gegeben $N_{t=k}$ erhalten wir dann, indem wir s_{k+1} herausintegrieren:

$$\begin{aligned} f_{(S_1, \dots, S_k)|N_t=t}(y_1, \dots, y_k) &= \int_{\mathbb{R}} f_{(S_1, \dots, S_{k+1})|N_t=t}(y_1, \dots, y_{k+1}) dy_{k+1} \\ &= \lambda^{k+1} \frac{1}{\frac{(\lambda t)^k}{k!} e^{-\lambda t}} \mathbb{1}_{0 < s_1 < \dots < s_k \leq t} \int_{\mathbb{R}} e^{-\lambda y_{k+1}} \mathbb{1}_{t < y_{k+1}} dy_{k+1} \\ &= \lambda^{k+1} \frac{1}{\frac{(\lambda t)^k}{k!} e^{-\lambda t}} \mathbb{1}_{0 < s_1 < \dots < s_k \leq t} \int_t^{+\infty} e^{-\lambda y_{k+1}} dy_{k+1} \\ &= \frac{k!}{t^k} \mathbb{1}_{0 < s_1 < \dots < s_k \leq t}(y_1, \dots, y_k). \end{aligned}$$

Dies zeigt die behauptete Implikation.

„(4) $\Rightarrow$ (3)“: Es reicht zu zeigen, dass (4) impliziert, dass

$$(N_t)_t \quad \text{hat unabhängige und stationäre Zuwächse.} \quad (6.4)$$

Seien $0 = t_0 < t_1 < \dots < t_n = t$, $k \in \mathbb{N}_0$, $j_1, \dots, j_n \in \mathbb{N}_0$ mit $\sum_{i=1}^n j_i = k$ und seien $(U_i)_{i \in \mathbb{N}} \sim \text{Unif}([0, T])$. Dann

$$\begin{aligned} \mathbb{P} \left(\bigcap_{i=1}^n \{N_{t_i} - N_{t_{i-1}} = j_i\} \mid N_t = k \right) &\stackrel{(4)}{=} \mathbb{P} \left(\bigcap_{i=1}^n \left\{ \sum_{\ell=1}^k \mathbb{1}_{U_\ell \in (t_{i-1}, t_i]} = j_i \right\} \right) \\ &= \frac{k!}{j_1! \dots j_n!} \cdot \prod_{i=1}^n \left(\frac{t_i - t_{i-1}}{t} \right)^{j_i} \end{aligned}$$

Damit folgt also $(N_{t_i} - N_{t_{i-1}})_{i=1}^n$ gegeben $N_t = t$ multinomial mit Parametern k , $\frac{t_i - t_{i-1}}{t}$ für $i = 1, \dots, n$ verteilt ist. Weil $N_t \sim \text{Pois}(\lambda t)$ folgt mit Lemma 6.17, dass

$$(N_{t_i} - N_{t_{i-1}})_{i=1}^n \quad \text{sind unabhängig und} \quad N_{t_i} - N_{t_{i-1}} \sim \text{Pois}(\lambda(t_i - t_{i-1})).$$

Daraus folgt (6.4). Dies vollendet den Beweis. $\square$

Lemma 6.17. Seien $\lambda_1, \dots, \lambda_n > 0$ und $\lambda := \lambda_1 + \dots + \lambda_n$ und $p_i = \frac{\lambda_i}{\lambda}$. Für $\mathbb{N}_0$ -wertige Zufallsvariablen $Z_1, \dots, Z_n$ und $S_n := \sum_{i=1}^n Z_i$ sind folgende Bedingungen äquivalent:

1. $Z_1, \dots, Z_n$ sind unabhängig und für alle i ist $Z_i \sim \text{Pois}(\lambda_i)$
2. $S_n \sim \text{Pois}(\lambda)$ und für alle $k \in \mathbb{N}_0$ bedingt auf $S_n = k$ ist

$$(Z_1, \dots, Z_n) \sim \text{Multinomial}(k; p_1, \dots, p_n).$$

Beweis. „(1) $\Rightarrow$ (2)“: siehe Übungen

„(2) $\Rightarrow$ (1)“: Für alle $j_1, \dots, j_n \in \mathbb{N}_0$ gilt

$$\begin{aligned} \mathbb{P}\left(\bigcap_{i=1}^n \{Z_i = j_i\}\right) &= \sum_{k=0}^{+\infty} \mathbb{P}\left(\bigcap_{i=1}^n \{Z_i = j_i\} \mid S_n = k\right) \mathbb{P}(S_n = k) \\ &\stackrel{(2)}{=} \sum_{k=0}^{+\infty} \mathbb{1}_{j_1+\dots+j_n=k} \cdot \frac{k!}{j_1! \dots j_n!} p_1^{j_1} \dots p_n^{j_n} e^{-\lambda} \frac{\lambda^k}{k!} \\ &= \sum_{k=0}^{+\infty} \mathbb{1}_{j_1+\dots+j_n=k} \left(\prod_{i=1}^n \frac{\lambda_i^{j_i}}{j_i!}\right) \exp\left\{-\sum_{\ell=1}^n \lambda_\ell\right\} \\ &= \left(\prod_{i=1}^n \frac{\lambda_i^{j_i}}{j_i!} e^{-\lambda_i}\right) = \prod_{i=1}^n \mathbb{P}(Z_i = j_i), \end{aligned}$$

dies zeigt das Resultat. □

6.4. Stationäre Poisson-Prozesse

Wir definieren jetzt einen Poisson-Prozess auf ganz $\mathbb{R}$. Seien dazu $(N_t^+)_{t \in \mathbb{R}_+}$ und $(N_t^-)_{t \in \mathbb{R}_+}$ unabhängige Poisson-Prozesse mit Intensität $\lambda > 0$. Wir bezeichnen die Sprungzeiten von N^+ und N^- jeweils mit S_i^+ und S_i^- . Wir setzen nun

$$S_k := \begin{cases} S_k^+ & k \geq 1 \\ -S_{|k|+1}^- & k \leq 0 \end{cases}.$$

Bemerkung 6.18. Die Verteilung von $(S_i)_{i \in \mathbb{Z}}$ ist bestimmt durch

$$S_1, S_2 - S_1, S_3 - S_2, \dots \quad S_0, S_0 - S_{-1}, S_{-2} - S_{-3}, \dots$$

welche wieder gleichteilte und unabhängige Zufallsvariablen sind. Hier spielt die Null eine spezielle Rolle, da $S_0 < 0 < S_1$. △

Wir betrachten nun $t > 0$ ($t < 0$ ist ähnlich) und schauen uns den ganzen Prozess von t aus an, das heisst wir setzen für $t > 0$ fixiert

$$\tilde{S}_k := S_{N_t+k} - t.$$

Wir erhalten nun den folgenden Satz:

Satz 6.19 (Stationarität). Der Prozess $(\tilde{S}_k)_{k \in \mathbb{Z}}$ hat die gleiche Verteilung wie $(S_k)_{k \in \mathbb{Z}}$.

Beweis. Sei

$$N_{u-}^+ := \lim_{s \nearrow u} N_s^+, \quad \tilde{N}_s^+ := N_{t+s}^+ - N_t^+, \quad \tilde{N}_s^- := \begin{cases} N_t^+ - N_{(t-s)-}^+, & 0 \leq s < t \\ N_t^+ + N_{s-t}^-, & s \geq t \end{cases} \quad (6.5)$$

wobei N_{u-}^+ gleich N_u^+ ist, falls in u kein Sprung ist. Bemerke, dass $\tilde{N}_0^+ \equiv 0$ aber $\tilde{N}_0^-$ kann 1 sein, falls $t \in \{S_k\}_{k \in \mathbb{N}}$, was aber mit Wahrscheinlichkeit 0 passiert und wir diesen Fall somit getrost ignorieren können. Die Sprünge von $\tilde{N}^+$ sind genau $(\tilde{S}_k)_{k \geq 1}$ und die Sprünge von $\tilde{N}^-$ sind genau $(\tilde{S}_{1-k})_{k \geq 1}$ (da $t > 0$). Aus (6.5) und dem Fakt, dass N^+ und N^- unabhängig mit stationären Zuwächsen sind, folgt auch, dass $\tilde{N}^+$ und $\tilde{N}^-$ die gleichen Eigenschaften haben.

Weiter sind $\tilde{N}_s^+, \tilde{N}_s^- \sim \text{Pois}(\lambda s)$ wegen (6.5). Damit impliziert Theorem 6.15, dass $(\tilde{N}_s^+)_{s \geq 0}$ und $(\tilde{N}_s^- \mathbf{1}_{\tilde{N}_0^- = 0})_{s \geq 0}$ sind unabhängige Poisson-Prozesse mit Intensität $\lambda > 0$. Zusammen mit den Eigenschaften der Sprünge folgt dann das Behauptete. $\square$

6.5. Verzweigungsprozesse

Verzweigungsprozesse sind wichtige Werkzeuge in der Modellierung von Populationen.

Definition 6.20 (Galton-Watson-Prozess). Sei Z_0 eine $\mathbb{N}_0$ -wertige Zufallsvariable und $(X_{n,k})_{n \in \mathbb{N}_0, k \in \mathbb{N}}$ eine Familie von unabhängigen, gleichverteilten Zufallsvariablen, wobei

$$p_j = \mathbb{P}(X_{0,1} = j) \quad j \in \mathbb{N}_0$$

mit p_j gegeben. Der **Galton-Watson-Prozess** mit Start Z_0 und **Nachkommensverteilung** $(p_j)_{j \in \mathbb{N}_0}$ ist eine Markov-Kette $(Z_n)_{n \in \mathbb{N}_0}$, definiert durch

$$Z_{n+1} = \sum_{k=1}^{Z_n} X_{n,k}, \quad n \in \mathbb{N}_0.$$

Bemerkung 6.21. $X_{n,k}$ modelliert die Anzahl Kinder des k -ten Individuums in der n -ten Generation. Z_{n+1} modelliert dann die Anzahl Leute in der Generation $n+1$, also die Gesamtanzahl der Kinder der Generation n . Beim Schritt von Generation n zu $n+1$ erzeugt also jedes Individuum unabhängig von allen anderen $X_{n,k}$ Kinder, die ihr Elternteil ersetzen. $\triangle$

Notation 6.22. Wir werden im Folgenden nachstehende Notation verwenden:

$$m := \mathbb{E}[X_{0,1}], \quad \sigma^2 := \text{Var}(X_{0,1}).$$

Der Prozess ist deterministisch, falls wir ein j finden, mit $p_j = 1$. Oder ist $p_0 + p_1 = 1$ mit $p_0, p_1 \in (0, 1)$ stirbt die Population mit Wahrscheinlichkeit 1 in geometrischer verteilter Zeit aus. Aus diesem Grund nehmen wir im Folgenden an, dass

$$p_j \neq 1 \quad \text{für alle } j \quad \text{und} \quad p_0 + p_1 < 1. \quad (6.6)$$

Bemerkung 6.23 (Additivität). Aufgrund der Unabhängigkeit ist

$$Z_n = \sum_{j=1}^{Z_0} Z_n(j),$$

wobei $Z_n(j)$ die Nachkommen des j -ten Individuums aus der 0-ten Generation in der n -ten Generation sind. Damit ist Z_n eine Summe von Z_0 unabhängigen, identisch verteilten Zufallsvariablen, die jeweils von 1 gestartet sind. Im Folgenden nehmen wir deshalb an, dass

$$Z_0 \equiv 0.$$

△

Ein wichtiges Werkzeug, um diese Prozesse zu studieren sind die *Erzeugendenfunktionen*. Wir hatten diese für X eine $\mathbb{N}_0$ -wertige Zufallsvariable definiert durch:

$$g_X(t) = \mathbb{E}[t^X] = \sum_{k=0}^{+\infty} t^k \mathbb{P}(X = k) \quad t \in [0, 1].$$

Es lässt sich einfach beweisen, dass

$$\mathbb{E}[X] = \dot{g}_X(1) \quad \text{und} \quad \text{Var}(X) = \ddot{g}_X(1) + \dot{g}_X(1) - (\dot{g}_X(1))^2,$$

wobei die Gleichheiten gelten, sobald eine Seite endlich ist.

Lemma 6.24. Seien $X_1, X_2, \dots$ unabhängige gleichverteilte $\mathbb{N}_0$ -wertige Zufallsvariablen mit Erzeugendenfunktion g_X und sei Y eine $\mathbb{N}_0$ -wertige Zufallsvariable, unabhängig von $(X_i)_{i \in \mathbb{N}}$ mit Erzeugendenfunktion g_Y . Für die Zufallsvariable

$$S := \sum_{i=1}^Y X_i$$

gilt nun:

1. $g_S = g_Y \circ g_X$ auf $[0, 1]$,
2. $\mathbb{E}[S] = \mathbb{E}[Y]\mathbb{E}[X_1]$ und
3. $\text{Var}(S) = \text{Var}(X_1)\mathbb{E}[Y_1] + \mathbb{E}[X_1]^2 \text{Var}(Y)$.

Beweis. 1. Es gilt für $t \in [0, 1]$

$$\begin{aligned} g_S(t) &= \mathbb{E} \left[\exp \left\{ \log(t) \sum_{i=1}^Y X_i \right\} \right] = \sum_{k=1}^{+\infty} \mathbb{E} \left[\exp \left\{ \log(t) \sum_{i=1}^k X_i \right\} \mathbf{1}_{Y=k} \right] \\ &\stackrel{\text{Unabh.}}{=} \sum_{k=1}^{+\infty} \mathbb{E} \left[\exp \left\{ \log(t) \sum_{i=1}^k X_i \right\} \right] \mathbb{P}(Y = k) \\ &\stackrel{\text{Unabh.}}{=} \sum_{k=1}^{+\infty} \left(\prod_{i=1}^k \mathbb{E}[t^{X_i}] \right) \mathbb{P}(Y = k) = \sum_{k=0}^{+\infty} g_X(t)^k \mathbb{P}(Y = k) = g_Y \circ g_X(t) \end{aligned}$$

2. Wir differenzieren die Gleichung aus (1) und sehen, dass

$$\frac{d}{dt}g_S(t) = \frac{d}{dt}v(g_Y \circ g_X(t)) = \dot{g}_Y \circ g_X(t) \cdot \dot{g}_X(t).$$

Lassen wir $t \nearrow 1$ in den obigen Ausdrücken, ergibt sich die Formel.

3. Analog zeigt man die Formel für die Varianz. $\square$

Nun wollen wir die Frage beantworten, ob der Prozess irgendwann ausstirbt. Wir betrachten daher die Erzeugendenfunktion von Z_n und setzen dazu

$$g_n(t) := \mathbb{E}[t^{Z_n}] \quad \text{und} \quad g(t) := g_1(t) := g_{X_{0,1}}(t)$$

Mit Lemma 6.24 sehen wir $g_n = g \circ g_{n-1}$,

$$\mathbb{E}[Z_n] = \mathbb{E}[Z_{n-1}] \cdot m \quad \text{und} \quad \mathbb{E}[Z_n] = \sigma^2 \mathbb{E}[Z_{n-1}] + m^2 \cdot \text{Var}(Z_{n-1}).$$

Dies motiviert folgenden Satz:

Satz 6.25. Wenn $Z_0 \equiv 1$, dann ist die Erzeugendenfunktion von Z_n gegeben durch

$$g_n(t) = g^{\circ n}(t) := \underbrace{g \circ \cdots \circ g}_{n \text{ mal}}(t) \quad \text{für alle } t$$

und es gilt

$$\mathbb{E}[Z_n] = m^n, \quad \text{Var}(Z_n) = \begin{cases} \frac{\sigma^2 m^{n-1}(m^n - 1)}{m - 1} & m \neq 1 \\ n\sigma^2 & m = 1 \end{cases}$$

Beweis. Bis auf die Varianz folgt der Satz aus den obigen Berechnungen. Die Varianz wird dem Leser als Übung überlassen. $\square$

Lemma 6.26 (Eigenschaften von g). Unter der Annahme (6.6) gilt

1. g ist strikt konvex und monoton wachsend in $[0, 1]$.
2. $g(0) = p_0, g(1) = 1$
3. Ist $m \leq 1$ so gilt $g(t) > t$ für alle $t \in (0, 1)$.
4. Ist $m > 1$, dann hat $g(t) = t$ genau eine Lösung in $(0, 1)$.

Beweis. 1. Wegen $p_k > 0, \sum_{k=0}^{+\infty} p_k = 1$ und $0 < p_0 \leq p_1 + p_0 < 1$ ist $p_k > 0$ für ein $k \geq 2$. Damit gilt

$$\dot{g}(t) > 0 \quad \text{und} \quad \ddot{g}(t) > 0.$$

2. Ist klar.

3. Wenn $\dot{g}(1) = m \leq 1$, dann

$$\frac{d}{dt}(g(t) - t) = \dot{g}(t) - 1 < \dot{g}(1) - 1 \leq 0,$$

das heisst, $t \mapsto g(t) - t$ ist strikt fallend und wegen $g(1) = 1$ folgt die behauptete Ungleichung.

4. Wegen der Konvexität hat die Gleichung

$$g(t) = t \quad (6.7)$$

höchstens 2 Lösungen auf $[0, 1]$, eine davon ist $t = 1$. Aus $\dot{g}(1) = m > 1$ und $g(0) = p_0 > 0$ folgt die Existenz einer Lösung von (6.7) in $(0, 1)$. Sei q die kleinste Lösung von (6.7), dann gilt nach Lemma 6.26: Ist $m \leq 1$, ist $q = 1$ und ist $m > 1$, dann ist $q < 1$. $\square$

Das folgende Lemma zeigt, dass q , wie im obigen Beweis ein Fixpunkt für $x_n = g(x_n)$ mit $x_0 \in [0, 1)$.

Lemma 6.27. Es gilt:

1. Ist $t \in (0, q)$, dann $g_n(t) \nearrow q$ für $n \rightarrow +\infty$
2. Ist $t \in (q, 1)$, so gilt $g_n(t) \searrow q$ für $n \rightarrow +\infty$
3. Ist $t \in \{q, 1\}$, so gilt $g_n(t) = t$ für $n \in \mathbb{N}$.

Beweis. 1. Für $0 \leq t < q$ gilt nach Lemma 6.26 $t < g(t) \leq g(q)$ und es folgt

$$t < g_1(t) < g_2(t) < \cdots < g_n(t) < g(q) = q \quad \text{für alle } n \in \mathbb{N}.$$

Da diese Folge beschränkt und monoton ist, konvergiert sie auch. Da g stetig ist folgt aber

$$\lim_{n \rightarrow +\infty} g_n(t) = \lim_{n \rightarrow +\infty} g(g_{n-1}(t)) = g(\lim_{n \rightarrow +\infty} g_n(t))$$

das heisst, der Grenzwert ist ein Fixpunkt. Da q nach Annahme die kleinste Lösung von

$$g(t) = t$$

ist gilt

$$\lim_{n \rightarrow +\infty} g_n(t) = q.$$

2. Ist $q < t < 1$, dann zeigt man mit einem ähnlichen Argument, dass

$$1 > g_n(t) \searrow \lim_{n \rightarrow +\infty} g_n(t) \geq q.$$

Da q und 1 die einzigen Fixpunkte dieser Iteration sind, gilt

$$\lim_{n \rightarrow +\infty} g_n(t) = q.$$

3. Nach Lemma 6.26 sind q und 1 die einzigen Fixpunkte von g . $\square$

Definition 6.28. Das **Aussterbeereignis** des Galton-Watson-Prozesses $(Z_n)_{n \in \mathbb{N}_0}$ ist

$$Q := \bigcup_{n=1}^{+\infty} \bigcap_{k=n}^{+\infty} \{Z_k = 0\} = \left\{ \lim_{k \rightarrow +\infty} Z_k = 0 \right\} \cup \{ \exists N \in \mathbb{N}_0 : Z_n = 0 \forall n \geq N \}$$

Wir nennen $\mathbb{P}(Q)$ dann die **Aussterbewahrscheinlichkeit**.

Bemerkung 6.29. Da aus $Z_k = 0$ stets $Z_n = 0$ für alle $n \geq k$ folgt, gilt also

$$Q = \bigcup_{n \in \mathbb{N}} \{Z_n = 0\}$$

und damit

$$\mathbb{P}(Q) = \lim_{n \rightarrow +\infty} \mathbb{P} \left(\bigcup_{k=1}^n \{Z_k = 0\} \right) = \lim_{n \rightarrow +\infty} \mathbb{P}(Z_n = 0) = \lim_{n \rightarrow +\infty} g_n(0).$$

△

Satz 6.30. Die Aussterbewahrscheinlichkeit eines Galton-Watson-Prozesses $(Z_n)_{n \in \mathbb{N}}$ mit $Z_0 \equiv 1$ ist die kleinste Lösung q von

$$g(t) = t, \quad t \in [0, 1].$$

Dabei ist $\mathbb{P}(Q) = 1$ falls $m \leq 1$ und $\mathbb{P}(Q) < 1$ falls $m > 1$.

Beweis. Dies ist eine direkte Konsequenz der obigen Lemmata und Bemerkungen. □

7. Markov-Ketten in stetiger Zeit

7.1. Definition und Basics

Wir werden analog zu den ersten Kapiteln mit E den Zustandsraum bezeichnen, den wir als *höchstens abzählbar* annehmen.

Definition 7.1. Eine Familie $X = (X_t)_{t \in [0, +\infty)}$ von E -wertigen Zufallsvariable heisst **Markov-Kette in stetiger Zeit**, falls für jedes $n \in \mathbb{N}_0$, $0 \leq t_0 \leq \dots \leq t_n$, $s \geq 0$, $x_0, \dots, x_n \in E$,

$$\mathbb{P} \left(X_{t_n+s} = y \mid \bigcap_{i=0}^n \{X_{t_i} = x_i\} \right) = \mathbb{P}(X_s = y \mid X_0 = x_n). \quad (7.1)$$

Bemerkung 7.2. Man beachte einerseits die Ähnlichkeit mit der Markov-Kette in diskreter Zeit. Andererseits ist (7.1) die „ein Zeit“-Markoveigenschaft und impliziert auch die Homogenität in Zeit. $\triangle$

Bemerkung 7.3. Man kann zeigen, dass der Poisson Prozess die Eigenschaft der Markov-Kette in stetiger Zeit erfüllt. Dies lässt sich mit Satz Theorem 6.13 zeigen. $\triangle$

Beispiel 7.4. Sei $N = (N_t)_{t \in [0, +\infty)}$ ein Poisson-Prozess mit Intensität $\lambda > 0$ und sei $Y = (Y_n)_{n \in \mathbb{N}_0}$ eine Markov-Kette in diskreter Zeit mit Startverteilung μ und Übergangswahrscheinlichkeit $p = (p_{x,y})_{x,y \in E}$, wobei N und Y unabhängig sind. Wir definieren nun einen stochastische Prozess $X = (X_t)_{t \in [0, +\infty)}$ durch

$$X_t := Y_{N(t)}. \quad (7.2)$$

$\triangle$

Behauptung 7.5. (7.2) ist eine Markov-Kette in stetiger Zeit.

Beweis. Wir nehmen Zeiten und Punkte $0 = t_0 < \dots < t_n$, $s \geq 0$, $x_0, \dots, x_n \in E$, dann folgt

$$\begin{aligned} \mathbb{P} \left(\bigcap_{i=0}^n \{X_{t_i} = x_i\} \right) &= \sum_{\substack{k_1, \dots, k_n=0 \\ k_1 \leq k_2 \leq \dots \leq k_n}}^{+\infty} \mathbb{P} \left(\bigcap_{i=0}^n \{N_{t_i} = k_i, Y_{k_i} = x_i\} \right) \\ &= \sum_{k_1, \dots, k_n} \mathbb{P} \left(\bigcap_{i=0}^n \{Y_{k_i} = x_i\} \mid \bigcap_{i=1}^n \{N_{t_i} = k_i\} \right) \mathbb{P} \left(\bigcap_{i=1}^n \{N_{t_i} = k_i\} \right). \end{aligned}$$

Wegen der Unabhängigkeit folgt nun dass

$$\mathbb{P} \left(\bigcap_{i=0}^n \{Y_{k_i} = x_i\} \mid \bigcap_{i=1}^n \{N_{t_i} = k_i\} \right) = \mathbb{P} \left(\bigcap_{i=0}^n \{Y_{k_i} = x_i\} \right) = \mu(x_0) \prod_{i=1}^n p^{k_i - k_{i-1}}(x_{i-1}, x_i)$$

und dank der Eigenschaft des Poisson-Prozesses

$$\mathbb{P}\left(\bigcap_{i=1}^n \{N_{t_i} = k_i\}\right) = \mathbb{1}_{k_0=0} \left(\prod_{i=1}^n e^{-\lambda(t_i - t_{i-1})} \frac{(\lambda(t_i - t_{i-1}))^{k_i - k_{i-1}}}{(k_i - k_{i-1})!} \right),$$

woraus wir nun sehen, dass

$$\begin{aligned} \mathbb{P}\left(\bigcap_{i=0}^n \{X_{t_i} = x_i\}\right) &= \mu(x_0) \sum_{\substack{k_1, \dots, k_n=0 \\ k_1 \leq k_2 \leq \dots \leq k_n}}^{+\infty} \prod_{i=1}^n p^{k_i - k_{i-1}}(x_{i-1}, x_i) e^{-\lambda(t_i - t_{i-1})} \frac{(\lambda(t_i - t_{i-1}))^{k_i - k_{i-1}}}{(k_i - k_{i-1})!} \\ &= \mu(x_0) \prod_{i=1}^n \sum_{\ell_i=0}^{+\infty} p^{\ell_i}(x_{i-1}, x_i) e^{-\lambda t_i} \frac{(\lambda t_i)^{\ell_i}}{\ell_i!} \end{aligned}$$

und analog sieht man, dass

$$\mathbb{P}(X_{t_0}, \dots, X_{t_n} = x_n, X_{t_n+s} = y)$$

eine ähnliche Struktur hat. Dann liefert Division der obigen Terme, dass die linke Seite von (7.1) gleich

$$\sum_{\ell \geq 0} e^{-\lambda s} \frac{(\lambda s)^\ell}{\ell!} p^\ell(x_n, y) = P(X_s = y \mid X_0 = x_n)$$

ist und damit gilt (7.1). Dies zeigt die Behauptung. $\square$

Bemerkung 7.6. Wir sehen nun, dass X die Übergangswahrscheinlichkeit

$$\mathbb{P}(X_t = y \mid X_0 = x_0) = \sum_{\ell \geq 0} e^{-\lambda s} \frac{(\lambda s)^\ell}{\ell!} p^\ell(x, y)$$

hat. $\triangle$

Satz 7.7 (Chapmann-Kolmogorov). Sei X wie in Definition 7.1. Setze

$$p_t(x, y) := \mathbb{P}(X_t = y \mid X_0 = x_0)$$

die *Übergangswahrscheinlichkeiten*. Dann gilt

$$p_{t+s}(x, y) = \sum_{z \in E} p_t(x, z) p_s(z, y)$$

für alle $s, t \geq 0$ und $x, y \in E$.

Beweis. Dies folgt aus nachstehender Rechnung:

$$\begin{aligned}
 p_{t+s}(x, y) &= \mathbb{P}(X_{t+s} = y \mid X_0 = x_0) = \sum_{z \in E} \mathbb{P}(X_{t+s} = y, X_t = z \mid X_0 = x_0) \\
 &= \sum_{z \in E} \mathbb{P}(X_{t+s} = y \mid X_t = z, X_0 = x_0) \underbrace{\mathbb{P}(X_t = z \mid X_0 = x_0)}_{=p_t(x, z)} \\
 &\stackrel{\text{Lemma 6.17}}{=} \sum_{z \in E} \mathbb{P}(X_s = y \mid X_0 = z) p_t(x, z) \\
 &= \sum_{z \in E} p_t(x, z) p_s(z, y). \quad \square
 \end{aligned}$$

Bemerkung 7.8. Sei $t_0 > 0$. Ist $p_t(x, y)$ bekannt für alle $x, y \in E$ und $t \leq t_0$, kann man mit Chapman-Kolmogorov $p_t(x, y)$ für alle $t \geq 0$ berechnen. Daher: Um X_t komplett zu beschreiben braucht man lediglich

$$q(x, y) := \lim_{t \searrow 0} \frac{1}{t} p_t(x, y) = \underbrace{\frac{\partial}{\partial t^+} p_t(x, y)}_{\text{einseitige Ableitung}}, \quad x \neq y \quad (7.3)$$

zu kennen. △

Aus (7.3) folgt, dass für $x \neq y$

$$p_t(x, y) = q(x, y) \cdot t + o(t) \quad \text{für } t \searrow 0,$$

daher können wir $q(x, y)$ als die *Rate des Sprunges von x nach y* interpretieren. Kommen wir nun zurück zum vorherigen Beispiel:

Beispiel 7.9 (Fortsetzung von Example 7.4). Nun folgt für die Markov-Kette aus Example 7.4, dass für $x \neq y$

$$p_t(x, y) = 1p^0(x, y) + e^{-\lambda t}(\lambda t)p(x, y) + \underbrace{\sum_{\ell \geq 2} e^{-\lambda t} \frac{(\lambda t)^\ell}{\ell!} p^\ell(x, y)}_{=o(t)}$$

und damit $q(x, y) = \lambda p(x, y)$. Die gesamte Sprungrate für $x \in E$ ist dann gegeben durch

$$\sum_{\substack{y \in E \\ y \neq x}} q(x, y) = \lambda \sum_{y \in E \setminus \{x\}} p(x, y) = \lambda(1 - p(x, x)).$$

△

Beispiel 7.10 (M/M/S-Schlange). Betrachte eine Bankfiliale mit Anzahl Schaltern $s < +\infty$. Wir betrachten nun die Warteschlange und möchten einen stochastischen Prozess finden, der dies modelliert. Wir nehmen also an, dass die Kunden nach einem Poissonprozess mit Intensität $\lambda > 0$ ankommen und dass die Bedienungszeiten $\text{Exp}(\mu)$ verteilt sind und unabhängig von einander sind. Seien

$$X_t := \# \text{Kunden in der Bank zur Zeit } t.$$

Was ist nun die Rate $q(x, y)$?

$$q(x, y) = \begin{cases} \lambda, & y = x + 1 \\ x \cdot \mu, & x \leq s, y = x - 1 \\ s \cdot \mu, & x > s, y = x - 1 \\ 0, & \text{sonst} \end{cases}$$

Im Folgenden wollen wir aus diesen Raten einen stochastischen Prozess konstruieren. $\triangle$

7.2. Konstruktion einer Markov-Kette in stetiger Zeit aus den Raten

Gegeben seien: E , ein höchstens abzählbarer Zustandsraum und $(q(x, y))_{x, y \in E}$ mit $q(x, y) \in [0, +\infty)$ für alle $x, y \in E$. Wir wollen nun eine Markov-Kette mit diesen Raten konstruieren.

Setze dazu

$$\lambda(x) := \sum_{y \in E \setminus \{x\}} q(x, y) = \text{Gesamtrate des Sprunges weg von } x$$

und weiter

$$r(x, y) = \begin{cases} \frac{q(x, y)}{\lambda(x)}, & \lambda(x) > 0, x \neq y \\ \delta(x, y) & \lambda(x) = 0 \\ 0 & \lambda(x) > 0, x = y \end{cases} \quad (7.4)$$

Behauptung 7.11. (7.4) ist eine diskrete Übergangswahrscheinlichkeit.

Beweis. Der einfache Beweis verbleibt dem Leser zur Übung. $\square$

Informell können wir die Markov-Kette folgendermassen konstruieren: Ist $X_t = x$ dann

- falls $\lambda(x) = 0$ setzen wir $X_{t+s} = x$ für jedes $s \geq 0$
- falls $\lambda(x) > 0$ warten wir eine exponentialverteilte Zeit mit Parameter $\lambda(x)$ und machen dann einen Sprung mithilfe von den $r(x, \cdot)$ und interiere.

Beispiel 7.12. Formell gehen wir nun wie folgt vor: Sei μ eine Verteilung auf E , Y eine Markov-Kette mit Übergangswahrscheinlichkeit $p = (p_{x, y})_{x, y \in E}$ und Startverteilung μ und sei $(\tau_i)_{i \in \mathbb{N}}$ eine Folge von unabhängigen Zufallsvariablen mit $\tau_i \sim \text{Exp}(1)$ für alle $i \in \mathbb{N}$, unabhängig von Y . Setze nun

$$T_i := \frac{\tau_i}{\lambda(Y_i)} \sim \text{Exp}(\lambda(Y_i)), \quad \text{bedingt auf } Y,$$

$$S_n := \sum_{i=0}^{n-1} T_i, \quad S_0 = 0$$

und

$$X_t = Y_n \quad \text{falls } t \in [S_{n-1}, S_n).$$

Man könnte hier auch äquivalent

$$N_t := \sup\{n \geq 0 : S_n \leq t\} = \# \text{ Sprünge vor } t$$

definieren und

$$X_t := Y_{N_t}$$

setzen (Achtung: N_t ist nicht unbedingt ein Poisson-Prozess!). $\triangle$

Frage 7.13. 1. Ist dies eine Markov-Kette im Sinne von Definition 7.1?

2. Wie berechnet man die Übergangswahrscheinlichkeiten?

3. Ist diese Konstruktion allgemein d.h., funktioniert dies für alle Ratenmatrizen.

Zu 3: Was kann schiefgehen? Sei

$$S_\infty := \lim_{n \rightarrow +\infty} S_n.$$

Ist $S_\infty < +\infty$ fast überall, dann ist X_t für $t \in [S_\infty, +\infty)$ nicht definiert.

Beispiel 7.14 (Birth-Chain). Sei $E = \mathbb{N}$, $p \geq 0$ und

$$q : E \times E \rightarrow E, \quad q(x, y) := \begin{cases} x^p, & y = x + 1 \\ 0, & \text{sonst} \end{cases}.$$

Wir starten eine Kette $X_0 \equiv 1$. Dann ist $\lambda(x) = x^p$ und

$$r(x, y) = \mathbb{1}_{y=x+1}(x, y) \Rightarrow Y_i = i + 1$$

und daher $\tau_i \sim \text{Exp}((i+1)^p)$ und damit $\mathbb{E}[\tau_i] = (i+1)^{-p}$ und $\text{Var}(\tau_i) = (i+1)^{-2p}$. Mit monotoner Konvergenz sehen wir, dass

$$\mathbb{E}[S_\infty] = \lim_{n \rightarrow +\infty} \mathbb{E}[S_n] = \lim_{n \rightarrow +\infty} \sum_{i=0}^{n-1} \frac{1}{(i+1)^p} = \begin{cases} +\infty, & p \leq 1 \\ C \in \mathbb{R}, & p > 1 \end{cases}.$$

Damit ist im Fall $p > 1$ S_∞ fast sicher endlich. Dies ist aber wie oben erwähnt problematisch; der Prozess ist dann nicht überall definiert. Dies nennt man *Explosion* der Kette (in endlicher Zeit haben wir unendliche Population). $\triangle$

Übung 7.15. Zeigen sie, dass $p \leq 1$ impliziert, dass $\mathbb{P}(S_\infty = +\infty) = 1$. *Hinweis:* Sie werden die Varianz dafür brauchen.

Wir werden im Folgenden voraussetzen, dass die Parameter so gewählt werden, dass keine Explosion stattfindet.

Zu 1: Wir wollen zeigen, dass $(X_t)_{t \geq 0}$ eine Markov-Kette ist:

Satz 7.16. Seien E, q so gewählt, dass $\mathbb{P}(S_\infty = +\infty) = 1$. Dann definiert Example 7.12 eine Markov-Kette auf E .

Notation 7.17. Sei $\mathbb{P}_x$ die Verteilung von X gegeben $X_0 = x$, analog zu den Markov-Ketten in diskreter Zeit.

Beweis von Theorem 7.16. Seien $0 \leq t_0 \leq \dots \leq t_n$, $s \geq 0$ und $x_0, \dots, x_n, y \in E$. Wir wollen nun zeigen, dass

$$\mathbb{P} \left(\bigcap_{i=0}^n \{X_{t_i} = x_i\} \cap \{X_{t_n+s} = y\} \right) = \mathbb{P} \left(\bigcap_{i=0}^n \{X_{t_i} = x_i\} \right) \mathbb{P}_{x_n}(X_s = y).$$

Wir führen dazu folgende Notation ein:

$$\mathbf{x} := \begin{bmatrix} x_0 \\ \vdots \\ x_n \end{bmatrix} \in E^{n+1}, \quad \mathbf{t} := \begin{bmatrix} t_0 \\ \vdots \\ t_n \end{bmatrix} \in \mathbb{R}_{\geq 0}^{n+1} \quad \mathbf{X}_{\mathbf{t}} := \begin{bmatrix} X_{t_0} \\ \vdots \\ X_{t_n} \end{bmatrix},$$

analog für $\mathbf{N}$ und für $\boldsymbol{\alpha} = (\alpha_i)_{i=0}^n \in \mathbb{N}_0^{n+1}$ Multiindex setzen wir

$$\mathbf{Y}_{\boldsymbol{\alpha}} := \begin{bmatrix} Y_{\alpha_0} \\ \vdots \\ Y_{\alpha_n} \end{bmatrix} \quad \text{und} \quad \mathbf{Y}_{\mathbf{N}_{\mathbf{t}}} = \begin{bmatrix} Y_{N_{t_0}} \\ \vdots \\ Y_{N_{t_n}} \end{bmatrix}.$$

Zuerst sehen wir, dass

$$\begin{aligned} \mathbb{P} \left(\bigcap_{i=0}^n \{X_{t_i} = x_i\} \cap \{X_{t_n+s} = y\} \right) &= \mathbb{P}(\mathbf{X}_{\mathbf{t}} = \mathbf{x}, X_{t_n+s} = y) \\ &= \mathbb{P}(\mathbf{Y}_{\mathbf{N}_{\mathbf{t}}} = \mathbf{x}, Y_{N_{t_n}+s} = y) \\ &= \sum_{\substack{\boldsymbol{\alpha} = (\alpha_i)_{i=0}^n \in \mathbb{N}_0^{n+1} \\ 0 \leq \alpha_1 \leq \dots \leq \alpha_n}} \sum_{k \geq 0} \mathbb{P}(\mathbf{Y}_{\boldsymbol{\alpha}} = \mathbf{x}, Y_{k_n+k} = y, C_{\boldsymbol{\alpha},k}) \end{aligned}$$

wobei $C_{\boldsymbol{\alpha},k} = \{N_{t_0} = k_0, \dots, N_t = k_n, N_{t_n+s} = k_n + k\}$. Damit sehen wir, dass

$$\mathbb{P}(\mathbf{X}_{\mathbf{t}} = \mathbf{x}, X_{t_n+s} = y) = \sum_{\substack{0 \leq k_0 \leq \dots \leq k_n \\ k \geq 0}} \sum_{\substack{\mathbf{y} = (y_i)_{i=0}^{k_n+k} \in E^{k_n+k+1} \\ y_{k_i} = x_i \forall 0 \leq i \leq n, y_{k_n+k} = y}} \mathbb{P}(C_{\boldsymbol{\alpha},k} \mid \mathbf{Y}_{(i)_{i=0}^{k_n+k}} = \mathbf{y}) \mathbb{P}(\mathbf{Y}_{(i)_{i=0}^{k_n+k}} = \mathbf{y}).$$

Wir berechnen nun $\mathbb{P}(C_{\boldsymbol{\alpha},k} \mid \mathbf{Y}_{(i)_{i=0}^{k_n+k}} = \mathbf{y})$: Für alle $0 \leq i \leq n$,

$$\mathbb{P}(C_{\boldsymbol{\alpha},k} \mid \mathbf{Y}_{(i)_{i=0}^{k_n+k}} = \mathbf{y}) = \mathbb{P} \left(\bigcap_{i=1}^n \{S_{k_i} \leq t_i < S_{k_{i+1}}\} \cap \{S_{k_n+k} \leq t_n + s < S_{k_n+k+1}\} \mid \mathbf{Y}_{(i)_{i=0}^{k_n+k}} = \mathbf{y} \right)$$

Unter $\mathbf{Y}_{(i)_{i=0}^{k_n+k}} = \mathbf{y}$ sind die T_i s unabhängig und $T_i \sim \text{Exp}(\lambda y_i)$ (wegen der Bedingung). Wir setzen

$$U := t_n - (T_0 + \dots + T_{k_n-1}) \geq 0$$

und wir fordern nun aufgrund obiger Bedingungen $T_{k_n} \geq U$. Weiter ist

$$T_{k_n} - U + T_{k_n+1} + \dots + T_{k_n+k-1} \leq s < T_{k_n} - U + \dots + T_{k_n+k}.$$

Damit haben wir zwei weitere Bedingungen auf T_{k_n} gefunden. Wir können damit die Gedächtnislosigkeit anwenden, denn gegeben U und $T_{k_n} \geq U$ ist $T_{k_n} - U \sim \text{Exp}(\lambda y_{k_n})$.

Damit ist für $\mathbf{k} = (k_i)_{i=0}^n \in \mathbb{N}^{n+1}$, $k_i \leq k_{i+1}$,

$$\begin{aligned} \mathbb{P}\left(C_{\alpha,k} \mid \mathbf{Y}_{(i)_{i=0}^{k_n+k}} = \mathbf{y}\right) &= \mathbb{P}\left(\{\mathbf{N}_t = \mathbf{k}\} \cap \left\{\sum_{j=0}^{k-1} T_{k_n+i} \leq s \leq \sum_{\ell=0}^n T_{k_n+\ell}\right\} \mid \mathbf{Y}_{(i)_{i=0}^{k_n+k}} = \mathbf{y}\right) \\ &\stackrel{\text{Unabh.}}{=} \mathbb{P}\left(\mathbf{N}_t = \mathbf{k} \mid \mathbf{Y}_{(i)_{i=0}^{k_n+k}} = \mathbf{y}\right) \mathbb{P}\left(\sum_{j=0}^{k-1} T_{k_n+i} \leq s \leq \sum_{\ell=0}^k T_{k_n+\ell} \mid \mathbf{Y}_{(i)_{i=0}^{k_n+k}} = \mathbf{y}\right) \\ &= h_2(y_0, \dots, y_{k_n}) h_2(y_{k_n}, \dots, y_{k_n+k}) \end{aligned}$$

und weiter

$$\begin{aligned} \mathbb{P}\left(\mathbf{Y}_{(i)_{i=0}^{k_n+k}} = \mathbf{y}\right) &\stackrel{\text{ME für } Y}{=} \mathbb{P}(\mathbf{Y}_{(0,\dots,k_n)} = (y_i)_{i=0}^{k_n}) \mathbb{P}_{y_{k_n}}(\mathbf{Y}_{(0,\dots,k)} = (y_i)_{i=k_n}^{k_n+k}) = \\ &= \sum_{0 \leq k_0 \leq \dots \leq k_n} \sum_{\substack{y_0, \dots, y_{k_n} \\ y_{k_i} = x_i \forall 0 \leq i \leq n}} \mathbb{P}(\mathbf{Y}_{(0,\dots,k_n)} = (y_i)_{i=0}^{k_n}) h_1(y_0, \dots, y_{k_n}) \\ &\quad \underbrace{\hspace{10cm}}_{=\mathbb{P}(X_{t_0}=x_0, \dots, X_{t_n}=x_n)} \\ &\times \sum_{k \geq 0} \sum_{y_{k_n+1}, \dots, y_{k_n+k} = y} \underbrace{\mathbb{P}_{y_{k_n}}(\mathbf{Y}_{(0,\dots,k)} = (y_i)_{i=k_n}^{k_n+k})}_{=\mathbb{P}_{x_n}} h_2(y_{k_n}, \dots, y_{k_n+k}) \cdot \\ &\quad \underbrace{\hspace{10cm}}_{=\mathbb{P}_{x_n}(X_s=y)} \end{aligned}$$

Dies zeigt das Resultat. $\square$

Zu 2: Die Frage nach den Übergangswahrscheinlichkeiten hat auch praktische Anwendungen. Es gilt

$$\mathbb{P}_x(X_t = y) = \mathbb{P}_x(Y_{N_t} = y).$$

Das Y ist vergleichsweise einfach zu berechnen, aber N_t ist relative komplex und abhängig von Y . Für Poisson-Prozesse haben wir die entsprechenden Formeln gesehen, aber im Allgemeinen sind diese Wahrscheinlichkeiten schwierig zu berechnen.

Satz 7.18 (Kolmogorov Rückwärtsgleichung). Seien E, q so gewählt, dass keine Explosion stattfindet, d.h. $\mathbb{P}_x(S_\infty = +\infty) = 1$ für alle $x \in E$.

1. Die Funktion

$$t \mapsto p_t(x, y) \in C^1 \tag{7.5}$$

ist differenzierbar und

2. $p_t(x, y)$ löst die folgende Gleichung:

$$\frac{d}{dt} p_t(x, y) = \sum_{z \in E \setminus \{x\}} q(x, z) p_t(z, y) - \lambda(x) p_t(x, y)$$

für alle $x, y \in E$.

Intuition: Nehmen wir an, dass (7.5) differenzierbar sei. Dann ist

$$\frac{d}{dt} p_t(x, y) = \lim_{h \searrow 0} \frac{p_{t+h}(x, y) - p_t(x, y)}{h}.$$

Nutzen wir Chapman-Kolmogorov, ergibt sich

$$\begin{aligned} \frac{d}{dt} p_t(x, y) &= \lim_{h \searrow 0} \frac{1}{h} \left(\sum_{z \in E} p_h(x, z) p_t(z, y) - p_t(x, y) \right) \\ &= \lim_{h \searrow 0} \left(\sum_{z \in E \setminus \{x\}} \underbrace{\frac{p_h(x, z)}{h}}_{\xrightarrow{h \rightarrow 0} q(x, z)} p_t(z, y) + \underbrace{\frac{p_h(x, x) - 1}{h}}_{\xrightarrow{h \rightarrow 0} -\lambda(x)} p_t(x, y) \right) \end{aligned}$$

was im Falle von endlichem E die obige Formel ergibt, sofern man noch rechtfertigt, weshalb die angegebenen Konvergenzen vertauschen.

Lemma 7.19. Sei X wie in der formalen Konstruktion der Markov-Kette geschildert. Sei $T = T_0$. Dann:

1. Unter $\mathbb{P}_x$ sind T und X_T unabhängig für jedes $x \in E$.
2. Für alle $t_0 \leq \dots \leq t_n$ und $x_0, \dots, x_n \in E$ gilt

$$\mathbb{P} \left(\bigcap_{i=0}^n \{X_{T+t_i} = x_i\} \mid T, X_T \right) (\omega) = \mathbb{P}_{X_T(\omega)} \left(\bigcap_{i=0}^n \{X_{t_i} = x_i\} \right),$$

für $\mathbb{P}$ -fast alle $\omega \in \Omega$.

Bemerkung 7.20. Wir können die Bedingung X_T auch durch $X_T = y$ ersetzen für alle y und auf der RHS $\mathbb{P}_y$ schreiben, denn X_T ist eine diskrete Zufallsvariable, allerdings müssen wir immer noch das T behalten, da T eine zeitstetige Zufallsvariable ist. $\triangle$

Beweis von Lemma 7.19. Es gilt

$$T = T_0 = \frac{\tau_0}{\lambda(Y_0)} = \frac{\tau_0}{\lambda(x)} \quad \text{und} \quad X_T = X_{S_1} = Y_1$$

und da τ_0 und Y_1 unabhängig sind, folgt der erste Punkt. Den zweiten Punkt zeigen wir hier nicht. $\square$

Satz 7.21. Betrachte X wie konstruiert mit $\mathbb{P}(S_\infty = +\infty) = 1$. Dann gilt für jedes $t \geq 0$ und $x, y \in E$, dass

$$p_t(x, y) = e^{-\lambda(x)t} \delta_{x,y} + \int_0^t \lambda(x) e^{-\lambda(x)s} \sum_{z \neq x} r(x, z) p_{t-s}(z, y) ds$$

Beweis. Siehe Notizen. $\square$

Wir schreiben

$$\begin{aligned} p_t(x, y) &= \mathbb{P}_x(X_t = y) = \underbrace{\mathbb{P}_x(X_t = y, T > t)}_{=\delta_{x,y} \mathbb{P}_x(T > t)} + \mathbb{P}_x(X_t = y, T \leq t) \\ &= \delta_{x,y} e^{-\lambda(x)t} + \mathbb{P}_x(X_t = y, T \leq t) \end{aligned}$$

und

$$\begin{aligned}\mathbb{P}_x(X_T = y, T \leq t) &= \sum_{z \neq x} \mathbb{P}_x(X_t = y, X_T = z, T \leq t) \\ &= \dots\end{aligned}$$

(siehe Skript!!!!).

Dann folgt die Differentialgleichung aus obiger Argumentation.

Satz 7.22 (Vorwärts-Kolmogorov-Gleichung). Sei X wie in der Konstruktion und ohne Explosion. Dann

$$\frac{d}{dt}p_t(x, y) = \sum_{z \neq y} p_t(x, z)q(z, y) - \lambda(y)p_t(x, y).$$

Informell ergibt sich dies aus

$$\begin{aligned}\frac{d}{dt}p_t(x, y) &= \lim_{h \searrow 0} \frac{p_{t+h}(x, y) - p_t(x, y)}{h} \\ &= \lim_{h \searrow 0} \sum_{z \in E} \frac{p_t(x, z)p_h(z, y) - p_t(x, y)}{h} \\ &= \sum_{z \neq y} \lim_{h \searrow 0} p_t(x, z) \underbrace{\frac{p_h(z, y)}{h}}_{\rightarrow q(z, y)} + \lim_{h \searrow 0} p_t(x, y) \underbrace{\frac{p_h(y, y) - 1}{h}}_{\rightarrow -\lambda(y)},\end{aligned}$$

wobei man aber wieder rechtfertigen müsste, weshalb man nur die einseitige Ableitung betrachtet und man erklären müsste, weshalb man Summe und Grenzwert vertauschen darf.

Definition 7.23. Seien (E, q) wie vorher. Die **Generatormatrix** (Q-Matrix) von X ist

$$Q(x, y) = \begin{cases} q(x, y), & x \neq y \\ -\lambda(x), & x = y \end{cases} \quad \text{für alle } x, y \in E.$$

Bemerke: Dies ist nur eine Matrix, wenn E endlich ist.

Im endlichen Fall ist dann die Vorwärtsgleichung

$$\frac{d}{dt}\mathbf{P}_t = \mathbf{P}_t\mathbf{Q}, \quad \mathbf{P}_0 = \mathbf{I} \quad \text{mit} \quad \mathbf{P}_t = (p_t(x, y))_{x, y \in E} \in \mathbb{R}^{|E| \times |E|}, \quad (7.6)$$

wobei $\mathbf{I}$ die Einheitsmatrix bezeichnet und die Rückwärtsgleichung

$$\frac{d}{dt}\mathbf{P}_t = \mathbf{Q}\mathbf{P}_t, \quad \mathbf{P}_0 = \mathbf{I}. \quad (7.7)$$

Die Lösung von (7.6) ist dann

$$\mathbf{P}_t = e^{t\mathbf{Q}}.$$

Beispiel 7.24. Wir betrachten eine Maschine, die kaputtgeht mit Rate $\lambda > 0$. Geht sie kaputt wird sie mit Rate μ repariert. Wir modellieren dies mit $E = \{0, 1\}$, wobei wir den Zustand 1 mit „kaputt“ assoziieren. Dann ist die Generatormatrix

$$\mathbf{Q} = \begin{bmatrix} -\lambda & \lambda \\ \mu & -\mu \end{bmatrix} \in \mathbb{R}^{2 \times 2}.$$

Wir sind nun interessiert in $\mathbb{P}_x(X_t = y)$ mit $x, y \in E$. Benutzen wir die Rückwärtsgleichung

$$\frac{d}{dt} \mathbf{P}_t = \mathbf{Q} \mathbf{P}_t, \quad \mathbf{P}_0 = \mathbf{I}$$

und $p_t(x, 0) + p_t(x, 1) = 1$ finden wir

$$\begin{aligned} p'_t(0, 0) &= -\lambda p(0, 0) + \lambda p(1, 0) \quad \text{und} \\ p'_t(1, 0) &= \mu p(0, 0) - \mu p(1, 0), \end{aligned}$$

womit

$$\mu p'_t(0, 0) + \lambda p'_t(1, 0) = 0$$

das impliziert, dass die Stammfunktion obiger Funktion konstant ist, daher

$$\mu p_t(0, 0) + \lambda p_t(1, 0) = \underbrace{\mu p_0(0, 0)}_{=1} + \underbrace{\lambda p_0(1, 0)}_{=0} = \mu.$$

Dann finden wir

$$p'_t(0, 0) = \lambda p_t(1, 0) + \mu(1 - p_t(0, 0)) = \mu - (\lambda + \mu)p_t(0, 0).$$

Setzen wir nun $g(t) := p_t(0, 0) - \frac{\mu}{\lambda + \mu}$ liest sich die Gleichung als

$$g'(t) = -(\lambda + \mu)g(t), \quad g(0) = 1 - \frac{\mu}{\lambda + \mu} = \frac{\lambda}{\lambda + \mu}.$$

Diese besitzt die Lösung $g(t) = \frac{\lambda}{\lambda + \mu} e^{-(\lambda + \mu)t}$ und damit

$$\begin{aligned} p_t(0, 0) &= \frac{\mu}{\lambda + \mu} + \frac{\lambda}{\lambda + \mu} e^{-(\lambda + \mu)t}, \\ p_t(0, 1) &= \frac{\lambda}{\lambda + \mu} - \frac{\lambda}{\lambda + \mu} e^{-(\lambda + \mu)t}, \\ p_t(1, 0) &= \frac{\mu}{\lambda + \mu} t - \frac{\mu}{\lambda + \mu} e^{-(\lambda + \mu)t} \quad \text{und} \\ p_t(1, 1) &= \frac{\lambda}{\lambda + \mu} + \frac{\mu}{\lambda + \mu} e^{-(\lambda + \mu)t}. \end{aligned}$$

Es folgt aus diesen Berechnungen, dass

$$\lim_{t \rightarrow +\infty} \mathbb{P}_x(X_t = 0) = \frac{\mu}{\lambda + \mu} \quad \text{und} \quad \lim_{t \rightarrow +\infty} \mathbb{P}_x(X_t = 1) = \frac{\lambda}{\lambda + \mu}$$

d.h., die Markov-Kette konvergiert gegen eine invariante Verteilung mit exponentieller Geschwindigkeit. $\triangle$

7.3. Klassifizierung stetiger Markov-Ketten

Das Ziel ist es nun, zu zeigen, dass Example 7.12 alle Markov-Ketten auf höchstens abzählbaren Zuständen beschreibt. Wir definieren dazu die σ -Algebra $\mathcal{F}_t$ als die kleinste σ -Algebra, die alle Informationen über X bis t enthält, d.h.,

$$\mathcal{F}_t := \sigma(\{X_s = x\}_{s \leq t, x \in E}).$$

Frage 7.25. Ist $\{X_s = x \forall s \leq t\} \in \mathcal{F}_t$?

Die Antwort ist im Allgemeinen leider nein, aufgrund der Überabzählbarkeit des Intervalls $[0, t]$. Wir werden daher zusätzliche Annahmen brauchen: Wir nehmen an, dass $X_t(\omega)$ rechtsstetig für jedes $\omega \in \Omega$ ist und hat endlich viele Sprünge auf $[0, t]$ für jedes $t \in \mathbb{R}_+$. Formal bedeutet dies

$$\Omega := \{\omega : [0, +\infty) \rightarrow E \mid \omega \text{ rechtsstetig und hat endlich viele Sprünge } [0, t] \forall t \geq 0\} \quad (7.8)$$

und $X_t(\omega) = \omega(t)$. Nun ist $\mathcal{F}_t$ die kleinste σ -Algebra, die $\{X_s = x\}$ enthält, denn: aufgrund der Rechtsstetigkeit ist

$$\{X_s = x \forall s \leq t\} = \{X_s = x \mid s \in [0, t] \cap \mathbb{Q}\} = \bigcup_{q \in [0, t] \cap \mathbb{Q}} \{X_q = x\} \in \mathcal{F}_t.$$

Beispiel 7.26. Sei $E := \{\frac{1}{n} \mid n \in \mathbb{N}\} \cup \{0\}$. Nehmen wir nun Rechtsstetigkeit für den Prozess X auf E an gilt: Es existiert $\varepsilon > 0$ sodass

$$X_{t+h}(\omega) = X_t \quad \text{für alle } h \in [0, \varepsilon].$$

△

Lemma 7.27. Sei X wie in Definition 7.1 mit der zusätzlichen Annahme (7.8). Dann gilt

$$\lim_{t \searrow 0} p_t(x, y) = \delta_{x, y} \quad \text{für alle } x, y \in E.$$

Beweis. Es folgt wegen der Rechtsstetigkeit für eine Folge $(t_n)_{n \in \mathbb{N}}$ mit $t_n \in [0, 1]$ und $t_n \searrow 0$

$$\{X_0(\omega) = x\} = \bigcap_{n \in \mathbb{N}} \{X_r = x \forall r \leq t_n\}$$

und unter $\mathbb{P}_x$ mit der Stetigkeit des Wahrscheinlichkeitsmasses

$$\begin{aligned} 1 = \mathbb{P}_x(X_0 = x) &= \lim_{n \rightarrow +\infty} \mathbb{P}(X_r = x \forall r \leq t_n) \\ &\leq \lim_{n \rightarrow +\infty} \mathbb{P}_x(X_{t_n} = x) \leq \limsup_{n \rightarrow +\infty} p_{t_n}(x, x) \end{aligned}$$

Da aber $p_{t_n}(x, x) \leq 1$ für alle $n \in \mathbb{N}$ folgt, die Behauptung für $x = y$. Der Rest bleibt dem Leser als Übung überlassen. □

Satz 7.28 (Einfache Markov-Eigenschaft). Sei X wie in Definition 7.1. Dann für

$$0 \leq t_0 \leq \dots \leq t_n, \quad 0 \leq s_0 \leq \dots \leq s_m$$

und $x_0, \dots, x_n, y_0, \dots, y_m \in E$ ist

$$\mathbb{P}(X_{t_n+s_0} = y_0, \dots, X_{t_n+s_m} = y_m \mid X_{t_i} = x_i \forall i \leq n) = \mathbb{P}_{x_n}(X_{s_j} = y_j \forall j \leq m).$$

Beweis. Der Beweis verläuft analog zum diskreten Fall durch Induktion über n (siehe Theorem 2.15). Wir überlassen ihn als Übung. $\square$

Wir setzen $J(\omega) := \inf\{t \geq 0 \mid X_t(\omega) \neq X_0(\omega)\}$, die erste Sprungzeit. Dank der Rechtsstetigkeit gilt also

$$J(\omega) = \inf\{t \in \mathbb{Q}_+ \mid X_t(\omega) \neq X_0(\omega)\}.$$

Lemma 7.29. Sei X wie in Definition 7.1 mit Rechtsstetigkeit. Dann

1. Für jedes $x \in E$ finden wir $\lambda(x) \in [0, +\infty)$ sodass für jedes $t \geq 0$

$$\mathbb{P}_x(J \geq t) = e^{-\lambda(x)t}$$

(falls $\lambda(\omega) = 0$ ist $J = +\infty$).

2. Falls $\lambda(x) > 0$, dann sind J und X_J unabhängig unter $\mathbb{P}_x$.

Bemerkung 7.30. Dies impliziert, dass wir exponentialverteilte Wartezeiten haben. $\triangle$

Beweis von Lemma 7.29. Setze

$$D_n := \left\{ \frac{k}{2^n} \mid k \in \mathbb{N}_0 \right\}, \quad n \in \mathbb{N}.$$

Es gilt dann $D_n \subseteq D_{n+1}$ für alle $n \in \mathbb{N}$. Somit folgt dank der Rechtsstetigkeit

$$\{J \geq t\} = \bigcap_{n \in \mathbb{N}_0} \{X_s = X_0 \forall s \in D_n \cap [0, t]\}$$

und daraus, mit der Stetigkeit des Wahrscheinlichkeitsmasses

$$\begin{aligned} \mathbb{P}_x(J \geq s+t) &= \lim_{n \rightarrow +\infty} \mathbb{P}_x(X_r = x \forall s \in [0, s+t] \cap D_n) \\ &= \lim_{n \rightarrow +\infty} \mathbb{P}_x(X_r = x \forall r \in [0, t] \cap D_n, X_{t+u} = x \forall u \in [0, t] \cap D_n) \\ &\stackrel{\text{M.E.}}{=} \lim_{n \rightarrow +\infty} \mathbb{P}_x(X_r = x \forall r \in [0, t \cap D_n]) \mathbb{P}_x(X_u = x \forall u \in [0, s] \cap D_n) \\ &= \mathbb{P}_x(J > t) \mathbb{P}_x(J > s). \end{aligned}$$

Damit hat $t \mapsto \mathbb{P}_x(J \geq t)$ die Exponentialeigenschaft und ist fallend mit $\mathbb{P}_x(J \geq 0) = 1$, daher folgt die Behauptung 1.

Für 2. nehmen wir $x \in E$ mit $\lambda(x) > 0$. Seien $t \geq 0$ und $y \in E \setminus \{x\}$. Dann ist (wieder

mit der Rechtsstetigkeit)

$$\begin{aligned}
& \mathbb{P}_x(J > t, X_J = y) \\
&= \lim_{n \rightarrow +\infty} \sum_{k=0}^{+\infty} \mathbb{P}_x \left(X_r = x \forall r \in D_n \cap [0, t], X_{t+s} = x \forall s \in D_n \cap \left[0, \frac{k}{2^n}\right), X_{t+\frac{k}{2^n}} = y \right) \\
&\stackrel{\text{M.E.}}{=} \lim_{n \rightarrow +\infty} \sum_{k=0}^{+\infty} \mathbb{P}_x(X_r = x \forall r \in D_n \cap [0, t]) \mathbb{P}_x \left(X_{t+s} = x \forall s \in D_n \cap \left[0, \frac{k}{2^n}\right), X_{t+\frac{k}{2^n}} = y \right) \\
&= \mathbb{P}_x(J > t) \mathbb{P}_x(Y_J = y),
\end{aligned}$$

dies zeigt die Behauptung. $\square$

Satz 7.31 (Starke Markov-Eigenschaft). Sei $T : \Omega \rightarrow \mathbb{R}_+$ eine Stoppzeit, d.h.

$$\{T \leq t\} \in \mathcal{F}_t \quad \text{für jedes } t \geq 0.$$

und sei $X = (X_t)_{t \geq 0}$ wie in Definition 7.1 und es gelte Rechtsstetigkeit. Es gilt

$$\mathbb{P}(T_{t+t_0} = y_0, \dots, X_{T+t_n} = y_n \mid \mathcal{F}_T) \equiv \mathbb{P}_{X_T}(X_{t_0} = y_0, \dots, X_{t_n} = y_n) \quad (7.9)$$

auf $T < +\infty$ für $0 \leq t_0 \leq \dots \leq t_n$ und $x_0, \dots, x_n \in E$.

Bemerkung 7.32. $A \in \mathcal{F}_T$ genau dann wenn

$$A \cap \{T \leq t\} \in \mathcal{F}_t \quad \text{für alle } t \geq 0,$$

das heisst, für jedes $A \in \mathcal{F}_T$ ist (7.9) äquivalent zu

$$\mathbb{E} \left[\mathbb{1}_{A \cap \{T < +\infty\}} \prod_{i=0}^n \mathbb{1}_{X_{T+t_i} = y_i} \right] = \mathbb{E}_x \left[\mathbb{1}_{A \cap \{T < +\infty\}} \mathbb{E}_{X_T} \left[\prod_{i=0}^n \mathbb{1}_{X_{t_i} = y_i} \right] \right]. \quad (7.10)$$

Bemerke: $A \cap \{T < +\infty\}$ liegt in der Vergangenheit bezüglich T und $\bigcap_{i=1}^n \{X_{T+t_i} = y_i\}$ liegt in der Zukunft bezüglich T . $\triangle$

Beweis von Theorem 7.31. Wir approximieren T durch eine Folge von Zufallsvariablen $(T_n)_{n \in \mathbb{N}}$, definiert durch

$$T_n := \begin{cases} \frac{k+1}{2^n}, & T \in \left(\frac{k}{2^n}, \frac{k+1}{2^n}\right] \\ 0, & T = +\infty \end{cases}.$$

Für jedes $n \in \mathbb{N}$ ist T_n eine Stoppzeit, die abzählbar viele Werte annimmt, denn

$$\left\{ T_n \leq \frac{k+1}{2^n} \right\} = \left\{ T \leq \frac{k+1}{2^n} \right\} \in \mathcal{F}_{\frac{k+1}{2^n}}$$

da T eine Stoppzeit ist. Wir schreiben nun

$$\mathbb{E} \left[\mathbb{1}_{A \cap \{T < +\infty\}} \prod_{i=0}^n \mathbb{1}_{X_{T_m+t_i} = x_i} \right] = \sum_{k=0}^{+\infty} \mathbb{E} \left[\mathbb{1}_{A \cap \{T_n = \frac{k}{2^m}\}} \prod_{i=0}^n \mathbb{1}_{X_{\frac{k}{2^m}+t_i} = x_i} \right], \quad (7.11)$$

dann ist nun $A \cap \{T_n = \frac{k}{2^m}\} \in \mathcal{F}_{\frac{k}{2^m}}$. Dann folgt aus der schwachen Markov-Eigenschaft, dass obiges gleich

$$\begin{aligned} (7.11) &= \sum_{k \geq 0} \mathbb{E}_x \left[\mathbb{1}_{A \cap \{T = \frac{k}{2^m}\}} \mathbb{P}_{X_{\frac{k}{2^m}}} \left[\bigcap_{i=0}^n X_{t_i} = x_i \right] \right] \\ &= \mathbb{E}_x \left[\mathbb{1}_{A \cap \{T_m < +\infty\}} \mathbb{P}_{X_{T_m}} \left[\bigcap_{i=0}^n X_{t_i} = x_i \right] \right] \end{aligned}$$

und damit

$$\mathbb{E} \left[\mathbb{1}_{A \cap \{T < +\infty\}} \prod_{i=0}^n \mathbb{1}_{X_{T_m+t_i}=x_i} \right] = \mathbb{E}_x \left[\mathbb{1}_{A \cap \{T_m < +\infty\}} \mathbb{P}_{X_{T_m}} \left[\bigcap_{i=0}^n X_{t_i} = x_i \right] \right]. \quad (7.12)$$

Wegen der Rechtsstetigkeit von X und $T_m \searrow T$ konvergiert $X_{T_m} \rightarrow X_T$ wenn $m \rightarrow +\infty$ und damit haben wir im obigen Ausdruck punktweise Konvergenz der Zufallsvariablen in den Erwartungswerten in (7.12). Da alle Funktionen im Erwartungswert durch 1 beschränkt sind, können wir dominierte Konvergenz anwenden und mit $m \rightarrow +\infty$ schliessen, dass (7.10) gilt. $\square$

Folgerung 7.33. Sei X wie in Definition 7.1 mit Rechtsstetigkeit. und $\lambda(x)$ wie im Lemma. Setze für $x \in E$ mit $\lambda(x) > 0$ $\rho(x, y) = \mathbb{P}_x(X_J = y)$ und

$$q(x, y) := \begin{cases} \lambda(x)r(x, y), & x \neq y, \lambda(x) > 0 \\ 0 & \text{sonst} \end{cases}.$$

Dann ist X verteilt wie der Prozess Example 7.12 mit diesem q .

7.4. Invariante Verteilungen zeitstetiger Markov-Ketten

Die Theorie der invarianten Verteilungen für zeitstetige Markov-Ketten ist analog zu der der zeitdiskreten und wird deshalb hier nicht besprochen.

8. Reversible Markov-Ketten, harmonische Funktionen und elektrische Netzwerke

Wie immer werden wir E als einen höchstens abzählbaren Zustandsraum bezeichnen und $p = (p_{x,y})_{x,y \in E}$ die Übergangswahrscheinlichkeit einer Markov-Kette $X = (X_n)_{n \in \mathbb{N}_0}$. Wir haben folgende Definition gesehen: X ist reversibel falls es eine Funktion $\pi : E \rightarrow [0, +\infty)$ mit

$$\pi(x)p_{x,y} = \pi(y)p_{y,x}.$$

Bemerkung 8.1. Ist die Summe $\sum_{x \in E} \pi(x) < +\infty$ endlich können wir reskalieren und ohne Beschränkung der Allgemeinheit annehmen, dass $\sum_{x \in E} \pi(x) = 1$. Als Beispiel hatten wir die symmetrische Irrfahrt auf $\mathbb{Z}$, die zwar reversibel ist, aber $\sum_{x \in E} \pi(x) = +\infty$ erfüllt. $\triangle$

Reversible Markov-Ketten kann man „fast“ immer als Irrfahrten auf einem Gewichteten Graphen interpretieren. Dazu setzen wir $w_{x,y} = \pi(x)p_{x,y}$. Aus der Reversibilität folgt nun, dass $w_{x,y} = w_{y,x}$. Wir definieren nun einen Graphen $G = (E, \mathcal{E})$ mit

$$\mathcal{E} := \{\{x, y\} \mid w_{x,y} > 0\}.$$

Wir werden $x \sim y$ schreiben, falls $\{x, y\} \in \mathcal{E}$, d.h. falls $w_{x,y} > 0$. Zu jeder Kante $\{x, y\} \in \mathcal{E}$ assoziieren wir $w_{x,y}$ als das Gewicht der jeweiligen Kante. Wir nehmen an, dass der gewichtete Graph (G, w) lokal endlich ist, d.h.,

$$\sum_{\substack{y \in E \\ y \sim x}} w_{x,y} < +\infty \quad \text{für jedes } x \in E.$$

Dann können wir die Übergangswahrscheinlichkeit durch

$$p_{x,y} := \begin{cases} \frac{w_{x,y}}{\sum_{z \sim x} w_{x,z}}, & x \sim y \\ 0 & x \not\sim y \end{cases} \quad (8.1)$$

definieren.

Satz 8.2. • (8.1) ist eine Übergangswahrscheinlichkeit.

- Ist $X = (X_n)_{n \in \mathbb{N}_0}$ eine Markovkette mit Übergangswahrscheinlichkeit p , dann ist X reversibel mit

$$\pi(x) := \sum_{y \sim x} w_{x,y}$$

Beweis. Offensichtlich ist $p_{x,y} \geq 0$ und durch

$$\sum_{y \in E} p_{x,y} = \sum_{y \sim x} p_{x,y} = \sum_{y \sim x} \frac{w_{x,y}}{\sum_{z \sim x} w_{x,z}} = 1$$

folgt, dass (8.1) eine Übergangswahrscheinlichkeit darstellt. Weiter ist

$$\pi(x)p_{x,y} = \frac{w_{x,y}}{\sum_{z \sim x} w_{x,z}} \cdot \sum_{z \sim x} w_{x,z} = w_{x,y}$$

und analog gilt $\pi(y)p_{y,x} = w_{y,x} = w_{x,y}$, womit sich die Reversibilität ergibt. □

Sei $w : \text{Kanten}(\mathbb{Z}^d) \rightarrow (0, k)$ mit $k \in (0, 1)$. Das Ziel ist es nun zu zeigen,

$$X \text{ rekurrent} \quad \Leftrightarrow \quad d \leq 2$$

für die Kette auf dem gewichteten Graphen (G, w) .

Exkurs: Schaltkreise. Siehe Vorlesungsskript.

A. Diverses

A.1. Erzeugendenfunktionen

Definition A.1. Sei $a = (a_i)_{i \in \mathbb{N}_0}$ eine beschränkte Folge. Wir definieren die **erzeugende Funktion** von a durch

$$\varphi(s) := \sum_{i=0}^{+\infty} a_i s^i \quad \text{für } |s| < 1.$$

Bemerkung A.2. f wird durch die Folge $(a_i)_{i \in \mathbb{N}_0}$ eindeutig bestimmt. $\triangle$

Satz A.3. Sei E endlich. Für jede wesentliche Kommunikationsklasse C der Markov Kette $X = (X_n)_{n \in \mathbb{N}_0}$ auf dem Zustandsraum E existiert eine eindeutige invariante Verteilung μ_C die von C getragen wird d.h. $\mu_C(C) = 1$.

Jede invariante Verteilung μ ist eine Linearkombination der obigen invarianten Verteilungen.

Satz A.4. Sei $\mathbf{X}$ ein $\mathbb{R}^n$ -wertiger Zufallsvektor mit Dichte $f_{\mathbf{X}} : \mathbb{R}^n \rightarrow \mathbb{R}_+$ und sei $\mathbf{Y} = \varphi(\mathbf{X})$ mit $\varphi : \mathbb{R}^n \rightarrow \mathbb{R}^n$ ein Diffeomorphismus. Dann ist die Dichte $f_{\mathbf{Y}}$ von $\mathbf{Y}$ gegeben durch

$$f_{\mathbf{Y}}(\mathbf{y}) = f_{\mathbf{X}}(\varphi^{-1}(\mathbf{y})) |\det(\mathbf{J}_{\varphi^{-1}}(\mathbf{y}))|$$